Problemas

- **Ruido**: edad aparece -5 o animal pesa 500kg.
- **Valores faltantes**: registros vacíos.
- **Inconsistencias**: un mismo producto aparece como Champú, Champu y Shampoo.
- **Datos superfluos**: columnas que no aportan valor estadístico.
- **Tamaño enorme**: millones de filas y columnas.

Etapas

- **Limpieza de datos**:
  - Manejo de valores nulos.
  - Tratamiento de valores atípicos (outliers).
  - Eliminar duplicados.
- **Integración de datos**: combinar datos de diferentes fuentes.
- **Transformación de datos**:
  - Crear nuevos atributos usando fórmulas o modelos matemáticos.
  - **Codificación de variables categóricas**: One-Hot Encoding (1 o 0) o Label Encoding (1 - n).
- **Reducción de datos**:
  - Selección de características o ejemplos.
  - **Reducción de dimensionalidad**: algoritmos como PCA para comprimir información sin perder la esencia.
- **Discretización**: convertir variables continuas en discretas.

Ejercicio

No se encontró “Pasted image 20260302125317.png”.

- **Limpieza**:
  - **Resolver NULL**: 204/edad, 202/peso.
  - **Valor atípico**: edad 250 en 205/edad, altura 1.75 en 206/altura, peso 0 en 207/peso.
- **Integración**:
  - **Conflicto de nombres**: BCN, Barcelona y Bcn en ciudad. Madrid y madrid en ciudad. Masculino, Hombre y M en género. Femenino y Mujer en género.
- **Transformación**:
  - One-Hot Encoding en género.
  - Label Encoding en ciudad.
  - Nueva columna IMC unificada por edad, altura y peso.

- **Reducción**: eliminar columna nombre.
- **Discretización**: IMC.

Limpieza de datos

Detecta y corrige errores, inconsistencias y datos faltantes en el conjunto de información original para evitar resultados sesgados o erróneos. Problemas de duplicados, consistencia, nulos y outliers.

- **Tratamiento de valores perdidos:**
  - **Eliminación (discarding)**: borrar registros o variables incompletas.
    - **Eliminación de instancias (filas)**: no se recomienda eliminar más del 5%.
      - **Pérdida del poder estadístico**: si tengo 100 datos y elimino 20, el modelo será más débil.
      - **Sesgo de elección**: si los huecos no son aleatorios, al borrar esas filas se está eliminando a un grupo específico, con lo que es probable que se esté sesgando el modelo hacia un subgrupo de la población.
    - **Eliminación de atributos (columnas)**: si hay muchos valores faltantes en una columna, intentar rellenar implica que la mayor parte de los datos serían inventados por un algoritmo, lo que introduce más ruido y sesgos que información real.
  - **Imputación simple**: rellenar el hueco con la moda (categóricas), media (numérica) o mediana (numérica, más robusta que la media).
  - **Imputación basada en modelos**: basándose en información disponible, predecir que valor va en el hueco.
    - **Regresión**: si falta el Peso, el modelo mira la Altura y la Edad de esa persona para calcular qué peso es el más probable.
    - **KNN**: buscamos a los registros más parecidos y copiamos el valor que ellos tienen. Supongamos que al i-simo registro le falta el valor del rasgo j (no se conoce el valor x_{ij}). Definimos la función de distancia de Gower entre dos registros x_i y x_j como:

      $$d(x_i, x_j) = \frac{\sum_{k=1}^{m} w_k \delta_{i,j}^k d_{i,j}^k}{\sum_{k=1}^{m} w_k \delta_{i,j}^k}$$

      donde w_k es el peso del atributo k, $\delta_{i,j}^k$ es 1 si la variable esta observada en ambos individuos y 0 si en uno de ellos tiene un valor perdido, $d_{i,j}^k$ es la disimilitud parcial del atributo k:
      - Si el atributo es numérico: $d_{i,j}^k = \frac{|x_{i,k} - x_{j,k}|}{R_k}$ donde R_k es el rango de a variable K.
      - Si el atributo es categórico: $d_{i,j}^k = 0$ si los valores coinciden, 1 si no coinciden.

- **Máxima verosimilitud (EM)**: probabilístico. Encuentra valores que mejor encajarían para que la distribución total de los datos sea lo más coherente posible.
  - **Expectation**: valor esperado para el dato perdido. $x_{miss} = \mu_{miss} + \Sigma_{12}\Sigma_{22}^{-1}(x_{obs} - \mu_{obs})$
  - **Maximization**: maximizar la función de verosimilitud, que representa la probabilidad de tener las observaciones que tenemos en el dataset. Hay que encontrar θ (media μ y varianza $\sigma = \frac{\sum(x-\mu)^2}{N}$) que mejor expliquen los datos faltantes. Covarianza $\Sigma = \frac{\sum(x-\mu_x)(y-\mu_y)}{N}$:

    No se encontró “Pasted image 20260302125736.png”.

    No se encontró “Pasted image 20260302125822.png”.

    No se encontró “Pasted image 20260302125831.png”.

    No se encontró “Pasted image 20260302125840.png”.

Ejercicio

No se encontró “Pasted image 20260302125439.png”.

$D(6,1) = \frac{8/8+1+1}{3} = 1$
$D(6,2) = \frac{0/8+0+0}{3} = 0$
$D(6,3) = \frac{7/8+1+1}{3} = 0.9583$
$D(6,4) = \frac{1/8+0+0}{3} = 0.0416$
$D(6,5) = \frac{7/8+1}{2} = 0.9375$

- **Datos anómalos**:
  - **Detección**:
    - **Métodos estadísticos**:
      - **Normalización o reescalado Min-Max**: transformar valores a un rango específico. Normalmente se reescala a [0,1]. Los valores extremos quedan cerca del 0 o 1.

        $$x' = \frac{x - min}{max - min}$$

      - **Z-score**: mide cuantas desviaciones estándar se encuentra un punto de la media. Un valor normalizado superior a 3 es anómalo (regla 68,27; 95; 99,73)

        $$x' = \frac{x - \mu}{\sigma}$$

      - **IQR (Rango Intercuartílico)**: dispersión de los datos. Se usan Q_1 y Q_3 y el rango intercuartílico $[Q_1 - 1.5 * IQR, Q_3 + 1.5 * IQR]$. Los puntos fuera del rango son anomalías.

No se encontró “Pasted image 20260225093427.png”.

No se encontró “Pasted image 20260225094611.png”.

- **Técnicas de visualización**:
  - **Boxplots**: visualiza cuartiles y puntos aislados que superan los límites del IQR.
  - **Scatter plots**: ver la relación entre dos variables e identificar puntos que se escapan del cluster principal.
  - **Histogramas**: frecuencia de los datos. Barras pequeñas o alejadas en los extremos son posibles anomalías.

No se encontró “Pasted image 20260225093530.png”.

- **Acciones**:
  - **Eliminación crítica**: se elimina si es error, el impacto es aceptable (menos del 5% de los datos) y no provoca sesgos.
  - **Imputación**: sustituir valores (apartado anterior).
  - **Transformar datos**:
    - **Transformaciones no lineales**: funciones logarítmicas o raíz cuadrada para reducir el peso de los extremos.
    - **Segmentación o clustering**: identificar si las anomalías forman un grupo con patrón propio para tratarlos de forma aislada en lugar de eliminarlos.
    - **Suavizado de datos**: aplicar filtros de variabilidad para minimizar el impacto del ruido aleatorio en el análisis global.

Integración de datos

Combinar información de múltiples fuentes para crear una vista única, coherente y valiosa.

- **Detección de instancias duplicadas**: cómo identificar registros repetidos.
  - **Métricas de caracteres**: Ejemplo: "Helena" y "Elena", "Calle Mayor 5" y "5, Mayor St.", "2345678X" y "2345678-X". Se cuenta el número de transformaciones necesarias para hacerlos coincidir.
  - **Métricas fonéticas**: Ejemplo: "Helena" y "Elena". Generan el mismo código fonético, por lo que podemos ignorar la diferencia ortográfica.
  - **Métrica de tokens**: Ejemplo: "Calle Mayor 5" y "5, Mayor St.". Se descompone la dirección en palabras sueltas y se ignora el orden.
  - **Modelo probabilístico (Fellegi-Sunter)**: definimos
    - m: probabilidad de que el campo coincida si los registros son el mismo.
    - u: probabilidad de que el campo coincida en dos registros distintos. Calculamos el peso de cada valor:
    - **Peso de concordancia (hay coincidencia)**: $w^+ = \log_2(\frac{m}{u})$

        - **Peso de desacuerdo (no hay coincidencia)**: $w^- = \log_2(\frac{1-m}{1-u})$
          Se define un score como la suma de los pesos de todas las variables y se establece un umbral $T_{superior}$ y $T_{inferior}$:
        - score $\geq T_{superior}$: mismo registro.
        - score $< T_{inferior}$: registros diferentes.
        - Otro caso: revisión manual.
- **Localización de datos redundantes**: qué información sobra. Atributo derivado de otro.
  - **Atributos nominales**:
    - **Test Chi-cuadrado de independencia**:
      - p-valor $> a$: no hay evidencia suficiente para afirmar dependencia, hay redundancia.
      - p-valor $\leq a$: hay dependencia. Solapamiento informativo. Evaluar eliminación.
  - **Atributos numéricos**:
    - **Coeficiente de correlación de Pearson**: si se sospecha relación lineal.
      - $|r| \approx 0$: no relación lineal. Mantener ambas variables.
      - $|r|$ alto ($>$ 0.8): fuerte dependencia lineal. Redundancia.
    - **Correlación de Spearman**: explorar relaciones no lineales.
      - $|\rho| \approx 0$: no relación monotónica. Mantener ambas variables.
      - $|\rho|$ alto ($>$ 0.8): fuerte dependencia monotónica. Redundancia.

        No se encontró “Pasted image 20260312182653.png”.

Transformación de datos

Transformar y refinar información bruta para que sirva de entrada adecuada a un algoritmo de aprendizaje.

- **Normalización/Escalado**: se transforman los valores de las variables para que sus magnitudes sean comparables.
  - **Escalado Min-Max**: valores a un rango entre [a, b].

$$x' = a + \frac{(x - x_{min})(b - a)}{x_{max} - x_{min}}$$

  - **Normalización Z-score**: datos con media $\mu = 0$ y desviación estándar $\sigma = 1$.

$$z = \frac{x - \mu}{\sigma}$$

  - **Escalado decimal**: se divide por una potencia de 10 para que los valores queden entre (-1, 1). j es el menor entero tal que $max(|x'|) < 1$.

$$x' = \frac{x}{10^j}$$

- **Transformaciones funcionales**: aplicamos funciones matemáticas para moldear los datos según la necesidad.
  - **Transformaciones univariantes**: aplicadas a cada variable por separado. Definen nuevas variables $Y_i = f(X_i)$
    - **Logarítmica**: $Y_i = \ln(X_i)$. Reduce asimetría positiva fuerte y estabiliza la varianza. Requiere $X_i > 0$.
    - **Potencia**: $Y_i = X_i^{\lambda}$. Modifica la asimetría según λ.
      - Si $0 < \lambda < 1$: comprime valores grandes (reduce cola derecha). Requiere $X_i \geq 0$.
      - Si $\lambda > 1$: expande los valores grandes.

      No se encontró “Pasted image 20260412210502.png”.
  - **Transformaciones multivariantes**: se crea un nuevo atributo $Y = f(X_1, ..., X_m)$ mediante transformaciones funcionales:
    - **Lineales**: suma ponderada de variables.

      $$Y = w_1 X_1 + ... + w_m X_m$$

    - **Cuadráticas**: genera una nueva variable con los términos al cuadrado y productos entre variables, modelando relaciones no lineales que una lineal no podría capturar.

      $$Y = \sum_{i=1}^{m} w_i X_i^2 + \sum_{1 \leq i < j \leq m} w_{ij} X_i X_j$$

    - **Box-Cox**: aproximar la normalidad y estabilizar la varianza en variables continuas. Requiere $X > 0$:

      $$z = g_\lambda(x) = \begin{cases} \frac{x^\lambda - 1}{\lambda}, & \text{si } \lambda \neq 0 \\ \ln(x), & \text{si } \lambda = 0 \end{cases}$$

      Si el atributo tiene valores negativos, antes desplazamos $x' = x + c$, con $c > -\min(x)$ En la versión **Box-Draper**, hace que sea invariante a cambios de escala dividiendo por la media geométrica $g = (x_1 x_2 ... x_n)^{1/n}$, quedando:

      $$z = g_\lambda(x) = \begin{cases} \frac{(x+c)^\lambda - 1}{\lambda g}, & \text{si } \lambda \neq 0 \\ \frac{\ln(x+c)}{g}, & \text{si } \lambda = 0 \end{cases}$$

      Para $\lambda = 1$ es lineal, $\lambda = 2$ cuadrática, $\lambda = 1/2$ raíz y $\lambda = -1$ inversa (aprox $1/x$). Hay que estimar λ que mejor normaliza el atributo (distribución gaussiana) con una normal con varianza constante. Se usa maxima verosimilitud.

      No se encontró “Pasted image 20260226100455.png”.
- **Codificación**: variables cualitativas se codifican de forma que puedan ser procesadas por los algoritmos.

- **One hot encoding**: categorías en k columnas binarias (0 o 1).

  No se encontró “Pasted image 20260412210755.png”.

- **Label encoding**: cada categoría a un número entero único.

  No se encontró “Pasted image 20260412210806.png”.

- **Ordinal encoding**: cada categoría a un número entero único reflejando el orden natural.

  No se encontró “Pasted image 20260412210818.png”.

Ejercicio

No se encontró “Pasted image 20260226091339.png”.

a) [0, 1]: $0 + \frac{(30-20)(1-0)}{50-20} = 1/3$
a) [-1, 1]: $-1 + \frac{(30-20)(1+1)}{50-20} = -1/3$
a) [5, 10]: $5 + \frac{(30-20)(10-5)}{50-20} = 10/3$
b) $\frac{30-35}{10} = -1/2$
c) $\frac{30}{10^2} = 0.3$ con $j = 2$

Ejercicio

No se encontró “Pasted image 20260226100947.png”.

a) Label encoding
b) Label encoding
c) Ordinal encoding

Reducción de datos

Problemas:

- **Alta dimensionalidad**: muchas columnas y pocas filas.
- **Gran volumen de datos**: muchas filas y pocas columnas.
- **Selección de rasgos**: seleccionar subconjunto de rasgos originales relevantes según un criterio estadístico o predictivo.
  - **Métodos de filtro**: filtro sobre las columnas (reducir). Se usa correlación de Pearson, Spearman, X^2, ganancia de información. Se calcula una medida para cada rasgo, ordenar los rasgos según la medida, seleccionar los k mejores o que superen un umbral.
  - **Métodos de envoltura**: se evalúan subconjuntos de rasgos entrenando un modelo y seleccionamos los que maximizan el rendimiento. Selección hacia delante (comienza sin rasgos y se añade los que más mejoran el rendimiento) y eliminación hacia atrás (comienza con todos los rasgos y se eliminan los que más afectan al

modelo). Selecciono S rasgos, entreno un modelo con S, evalúo rendimiento, repetir el proceso y comparar modelos.
    - **Métodos integrados**: los rasgos se seleccionan durante el entrenamiento del modelo. Regresión Lasso (regularización L1), árboles de decisión.

No se encontró “Pasted image 20260303091532.png”.

No se encontró “Pasted image 20260303092059.png”.

- **Selección de registros**: subconjunto de los datos para preservar la información relevante para el aprendizaje.
    - **Muestreo estadístico**: el subconjunto parezca una muestra del mismo.
        - **Aleatorio**: probabilidad uniforme.
        - **Estratificado**: divide en conjunto en estratos. Proporción original en cada grupo.
    - **Selección geométrica**: mantener la estructura relevante para el problema. Sea $d(x_i, x_j)$ una métrica, la selección se basa en analizar los vecinos.
        - **Eliminación de redundancia**: se usa CNN (Condensed Nearest Neighbor), que construye un subconjunto S de D eliminando ejemplos redundantes. Sea D el dataset y $d(x_i, x_j)$ una métrica: inicializamos S con un ejemplo de cada clase, para cada $x \in D$ se clasifica x usando KNN sobre S, si se clasifica mal, añadimos x a S. Repetir hasta quedarnos sin registros.

No se encontró “Pasted image 20260412170236.png”.

        - **Eliminación de ruido**: borra registros que estan mal en el espacio. Se usa ENN (Edited Nearest Neighbor), que elimina los mal clasificados de KNN. Para cada registro $x \in D$, consideramos $\leftarrow D$, clasificar x usando KNN sobre $D - x$, si falla eliminamos x. Repetir hasta quedarnos sin registros.

No se encontró “Pasted image 20260303100310.png”.

- **Feature extraction**: se transforman columnas en otras mas potentes. Datos originales en un espacio de menor dimensión. Se usa PCA.
- **Generación de registros**: problemas de que una clase tiene pocos ejemplos de una clase.
    - **Duplicación aleatoria**: duplica registros de la clase minoritaria hasta alcanzar la proporción deseada.
    - **Generación sintética (SMOTE)**: genera ejemplos interpolando entre vecinos. Sea $x_i \in D_{min}$ y x_j uno de sus k-vecinos más cercanos, se genera un nuevo ejemplo $x_{new} = x_i + \lambda(x_j - x_i), \lambda \in (0, 1)$.

No se encontró “Pasted image 20260303101123.png”.

Discretización

Transforma una variable continua en categórica definida por intervalos. Se define una partición del dominio observado $\leftarrow I_1 \; I_2 \; \ldots \; I_k, I_i \cdot I_j = \emptyset$ si $i \neq j$.

No se encontró “Pasted image 20260303101720.png”.