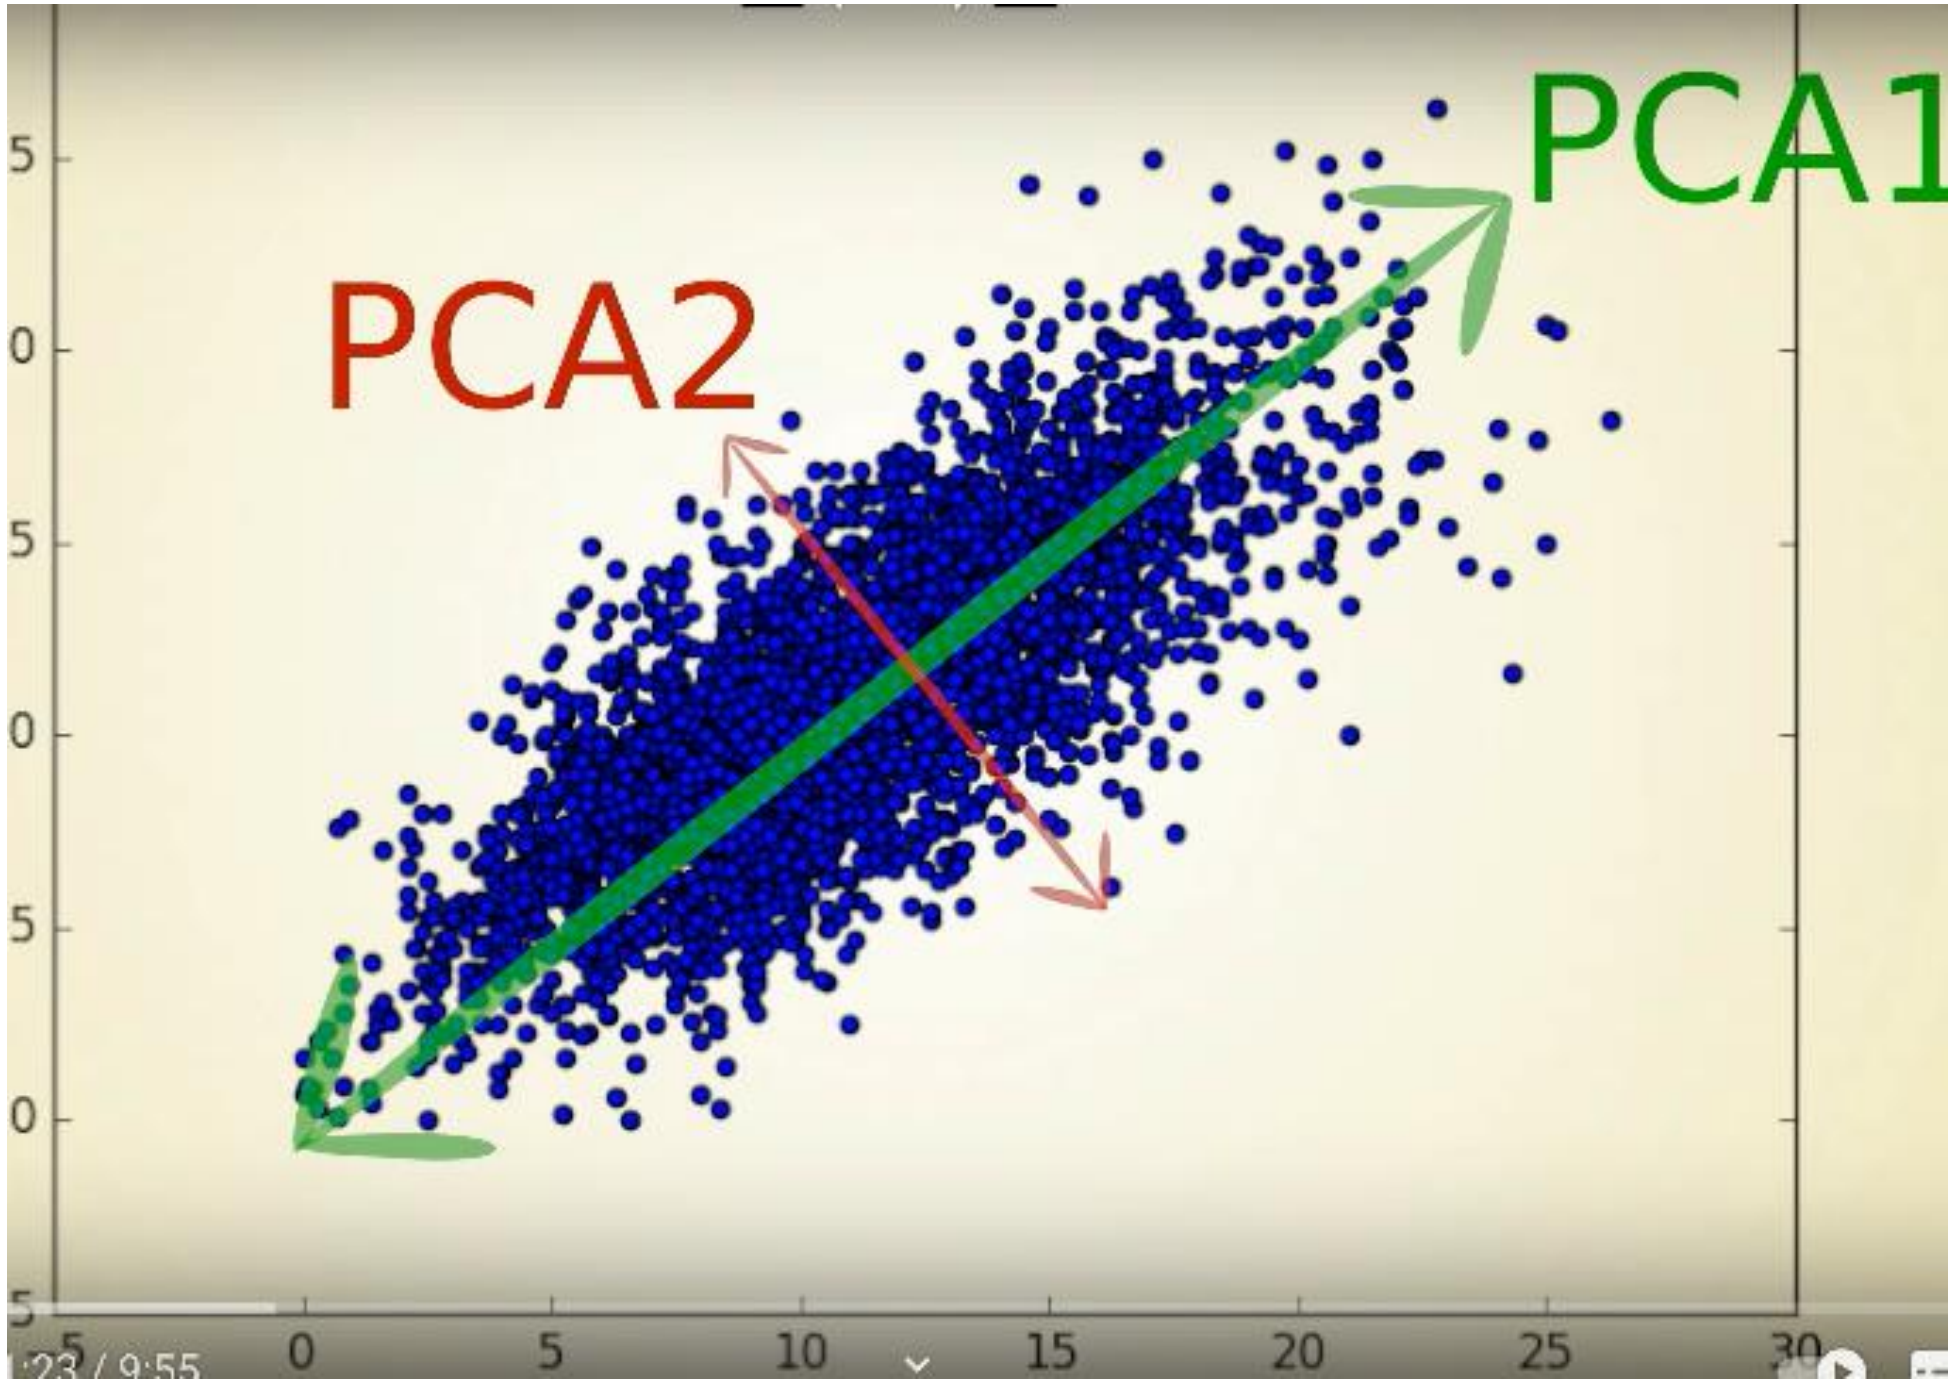
Análisis de Componentes Principales
Principal Component Analysis (PCA)

El **análisis de componentes principales** busca llevar los datos a un nuevo sistema de coordenadas de forma que los nuevos ejes apunten en las direcciones de máxima varianza. Las coordenadas de los datos según estos ejes se denominan componentes principales y se ordenan según la varianza que recogen.


PCA1
PCA2
5
0
5
0
5
0
5
5
0
5
10
15
20
25
30

El primer componente principal representaría la dirección de máxima varianza,

el segundo componente la dirección de máxima varianza ortogonal al anterior componente

y así sucesivamente hasta tener todos los componentes necesarios

Conceptos previos para el cálculo de PCA:

Valor y vector propio (autovalor, autovector)

- Dada A una matriz $m \times m$, $\vec{v}$ un vector de dimensión m, no nulo es una **vector propio** o **autovector** si existe un número real $\lambda \in \mathbb{R}$, tal que $\vec{v}\mathrm{A} = \vec{v}\lambda$.

- $\lambda \in \mathbb{R}$ recibe el nombre de **valor propio** o **autovalor** asociado al vector $\vec{v}$

Dado que $\vec{v}\mathrm{A} = \vec{v}\lambda$ entonces $\vec{v}(\mathrm{A} - \lambda\mathrm{I})$ con lo cual $|\mathrm{A} - \lambda\,\mathrm{I}| = 0$, entonces los ceros de este polinomio son los valores propios de la matriz A.

$\lambda \rightarrow$ autovalor

Ejemplo:

Sea la matriz $A = \begin{pmatrix} 3 & 2 \\ 1 & 4 \end{pmatrix}$

$$(A - \lambda I) = \begin{pmatrix} 3 & 2 \\ 1 & 4 \end{pmatrix} - \lambda \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 3-\lambda & 2 \\ 1 & 4-\lambda \end{pmatrix}$$

$$|A - \lambda I| = (3-\lambda)(4-\lambda) - 2 = 0$$

$$\lambda^2 - 7\lambda + 10 = 0$$

- $\lambda_1 = 2, \lambda_2 = 5$ son los **autovalores** de la matriz dada

Para $\lambda = 2$ resolvemos el sistema de ecuaciones

$$(\mathrm{A} - 2\,I)\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 2 \\ 1 & 2 \end{pmatrix}\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{matrix} x + 2y = 0 \\ x + 2y = 0 \end{matrix} \rightarrow x = -2y$$

La solución de un sistema homogéneo es siempre un subespacio. Los subespacios de autovectores se denominan *autoespacios*.

Buscamos una base de este subespacio: $S = gen\left\{\begin{pmatrix} 2 \\ -1 \end{pmatrix}\right.$

- Éste es el subespacio donde están los autovectores asociados al autovalor 2

Para $\lambda = 5$ resolvemos el sistema de ecuaciones

$$(\mathrm{A} - 5\,I)\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} -2 & 2 \\ 1 & -1 \end{pmatrix}\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{matrix} -2x + 2y = 0 \\ x - y = 0 \end{matrix} \rightarrow x = y$$

Buscamos una base de este subespacio: $S = gen\left\{\begin{pmatrix} 1 \\ 1 \end{pmatrix}\right.$

- Éste es el subespacio donde están los autovectores asociados al autovalor 5

Cálculo de componentes principales

Dada una muestra con n individuos cada uno con p variables

Imp

$$X_1, X_2, \cdots X_p,$$

es decir, el espacio muestral tiene p dimensiones.

$$X_i \rightarrow X_{i1}, X_{i2}, \cdots X_{ip}, \qquad i = 1, \ldots, n$$

Las variables se consideran estandarizadas, es decir

$$\frac{X_{ij} - \bar{X}}{sd(X_{ij})}$$



para evitar que las variables cuya escala sea mayor dominen al resto.

Cálculo de las m componentes principales*

$$Y_j = \alpha_{1j}X_1 + \alpha_{2j}X_2 + \cdots + \alpha_{pj}X_p, \qquad j = 1,2,\cdots,m$$

con $\vec{\alpha}_j^t \vec{\alpha}_j = 1$ Se calcula

Donde $\alpha_{1j}, \alpha_{2j}, \ldots, \alpha_{pj}$ son los pesos que tiene cada una de las p variables en el componente j .

*Cada una de estas nuevas m variables $(m < p)$ que explican aproximadamente lo mismo que las p variables originales

Primer componente principal

Maximizar

$$Var(Y_1) = Var\left(\vec{\alpha}_1^t \vec{X}\right) = \vec{\alpha}_1^t \Sigma \vec{\alpha}_1$$

respecto a las variables $\alpha_{11}, \alpha_{21}, \ldots, \alpha_{p1}$

sujeto a $\sum_{i=1}^{p} \alpha_{i1}^2 = 1$

donde Σ es la matriz de covarianza de $\vec{X}$

Max $\vec{\alpha}_1^t \Sigma \vec{\alpha}_1$

s.a.

$\vec{\alpha}_1^t \vec{\alpha}_1 = 1$

Aplicamos el método de los multiplicadores de Lagrange:

Maximizar

$$F(\vec{\alpha}_1^t, \lambda) = \vec{\alpha}_1^t \Sigma \vec{\alpha}_1 - \lambda(\vec{\alpha}_1^t \vec{\alpha}_1 - 1)$$

Si $F(\vec{\alpha}_1^t,\lambda) = \vec{\alpha}_1^t \Sigma \vec{\alpha}_1 - \lambda(\vec{\alpha}_1^t \vec{\alpha}_1 - 1)$

Derivamos F respecto a $\alpha_{11}, \alpha_{21}, \ldots, \alpha_{p1}$ y simplificamos e igualamos a cero

$$(\Sigma - \lambda I)\vec{\alpha}_1 = 0$$

Para que el sistema de ecuaciones anterior tenga solución distinta de cero la matriz $(\Sigma - \lambda I)$ debe ser singular, es decir, $|\Sigma - \lambda I| = 0$

Si $|\Sigma - \lambda I| = 0,$

λ es un valor propio de Σ con vector propio asociado $\vec{\alpha}_1$

y

$$Var(Y_1) = Var(\vec{\alpha}_1^t X) = \vec{\alpha}_1^t \Sigma \vec{\alpha}_1 = \vec{\alpha}_1^t \lambda \vec{v}_1 = \lambda \vec{\alpha}_1^t \vec{\alpha}_1 = \lambda$$

Luego para maximizar la varianza de Y_1 se tiene que tomar el mayor autovalor, λ_1

Sea λ_1, y el correspondiente autovector $\vec{\alpha}_1$

Entonces $\vec{\alpha}_1$ es un vector que da la combinación de las variables originales que tienen mayor varianza

$$\vec{\alpha}_1{}^t = (\alpha_{11}, \alpha_{21}, \dots, \alpha_{p1})$$

$$Y_1 = \vec{\alpha}_1{}^t \vec{X} = \alpha_{11}X_1 + \alpha_{21}X_2 + \cdots + \alpha_{p1}X_p$$

Segundo componente principal

Se quiere que Y_2 esté incorrelado con el anterior componente Y_1, entonces

$Cov(Y_2,Y_1)=0$

$Cov(Y_2, Y_1) = Cov(\vec{\alpha}_2^t \vec{X}, \vec{\alpha}_1^t \vec{X}) =$

$$\vec{\alpha}_2^t E\left[\left(\vec{X}-\mu\right)\left(\vec{X}-\mu\right)^t\right]\vec{\alpha}_1^t = \vec{\alpha}_2^t \Sigma \vec{\alpha}_1 = 0$$

Como se tenía que $\Sigma\vec{\alpha}_1 = \lambda\vec{\alpha}_1$

$\vec{\alpha}_2^t\Sigma\vec{\alpha}_1 = \vec{\alpha}_2^t\lambda\vec{\alpha}_1 = \lambda\vec{\alpha}_2^t\vec{\alpha}_1 = 0 => \vec{\alpha}_2^t\vec{\alpha}_1 = 0,$

con lo cual si los vectores $\vec{\alpha}_1$ **y** $\vec{\alpha}_2$ **son ortogonales** entonces es equivalente a Cov(Y_2, Y_1) =0.

Cálculo del segundo componente:

Maximizar $\vec{\alpha}_2^t\Sigma\vec{\alpha}_2$

s.a.

$$\vec{\alpha}_2^t\vec{\alpha}_2 = 1$$

$$\vec{\alpha}_2^t\vec{\alpha}_1 = 0$$

Aplicamos el método de los multiplicadores de Lagrange

$$F(\vec{\alpha}_2, \lambda, \Lambda) = \vec{\alpha}_2^t \Sigma \vec{\alpha}_2 - \lambda(\vec{\alpha}_2^t \vec{\alpha}_2 - 1) - \Lambda(\vec{\alpha}_2^t \vec{\alpha}_1) \Rightarrow$$

$$\frac{\delta F}{\delta \vec{\alpha}_2} = 2\,\Sigma \vec{\alpha}_2 - 2\,\lambda \vec{\alpha}_2 - \Lambda \vec{\alpha}_1 = 0$$

Multiplicamos por $\vec{\alpha}_1$

$$2\vec{\alpha}_1^t \Sigma \vec{\alpha}_2 - 2\lambda \vec{\alpha}_1^t \vec{\alpha}_2 - \Lambda \vec{\alpha}_1^t \vec{\alpha}_1 = 2\vec{\alpha}_1^t \Sigma \vec{\alpha}_2 - \Lambda = 0$$

$\vec{\alpha}_1^t \vec{\alpha}_2 = 0$ y $\vec{\alpha}_1^t \vec{\alpha}_1 = 1$

Entonces

$\Lambda=2\vec{\alpha}_1^t\Sigma\vec{\alpha}_2=0$

ya que $\text{Cov}(Y_1, Y_2) = \vec{\alpha}_2^t\Sigma\vec{\alpha}_1=0$

De este modo

$$\frac{\delta F}{\delta \boldsymbol{\alpha} 2} = 2\,\Sigma\vec{\alpha}_2 - 2\,\lambda\vec{\alpha}_2 = 2(\Sigma - \,\lambda\,\mathrm{I})\vec{\alpha}_2$$

Usando los mismos razonamientos que antes, elegimos toma λ como el segundo mayor autovalor de la matriz Σ con correspondiente autovector asociado $\overrightarrow{\alpha}_2$.

Lo anterior se puede extender, de modo que al j -ésimo componente le correspondería el j -ésimo autovalor.

Entonces todos los p componentes $\vec{Y}$ se pueden expresar como

$$\vec{Y}=\mathrm{A}\vec{X}$$

donde

$$\vec{Y}=\begin{pmatrix} Y_1 \\ \vdots \\ Y_m \end{pmatrix},\ \mathrm{A}=\begin{pmatrix} \alpha_{11} & \cdots & \alpha_{p1} \\ \vdots & \vdots & \vdots \\ \alpha_{1p} & \cdots & \alpha_{pm} \end{pmatrix},\vec{X}=\begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}$$

siendo $\mathrm{Var}(Y_1)= \lambda_1, \mathrm{Var}(Y_2) = \lambda_2, \dots, \mathrm{Var}(Y_m) = \lambda_m$

la matriz de covarianza es

$$C=\begin{pmatrix} \lambda_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \lambda_m \end{pmatrix}$$

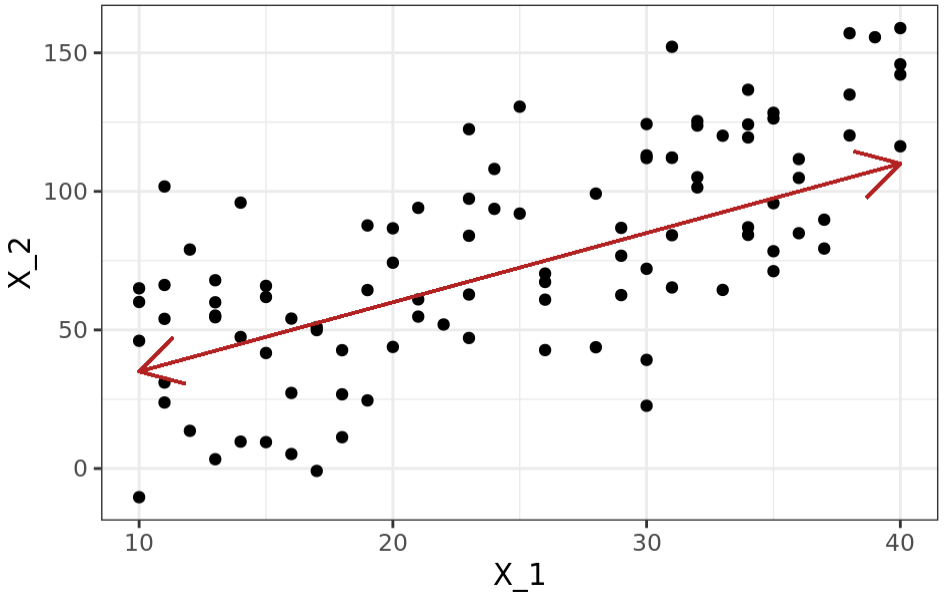
porque $Y_1, Y_2,\ldots, Y_m$ se han construido incorreladas.

- Se tiene que $\mathrm{Var}(\vec{Y})=A^t\mathrm{Var}(\vec{X})A= A^t\Sigma A$ o bien $\Sigma= A\ \mathrm{Var}(\vec{Y})\ A^t$

Ya que A es una matriz ortogonal

$(\vec{\alpha}_i^t\ \vec{\alpha}_i = 1$ para todas las columnas$)$ por lo que $AA^t=I$

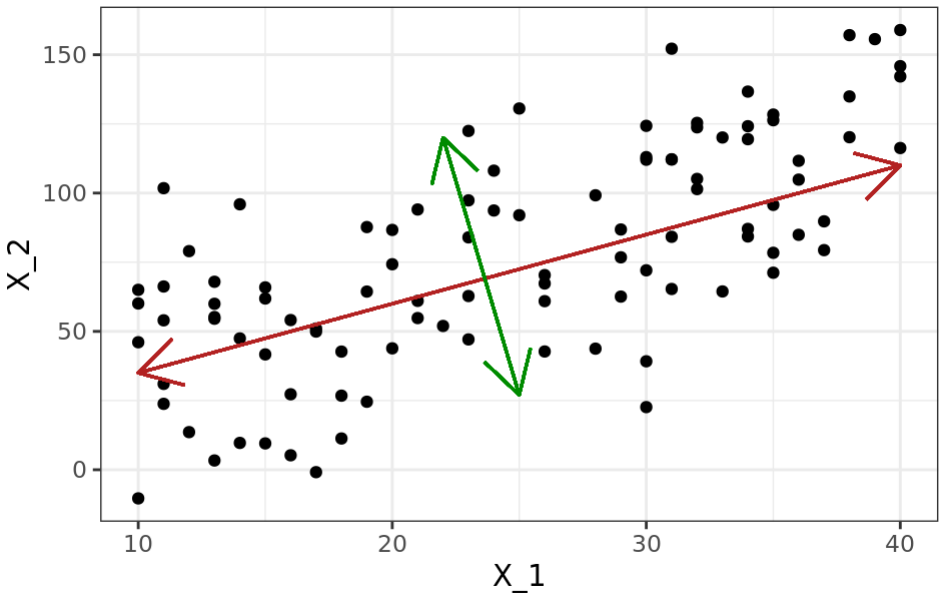
Interpretación Geométrica de las componentes principales



El vector que define la primera componente principal sigue la dirección en la que las observaciones varían más (línea roja)

La proyección de cada observación sobre esa dirección equivale al valor de la primera componente para dicha observación

Interpretación Geométrica de las componentes principales



La segunda componente sigue la segunda dirección en la que los datos muestran mayor varianza y que no está correlacionada con la primera componente

La condición de no correlación entre componentes principales equivale a decir que sus direcciones son perpendiculares/ortogonales.

Número óptimo de componentes principales

- **varianza explicada por la componente r**

$$\frac{1}{n}\sum_{i=1}^{n} Y_{ir}^2 = \frac{1}{n}\sum_{i=1}^{n}\left(\sum_{j=1}^{p} \alpha_{jr} X_{ij}\right)^2$$

- **proporción de varianza explicada por la componente r**

$$\frac{\sum_{i=1}^{n}\left(\sum_{j=1}^{p} \alpha_{jr} X_{ij}\right)^2}{\sum_{j=1}^{p}\sum_{i=1}^{n} X_{ij}^2}$$

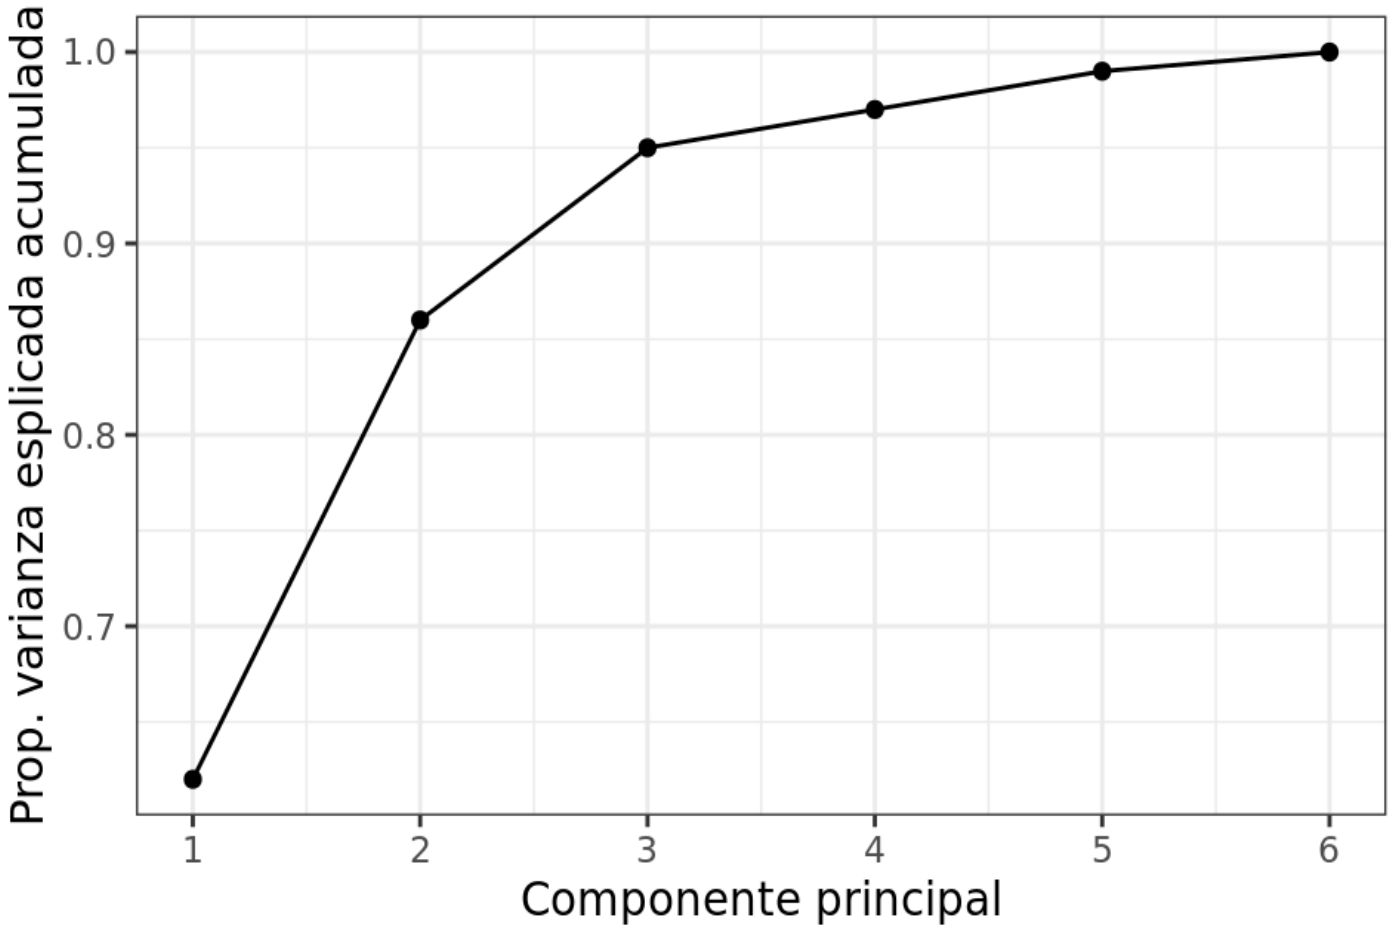
Número óptimo de componentes principales

- ✓ Dada una matriz de datos de dimensiones $n \times p$, el número de componentes principales que se pueden calcular es

$$\min(\, n - 1 \;\; , p)$$

- ✓ Es interesante utilizar el número mínimo de componentes que resultan suficientes para explicar los datos

Se evalúa la proporción de varianza explicada acumulada y seleccionar el número de componentes mínimo a partir del cual el incremento deja de ser sustancial.



Ejemplo1

- Sean los datos

X1=(2.5, 0.5, 2.2, 1.9, 3.1, 2.3, 2, 1, 1.5, 1.1),

X2=(2.4, 0.7, 2.9, 2.2, 3.0, 2.7, 1.6, 1.1, 1.6, 0.9)

n=10, p=2

- Los datos estandarizados son

X1=(0.69, -1.31,0.39,0.09,1.29,0.49,0.19,-0.81,-0.31,-0.71)

X2=(0.49,-1.21,0.99,0.29,1.09,0.79,-0.31,-0.81,-0.31,-1,01)

La matriz de covarianzas entre cada para de variables

	X1	X2
X1	0.6165556	0.6154444
X2	0.6154444	0.7165556

Autovalores: $\lambda_1 = 1.2840277$ $\lambda_2 = 0.0490834$

Autvectores: $\vec{\alpha}_1 = (0.6778734,\ 0.7351787)^t$

$\vec{\alpha}_2 = (-0.7351787,\ 0.6778734)^t$

Multiplicamos por los vectores de datos estandarizados y obtenemos

```
             PC1         PC2
##  [1,]  0.82797019 -0.17511531
##  [2,] -1.77758033  0.14285723
##  [3,]  0.99219749  0.38437499
##  [4,]  0.27421042  0.13041721
##  [5,]  1.67580142 -0.20949846
##  [6,]  0.91294910  0.17528244
##  [7,] -0.09910944 -0.34982470
##  [8,] -1.14457216  0.04641726
##  [9,] -0.43804614  0.01776463
## [10,] -1.22382056 -0.16267529
```

En este ejemplo, al partir inicialmente de un espacio muestral con 2 dimensiones y haber calculado sus 2 componentes principales

Ejemplo2: porcentaje de asaltos (Assault), asesinatos (Murder) y secuestros (Rape) por cada 100,000 habitantes para cada uno de los 50 estados de USA (1973). Además, también incluye el porcentaje de la población de cada estado que vive en zonas rurales (UrbanPoP).

	Murder <dbl>	Assault <int>	UrbanPop <int>	Rape <dbl>
Alabama	13.2	236	58	21.2
Alaska	10.0	263	48	44.5
Arizona	8.1	294	80	31.0
Arkansas	8.8	190	50	19.5
California	9.0	276	91	40.6
Colorado	7.9	204	78	38.7

Promedio	Murder	Assault	UrbanPop	Rape
	7.788	170.760	65.540	21.232

El promedio de los datos muestra que hay tres veces más secuestros que asesinatos y 8 veces más asaltos que secuestros.

Varianza	Murder	Assault	UrbanPop	Rape
	18.97047	6945.16571	209.51878	87.72916

Se estandarizan las variables para que la variable `Assault` no domine la mayoría de las componentes

- El número máximo de componentes principales es el mínimo(*n*-1,*p*), que en este caso es *min*(49,4)=4.

Calculado en R

```
##                PC1        PC2        PC3         PC4
## Murder   -0.5358995  0.4181809 -0.3412327  0.64922780
## Assault  -0.5831836  0.1879856 -0.2681484 -0.74340748
## UrbanPop -0.2781909 -0.8728062 -0.3780158  0.13387773
## Rape     -0.5434321 -0.1673186  0.8177779  0.08902432
```

Entonces

PC1 = −0.5358995 *Murder* −0.5831836 *Assault* −0.2781909 *UrbanPop*−0.5434321 *Rape*

PC2 = 0.4181809 *Murder* +0.1879856 *Assault* -0.8728062 *UrbanPop* −0.1879856 *Rape*

PC3= −0.3412327 *Murder* −0.2681484 *Assault* −0.3780158 *UrbanPop* +0.13387773 *Rape*

PC4= 0.64922780 *Murder* −0.74340748 *Assault* +0.13387773 *UrbanPop* +0.08902432 *Rape*

**Intepretación de los pesos (loadings)*

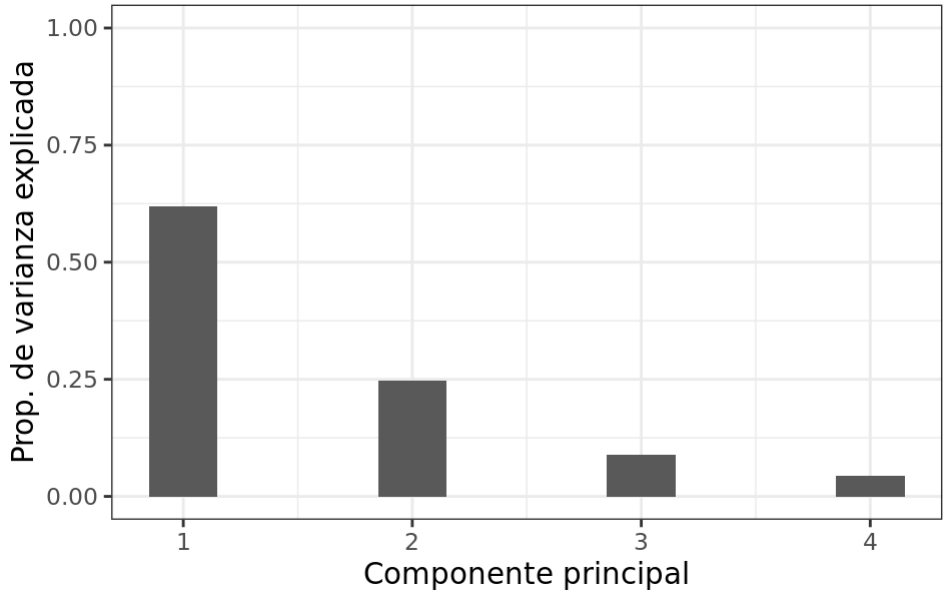
Cálculo del valor de las componentes principales para cada observación

Multiplicamos los datos por los vectores de *pesos* $\vec{\alpha}_j$

```
##                PC1        PC2         PC3          PC4
## Alabama    -0.9756604  1.1220012 -0.43980366  0.154696581
## Alaska     -1.9305379  1.0624269  2.01950027 -0.434175454
## Arizona    -1.7454429 -0.7384595  0.05423025 -0.826264240
## Arkansas    0.1399989  1.1085423  0.11342217 -0.180973554
## California -2.4986128 -1.5274267  0.59254100 -0.338559240
## Colorado   -1.4993407 -0.9776297  1.08400162  0.001450164
```

- Varianza explicada de cada componente

```
2.4802416 0.9897652 0.3565632 0.1734301
```

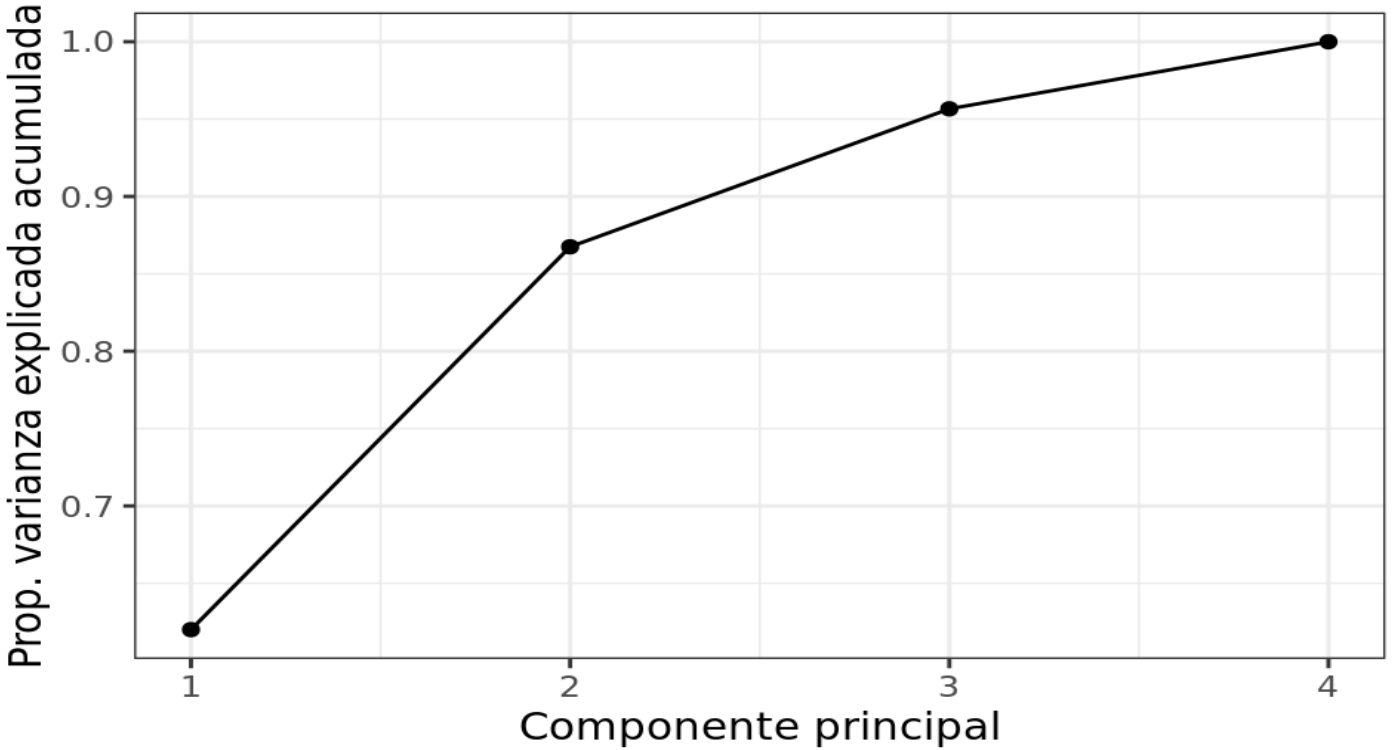


- Proporción de varianza de cada componente respecto al total

```
0.62006039 0.24744129 0.08914080 0.04335752
```

- Proporción de varianza de cada componente respecto al total

0.62006039 0.24744129 0.08914080 0.04335752



- Proporción de varianza acumulada

0.6200604 0.8675017 0.9566425 1.0000000

*Interpretar los resultados