Reducción de la dimensionalidad

La complejidad del proceso de aprendizaje depende de:

- el volumen de muestras de aprendizaje
- la dimensionalidad del espacio de representación

Técnicas para la reducción de los costes relativos al volumen de muestras

- **Muestreo Aleatorio**

Consiste en seleccionar un subconjunto de datos de manera aleatoria del conjunto original

- **Muestreo Estratificado**

Se trata de dividir el conjunto de datos en estratos (grupos homogéneos) y luego realizar un muestreo aleatorio dentro de cada estrato.

Técnicas para la reducción de los costes relativos al volumen de muestras

- **Filtrado de Datos**.

Elimina instancias redundantes o poco informativas.

Eliminación de duplicados (elimina filas repetidas)

Filtrado por relevancia (usa métricas para seleccionar datos útiles)

- **Técnicas de Resumen Estadístico**

Resume los datos usando estadísticas (medias, medianas, etc.) en lugar de mantener todas las instancias

Técnicas para la reducción de los costes relativos al volumen de muestras

- **Generación de Prototipos**

Crea prototipos sintéticos que representen grupos de datos.

K-Medoides: selecciona instancias reales como prototipos

Generación de datos sintéticos que usa algoritmos como SMOTE (Synthetic Minority Over-sampling Technique) para crear nuevos datos

Reducción de la dimensionalidad

Dada una muestra con n individuos cada uno con p variables

$$\vec{X}_1, \vec{X}_2, \cdots \vec{X}_n \text{ tales que}$$

$$\vec{X}_i = (X_{i1}, X_{i2}, \cdots, X_{ip})^t \qquad i = 1, \ldots, n$$

para cada muestra i se determina una selección o transformación de atributos

$$X_{ij} \Rightarrow Y_{ik}, j = 1, \cdots, p, k = 1, \cdots, l \quad l < p$$

tal que transforma los datos originales $\vec{X} \in \mathbb{R}^p$ en los de salida $\vec{Y} \in \mathbb{R}^l$ de menor dimensionalidad $l < p$.

Ejemplo:

Un estudio médico recopila información de pacientes para predecir el riesgo de enfermedad cardiovascular

Paciente	Edad (años)	Presión Sistólica (mmHg)	Colesterol (mg/dL)	IMC (Índice de Masa Corporal)	Resultado (Enfermedad: 1 = Sí, 0 = No)
1	55	140	250	28	1
2	60	150	260	30	1
3	45	130	180	25	0
4	70	160	300	32	1
5	40	120	170	24	0

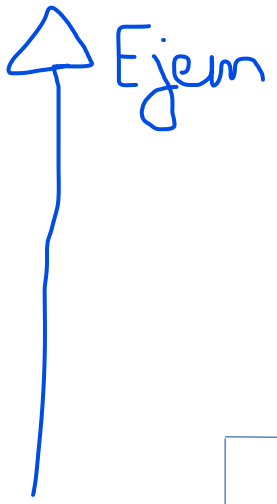
$\vec{X}_1 = (55,140,250,28,1),\ \vec{X}_2 = (60,150,260,30,1), \vec{X}_3 = (45,130,180,25,0),$
$\vec{X}_4 = (70,160,300,32,1), \vec{X}_5 = (40,120,170,24,0)$

Se analiza la relación de cada variable con el resultado (presencia de enfermedad).

- **Edad** y **Colesterol** tienen una correlación fuerte y son factores de riesgo bien conocidos.
- **Presión sistólica** e **IMC** aportan información, pero en este conjunto pueden mostrar una correlación menor con el resultado.

Paciente	Edad (años)	Colesterol (mg/dL)	Resultado
1	55	250	1
2	60	260	1
3	45	180	0
4	70	300	1
5	40	170	0

$$\vec{Y}_1 = (55,250,1),\ \vec{Y}_2 = (60,260,1),\ \vec{Y}_3 = (45,180,0),$$
$$\vec{Y}_4 = (70,300,1),\ \vec{Y}_5 = (40,170,0)$$



Técnicas de Reducción de la Dimensionalidad

- **Selección de Características**
- **Transformación de Características**
  - **Lineales**
  - **No Lineales**

Técnicas de Selección de Características

los datos resultantes forman un subconjunto del original

- **Métodos de Filtrado (Filter Methods):**

evalúan las características sin considerar el modelo de machine learning

Coeficiente de correlación de Pearson

Correlación de Spearman, Chi-cuadrado (χ^2)

ANOVA (Analysis of Variance)

Técnicas de Selección de Características

- **Métodos de Envoltura (Wrapper Methods):**

evalúan subconjuntos de características utilizando un modelo de machine learning específico.

Selección hacia adelante (Forward Selection)

Eliminación hacia atrás (Backward Elimination)

Búsqueda exhaustiva (Exhaustive Search)

Algoritmos genéticos

Técnicas de Selección de Características

- **Métodos Integrados (Embedded Methods):**

la selección de características es parte del proceso de entrenamiento del modelo.

Regularización L1 (Lasso)

Árboles de decisión y ensemble

Máquinas de Soporte Vectorial (SVM) con kernels lineales

Técnicas de Transformación de Características[1]

se genera una transformación de los datos

- **Técnicas Lineales:**

asumen que los datos pueden ser representados en un espacio de menor dimensión mediante transformaciones lineales

Análisis de Componentes Principales(PCA), ,Análisis Discriminante Lineal(LDA), Factorización de Matrices no negativas (NMF)

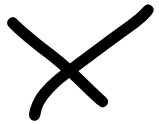
Técnicas de Transformación de Características [1] [2]

se genera una transformación de los datos

- **Técnicas no Lineales:**

útiles cuando los datos tienen una estructura no lineal

t-SNE (t-Distributed Stochastic Neighbour Embedding), UMAP (Uniform Manifold Approximation and Projection), Autoencoders



	Selección de Características	Transformación de Características
Definición	Elimina características irrelevantes o redundantes	Crea nuevas características a partir de las existentes
Impacto en los datos	Se mantienen sin modificaciones	Se modifican o combinan en nuevas variables
Interpretabilidad	Alta (las variables originales se conservan)	Baja (las nuevas variables pueden ser difíciles de interpretar)
Reducción de Dimensionalidad	Sí, al eliminar características	Sí, al representar la información con menos dimensiones

Ejemplo:

un conjunto de datos sobre vehículos testados por el Agencia de Certificación Americana para el Medio Ambiente.

Dataset Original

	year	desplazamiento	cilindros	consumo	co2	consumo_std	desplazamiento_std
0	1984	2.5	4.0	17	522.764706	-0.653195	-0.613385
1	1984	4.2	6.0	13	683.615385	-1.565710	0.676220
2	1985	2.5	4.0	16	555.437500	-0.881324	-0.613385
3	1985	4.2	6.0	13	683.615385	-1.565710	0.676220
4	1987	3.8	6.0	16	555.437500	-0.881324	0.372783

Selección de características

	desplazamiento	consumo
0	2.5	17
1	4.2	13
2	2.5	16
3	4.2	13
4	3.8	16

Transformación de características (PCA)

	x_reducida1	x_reducida2
0	52.484943	-16.098286
1	213.368898	-13.229260
2	85.144136	-14.550961
3	213.351066	-12.231043
4	85.153617	-12.406759

el conjunto de datos original (de 7 dimensiones) es representado en 2 dimensiones

Ventajas de la reducción de la dimensionalidad

- Facilita la visualización y la interpretación

Ejemplo: Conjunto de datos Iris con 50 muestras sobre tres especies de la flor **Iris**: **Iris setosa**, **Iris versicolor**, **Iris virginica** y cada muestra tiene **cuatro características** (todas en centímetros): **Largo del sépalo**, **Ancho del sépalo**, **Largo del pétalo**, **Ancho del pétalo**.



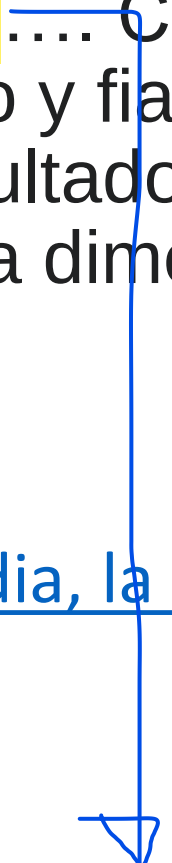
Ventajas de la reducción de la dimensionalidad

- Reducen la cantidad de recursos necesarios para entrenar, almacenar o utilizar el clasificador
- Elimina o reduce el número de atributos irrelevantes/redundantes para la tarea de clasificación.
- Evita la **maldición de la dimensionalidad**.

La maldición de la dimensionalidad

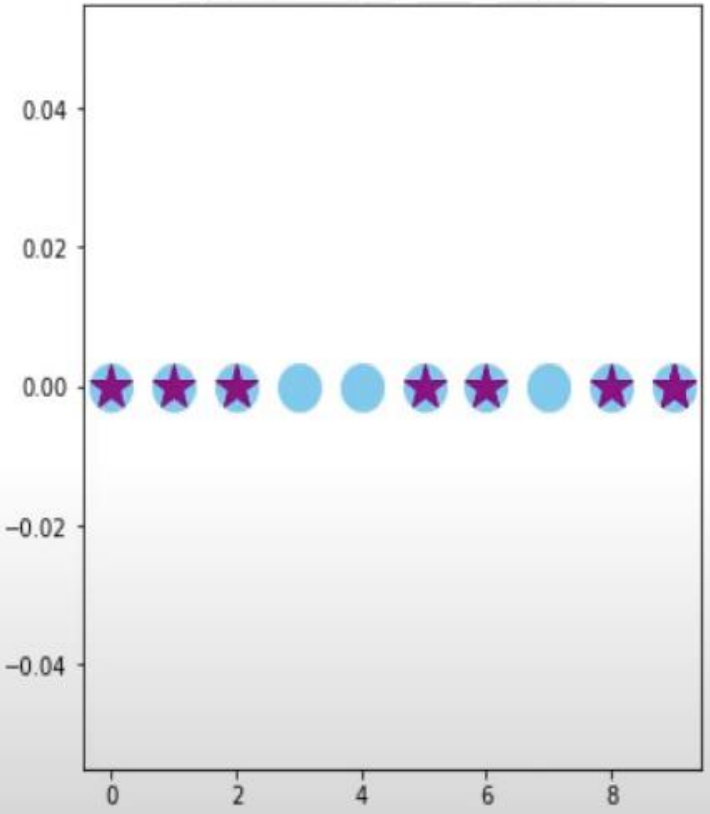
…. cuando aumenta la dimensionalidad, el volumen del espacio aumenta exponencialmente haciendo que los datos disponibles se vuelven dispersos…. Con el fin de obtener un resultado estadísticamente sólido y fiable, la cantidad de datos necesarios para mantener el resultado a menudo debe crecer también exponencialmente con la dimensionalidad.

Maldición de la dimensión - Wikipedia, la enciclopedia libre

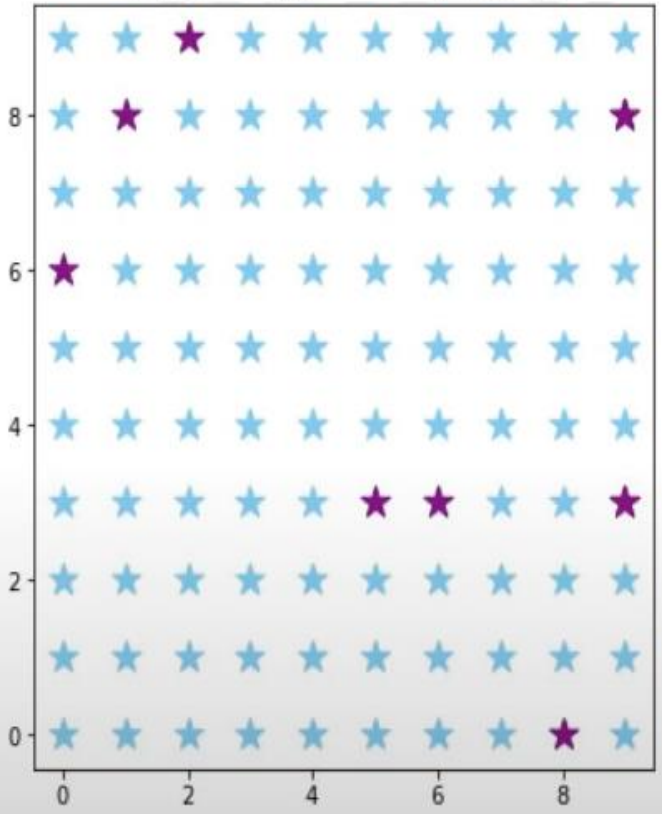


Ejemplo: una dimensión es una variable con valores desde 0 hasta 9 (10 valores), dos dimensiones son dos variables y tres dimensiones son 3 variables

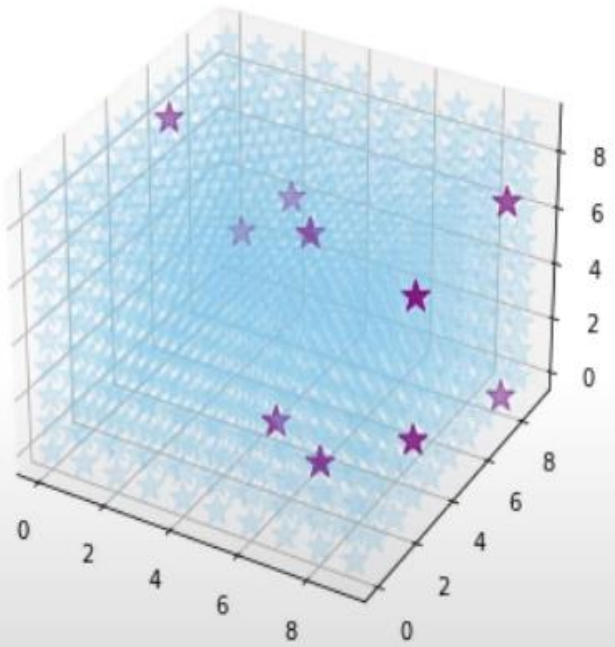
10^1 = 10



10^2 = 100



10^3 = 1000



En datos de alta dimensión todos los objetos parecen ser escasos y diferentes en muchos aspectos, debido a esta escasez, resulta mucho más fácil encontrar una solución perfecta para el modelo de Machine Learning, lo que muy probablemente conduzca a un **sobreajuste**

Alta dimensión → Fácil para el modelo → Sobreajuste

¿Cuándo NO usar reducción de dimensionalidad?

⚠ Si las características ya son pocas y cada una aporta información relevante.

⚠ Si la interpretabilidad es clave y perder variables originales no es deseable.

⚠ Si los modelos que se usan no se ven afectados por muchas características (ej. árboles de decisión, random forests).