Agrupamiento

El **agrupamiento o clustering** es un método que se utiliza para identificar conjuntos que se denominan clústeres o grupos, de tal modo que las instancias dentro de un clúster son similares, y son diferentes con respecto a instancias de otros clústeres.

Tipos de clústeres según su estructura:

✓**Clústeres Jerárquicos**.

Poseen una estructura jerárquica entre grupos, lo cual implica que hay grupos dentro de otros grupos.

✓ **Clústeres Planos**.

No presentan ningún tipo de estructura dependiente: cada grupo identificado es completamente independiente de los demás.

Tipos de clústeres según el grado de pertenencia:

✓ **Clústeres Duros (Hard Clusters).**

cada una de las instancias pertenece a un solo clúster.

✓ **Clústeres Blandos (Fuzzy Clusters).**

cada instancia tienen un grado de pertenencia; es decir, cada instancia podrá pertenecer a más de un clúster.

Clústeres Duros (Hard Clusters).

El resultado de un algoritmo de agrupamiento/clustering duro se puede representar por una matriz $k \times n$

$$\begin{pmatrix} u_{11} & \cdots & u_{1n} \\ \vdots & \ddots & \vdots \\ u_{k1} & \cdots & u_{kn} \end{pmatrix}$$

donde k es el número de clusters y n es el número de instancias o ejemplos en el computo de datos y

$$u_{ij} \in \{0,1\}, 1 \leq j \leq k, 1 \leq i \leq n,$$

$$\sum_{j=1}^{k} u_{ji} = 1, 1 \leq i \leq n,$$

$$\sum_{i=1}^{n} u_{ji} > 0, 1 \leq j \leq k$$

Clústeres Blandos (Fuzzy Clusters).

El resultado de un algoritmo de agrupamiento/clustering duro se puede representar por una matriz $k \times n$

$$\begin{pmatrix} u_{11} & \cdots & u_{1n} \\ \vdots & \ddots & \vdots \\ u_{k1} & \cdots & u_{kn} \end{pmatrix}$$

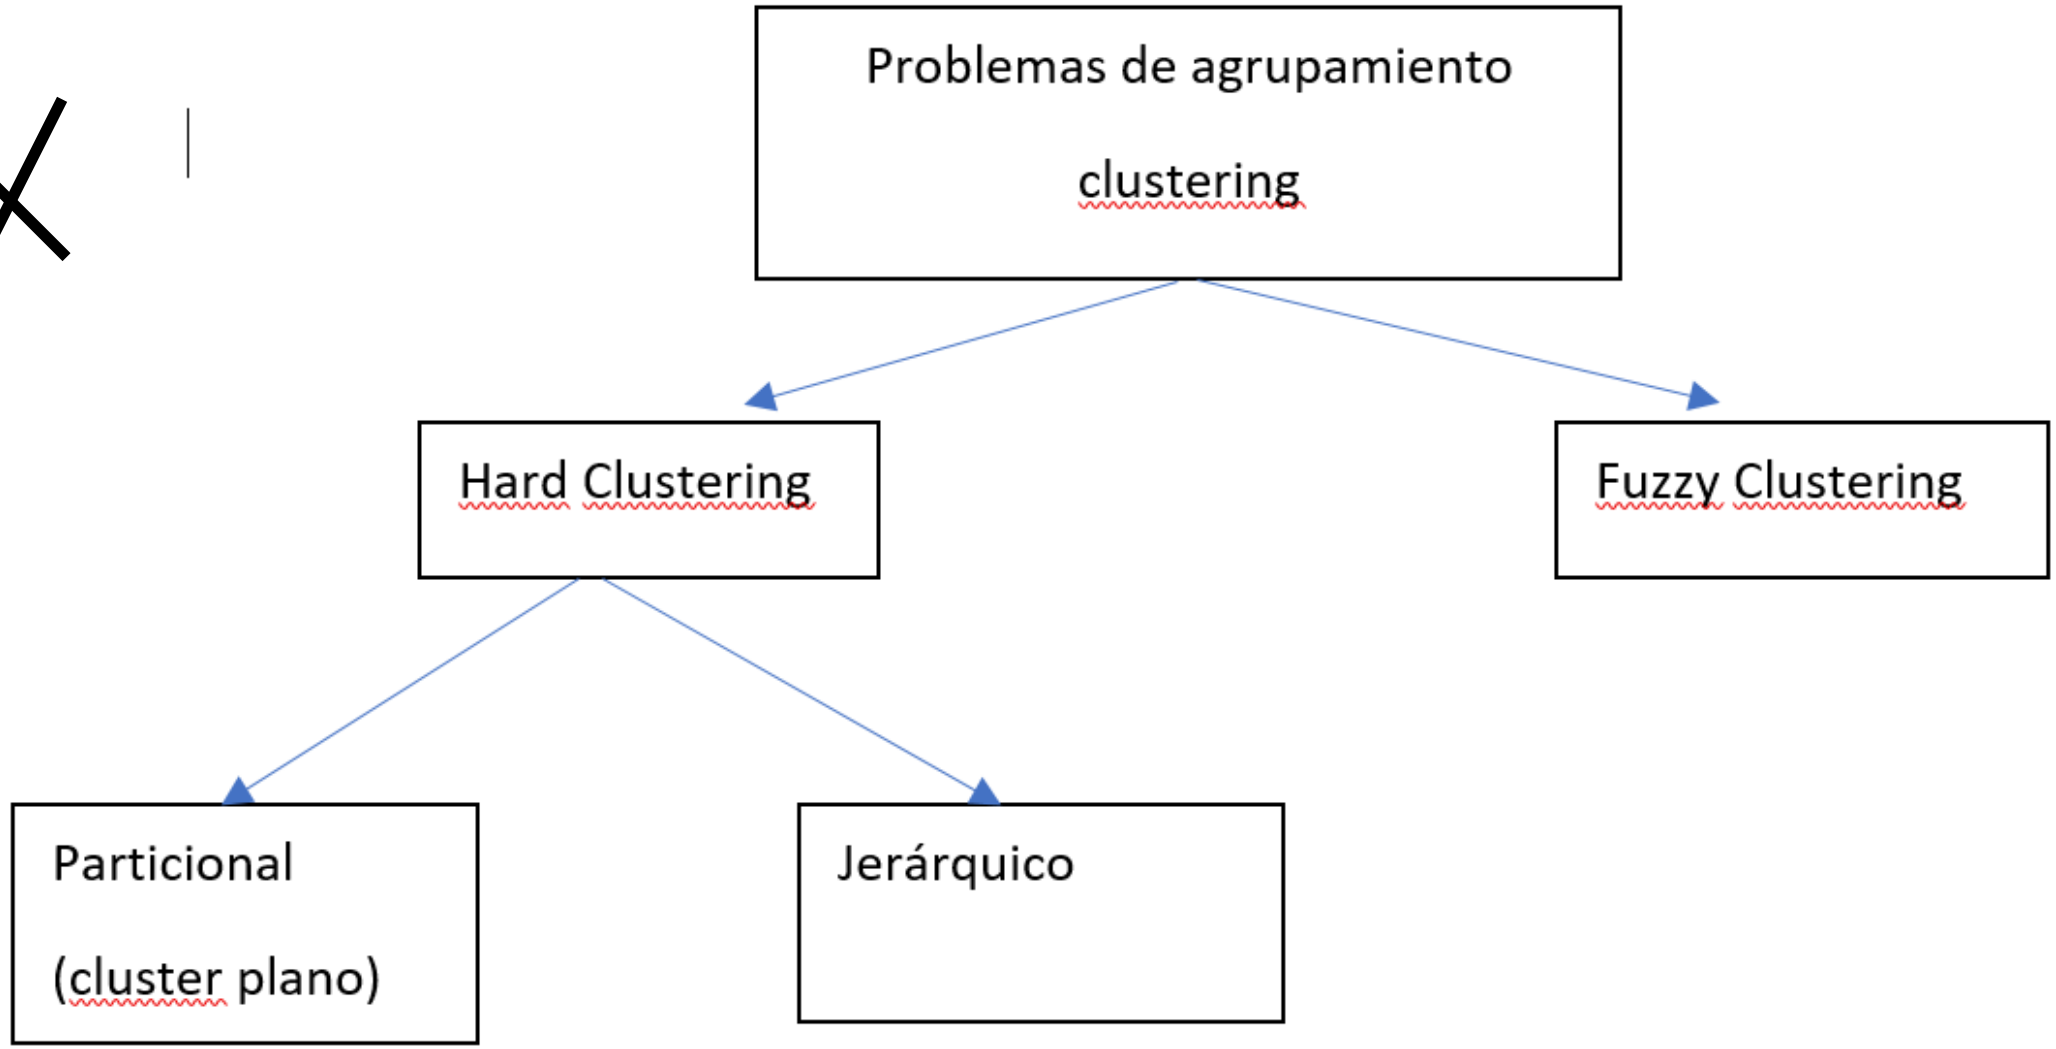
donde k es el número de clústeres y n es el número de instancias o ejemplos en el cómputo de datos y

$$u_{ij} \in [0,1], 1 \leq j \leq k, 1 \leq i \leq n,$$

$$\sum_{j=1}^{k} u_{ji} = 1, 1 \leq i \leq n,$$

$$\sum_{i=1}^{n} u_{ji} > 0, 1 \leq j \leq k$$

Clasificación de problemas de agrupamiento



Conceptos necesarios en agrupamiento:

Medidas de proximidad

Dado un conjunto de datos con n objetos, $C = \{\vec{x}_1, \vec{x}_2, \cdots, \vec{x}_n\}$ donde

- $\vec{x}_i = (x_{i1}, x_{i2}, \cdots x_{im})^t$ es un vector que denota el objeto i-ésimo objeto y x_{ij} es un escalar que denota la componente o atributo j de $\vec{x}_i$
- m es el número de atributos o características (dimensionalidad del conjunto de datos)

Una medida de proximidad estima lo cercanos o lejanos que están dos instancias $\vec{x}_i$ y $\vec{x}_j$, una con respecto a la otra

Tipos de medidas de proximidad

- **Medida de similitud u homogeneidad:**

$S: \mathbb{R}^m \times \mathbb{R}^m \to \mathbb{R}\,,\ S(\vec{x}_i, \vec{x}_j)$ determina cuan parecidas son las instancias

Ejemplos:

Similitud de cosenos

$$\cos(\vec{x}_i, \vec{x}_j) = \frac{\vec{x}_i.\vec{x}_j}{\|\vec{x}_i\|.\|\vec{x}_j\|} = \frac{\sum_{k=1}^{m} x_{ik}x_{jk}}{\sqrt{\sum_{k=1}^{m} x_{ik}^2 \sum_{k=1}^{m} x_{jk}^2}}$$

Coeficiente de Jaccard

$$S(\vec{x}_i, \vec{x}_j) = \frac{\vec{x}_i.\vec{x}_j}{\|\vec{x}_i\|^2 + \|\vec{x}_j\|^2 - \vec{x}_i.\vec{x}_j} = \frac{\sum_{k=1}^{m} x_{ik}x_{jk}}{\sum_{k=1}^{m} x_{ik}^2 + \sum_{k=1}^{m} x_{jk}^2 - \sum_{k=1}^{m} x_{ik}x_{jk}}$$

Tipos de medidas de proximidad

- **Medida de distancia o disimilitud:**

$D: \mathbb{R}^m \times \mathbb{R}^m \rightarrow \mathbb{R}$,

$D(\vec{x}_i, \vec{x}_j)$ indica la distancia relativa existente entre ambas instancias

Ejemplo:

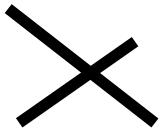
Distancia de Minkowski o Lp

$$D(\vec{x}_i, \vec{x}_j) = \left(\sum_{i=1}^{p} \left| \vec{x}_i - \vec{x}_j \right|^p \right)^{1/p}$$

distancia Euclídea o norma L2 cuando p = 2

distancia de Manhattan o norma L1 cuando p = 1

Los elementos de un clúster combinarán varios criterios:



- Compartir propiedades iguales o estrechamente relacionadas
- Mostrar pequeñas distancias o diferencias entre ellos
- Tener contactos o relaciones con al menos otro objeto del grupo
- Distinguirse claramente del complementario, es decir, del resto de los objetos en el conjunto de datos.

Retos asociados a las técnicas de agrupamiento:

- Determinación del verdadero número de clústeres en el conjunto de datos
- Capacidad de manejar un alto nivel de ruido que surgen al tratar con experimentos complejos
- Capacidad de manejar clústeres que se solapan
- Representación de las estructuras de los clústeres
- Los resultados de la agrupación pueden verse afectados por procedimientos de preprocesamiento (estandarización, manejo de valores que faltan, filtrado de patrones …)

  Es conveniente usar diferentes técnicas de clustering y comparar los resultados

  Es útil aplicar el algoritmo varias veces con distintas condiciones iniciales

Criterios de Evaluación de técnicas de agrupamiento:

- **Criterio de cohesión intragrupo**

El objetivo es obtener clústeres de tal modo que las instancias estén lo más cercanas posibles dentro de un mismo clúster

- **Criterio de separación intergrupal**

El objetivo es determinar clústeres de tal modo que sus centroides se encuentren lo más alejados unos de otros.

Ejemplo de agrupamiento

Segmentación de clientes en un supermercado

Una tienda desea segmentar a sus clientes según:

- **Edad**
- **Ingreso mensual**
- **Frecuencia de compra**

Se recolectan los datos y se aplica un algoritmo de agrupamiento.

La empresa **no sabe cuántos tipos de clientes existen realmente**

Ejemplo agrupamiento

El número de grupos determina la estructura final del modelo y afecta directamente la interpretación y las decisiones basadas en los datos.

K = 2 (clientes frecuentes vs. ocasionales)

K = 3 (alto, medio y bajo poder adquisitivo)

Se puede perder información intermedia

K = 5

El modelo crea subgrupos muy pequeños, puede estar sobreajustando (demasiada segmentación).