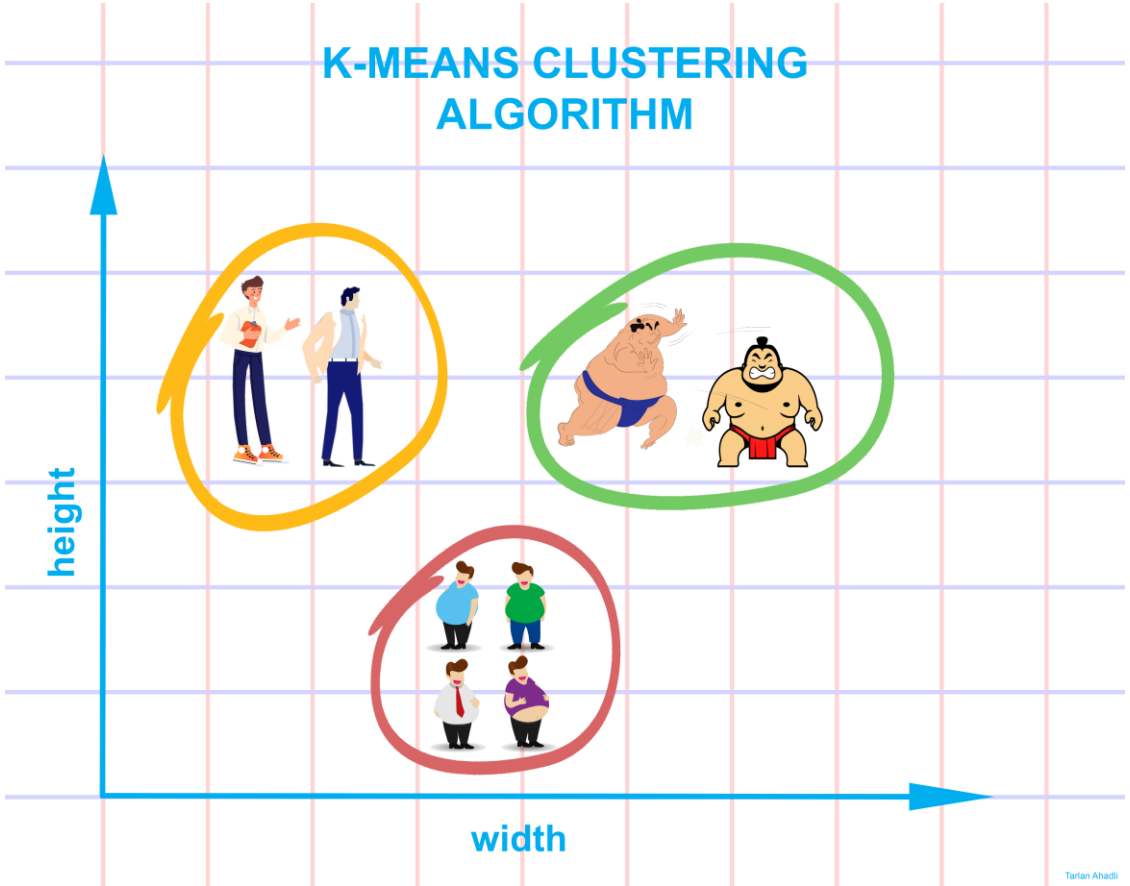
K-medias
(K-means)



K-medias (Notación)

- ✓ $c_i \in \mathbb{R}$: número del clúster al cual pertenece la instancia $\vec{x}_i \in \mathbb{R}^m$.

Toma valores entre 1 y K. Por ejemplo, si la instancia $\vec{x}_{10}$ pertenece al cluster 3, c_{10}= 3.

- ✓ $\vec{\mu}_k \in \mathbb{R}^m$: centroide del clúster k.

- ✓ $\vec{\mu}_{c_i} \in \mathbb{R}^m$: centroide del clúster al cual pertenece la instancia $\vec{x}_i$. Por ejemplo, si la instancia $\vec{x}_i$ pertenece al clúster 3, su centroide será $\vec{\mu}_{c_{10}}$=$\vec{\mu}_3$.

K-medias (Notación)

- ✓ El número de elementos N_k que contiene el clúster k-ésimo se determina como

$$N_k = \sum_{i=1}^{n} [\![c_i = k]\!]$$

donde se ha utilizado el corchete de Iverson.

- ✓ el **centroide** del clúster k-ésimo como

$$\vec{\mu}_k = \frac{1}{N_k} \sum_{i=1}^{n} \vec{x}_i \, [\![c_i = k]\!]$$

K-medias (Notación)

- ✓ Función de costo/función de distorsión

$$J(c_1, c_2, \dots c_n, \mu_1, \mu_2, \dots \mu_k) = \frac{1}{n}\sum_{i=1}^{n} \left\| \vec{x}_i - \vec{\mu}_{C_i} \right\|^2$$

K-medias

- k-medias es un algoritmo particional que genera K clústeres, siendo K un hiperparámetro.
- Cada instancia $\vec{x}_i$ pertenecerá al clúster cuyo centroide se encuentre más cercano a $\vec{x}_i$.
- el algoritmo de k-means trata de encontrar los centroides $\mu_1 \mu_2, \ldots, \mu_k$ tales que la función de costo sea lo mínima posible.

Algoritmo de las k-medias

Asumiendo K clases y un número total de n instancias

1. *Inicialización de los centroides*

- Seleccionar puntos aleatorios en el espacio $\mathbb{R}^m$.
- Escoger de forma aleatoria instancias $\vec{x}_i$ como centroides iniciales (solo si k < n).

2. *Asignación de clúster*

minimizar J con respecto a cada c_i manteniendo los centroides μ_i constantes con lo cual

$$c_i = \arg\min_k \|\vec{x}_i - \mu_i\|^2, \qquad k=1,\ldots,K$$

Algoritmo de las k-medias

3. Movimiento del centroide

minimizar J con respecto a cada centroide μ_i, manteniendo las asignaciones de instancias a clústeres constante

$$\vec{\mu}_k = \frac{1}{N_k}\Sigma_{i=1}^{n}\vec{x}_i[\![c_i = k]\!], \qquad \text{k=1,…,K}$$

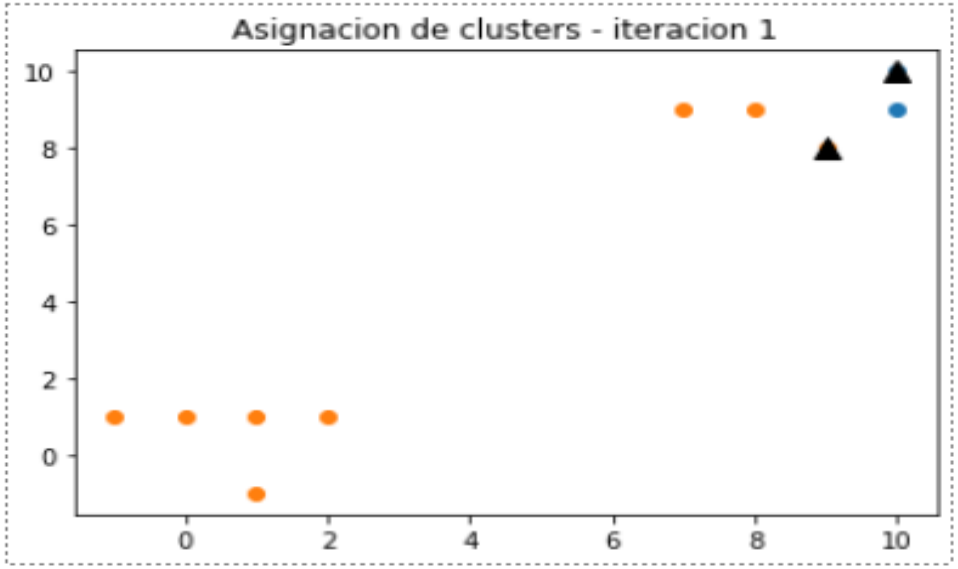
4. Criterio de Finalización

Se repite de manera consecutiva la etapa 2 y 3 hasta que se satisfaga algún criterio de finalización ->

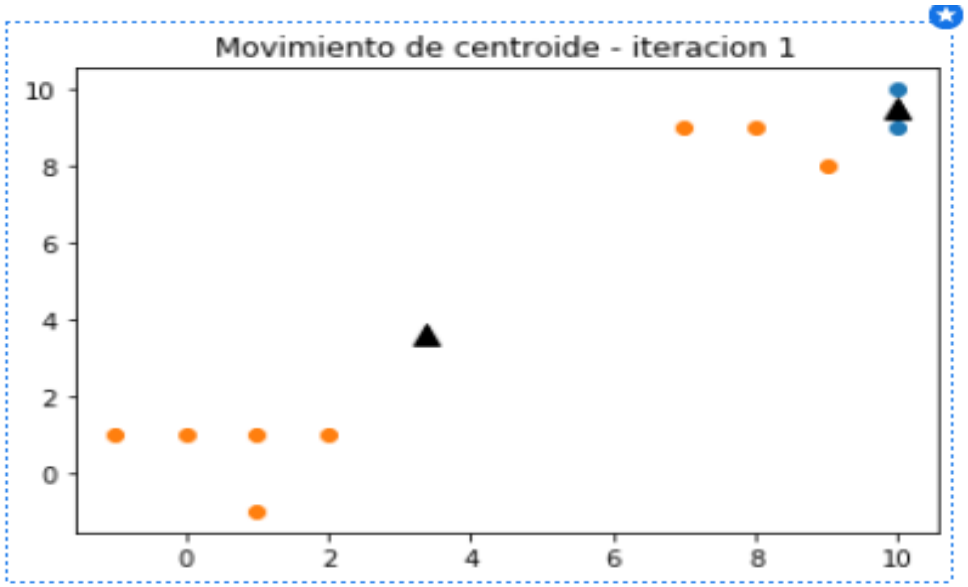
Criterios de finalización del algoritmo K-medias

- Cuando ya no existe reasignaciones de las instancias a clústeres diferentes, o estas reasignaciones son mínimas.
- Cuando ya no existe cambio en los centroides o el cambio es mínimo (entre iteraciones sucesivas).
- Cuando la función de costo J, presenta una disminución mínima entre iteraciones sucesivas.

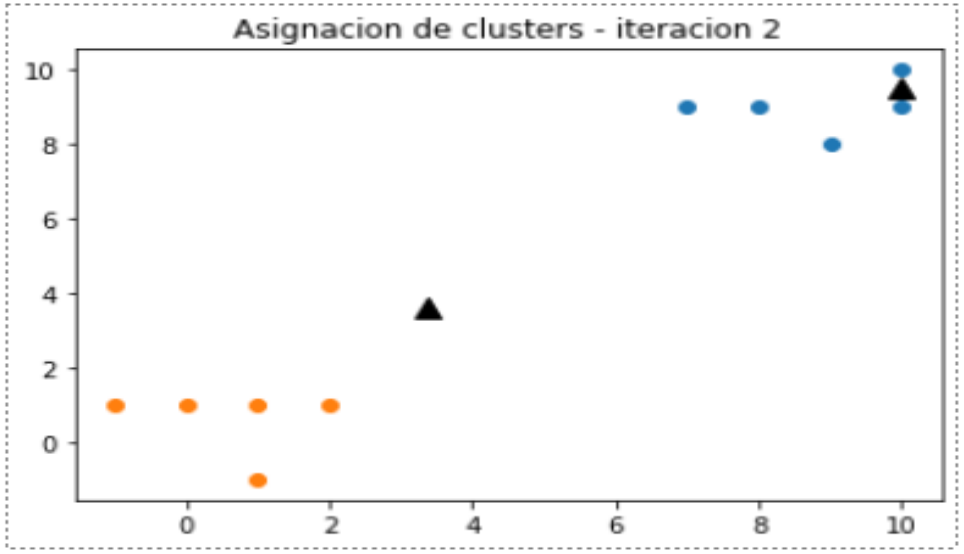
Ejemplo 1



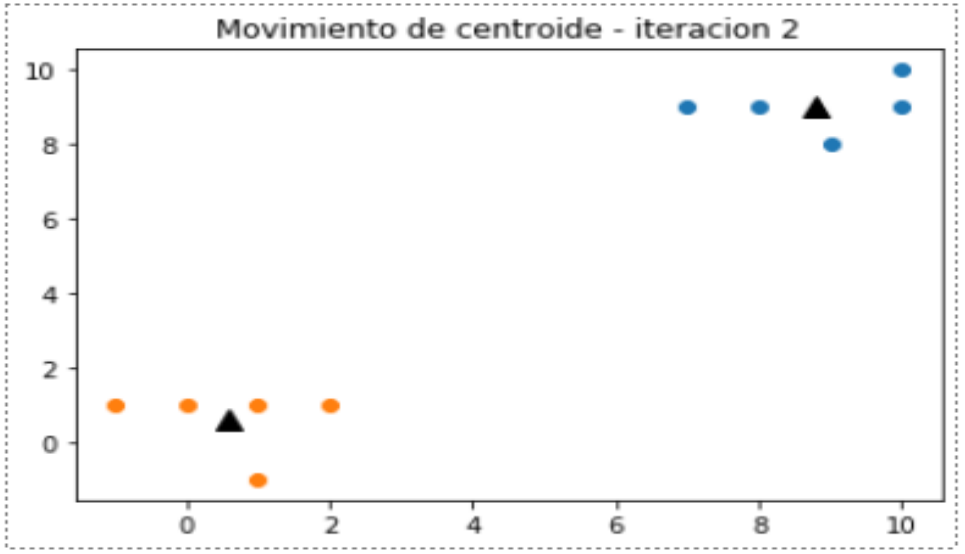
(a) Iteración 1 (Etapa 2)



(b) Iteración 1 (Etapa 3)

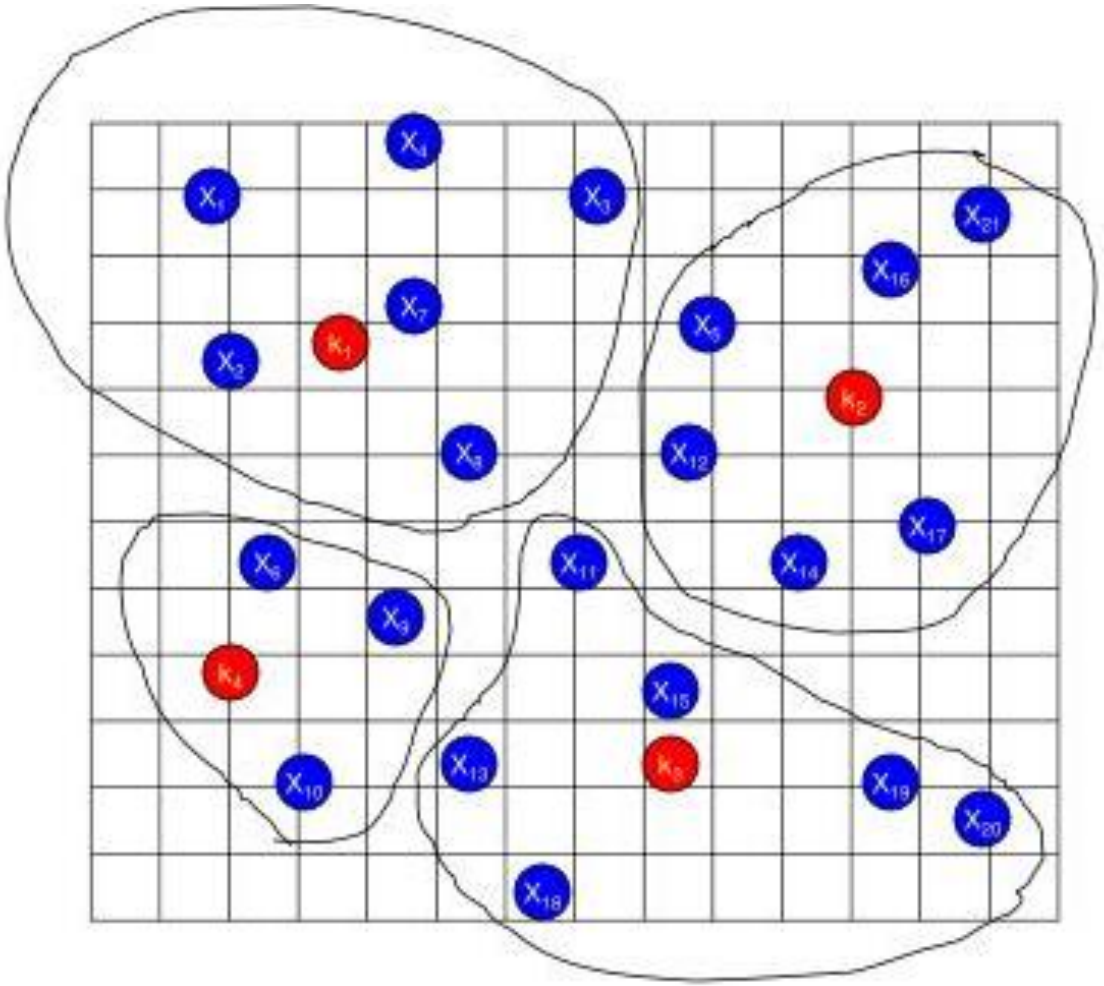


(c) Iteración 2 (Etapa 2)



(d) Iteración 2 (Etapa 3)

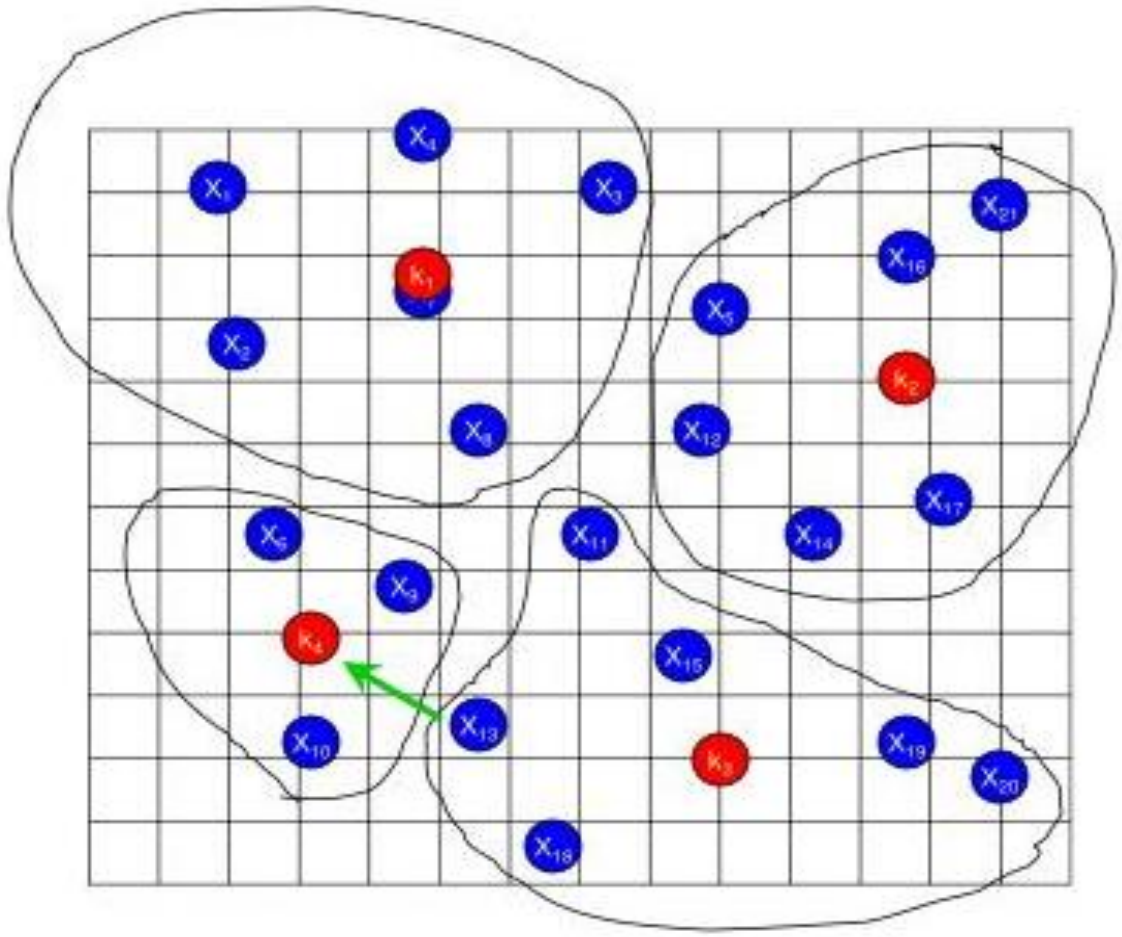
Ejemplo 2



Inicialización:

- Posición inicial aleatoria de los centros de los clústeres
- Cálculo de la media de cada clúster

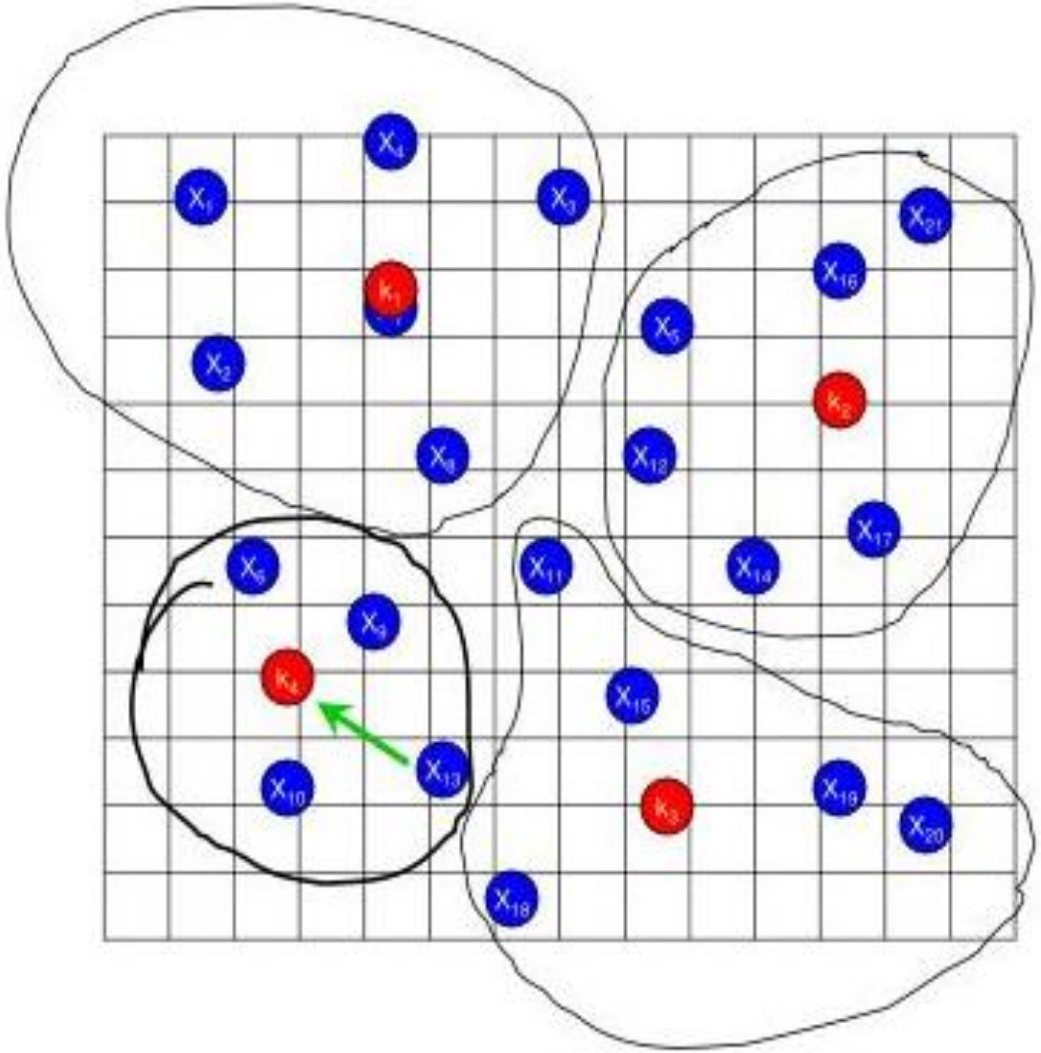
Ejemplo 2



Paso1:

Reasignar cada dato a una de las K medias

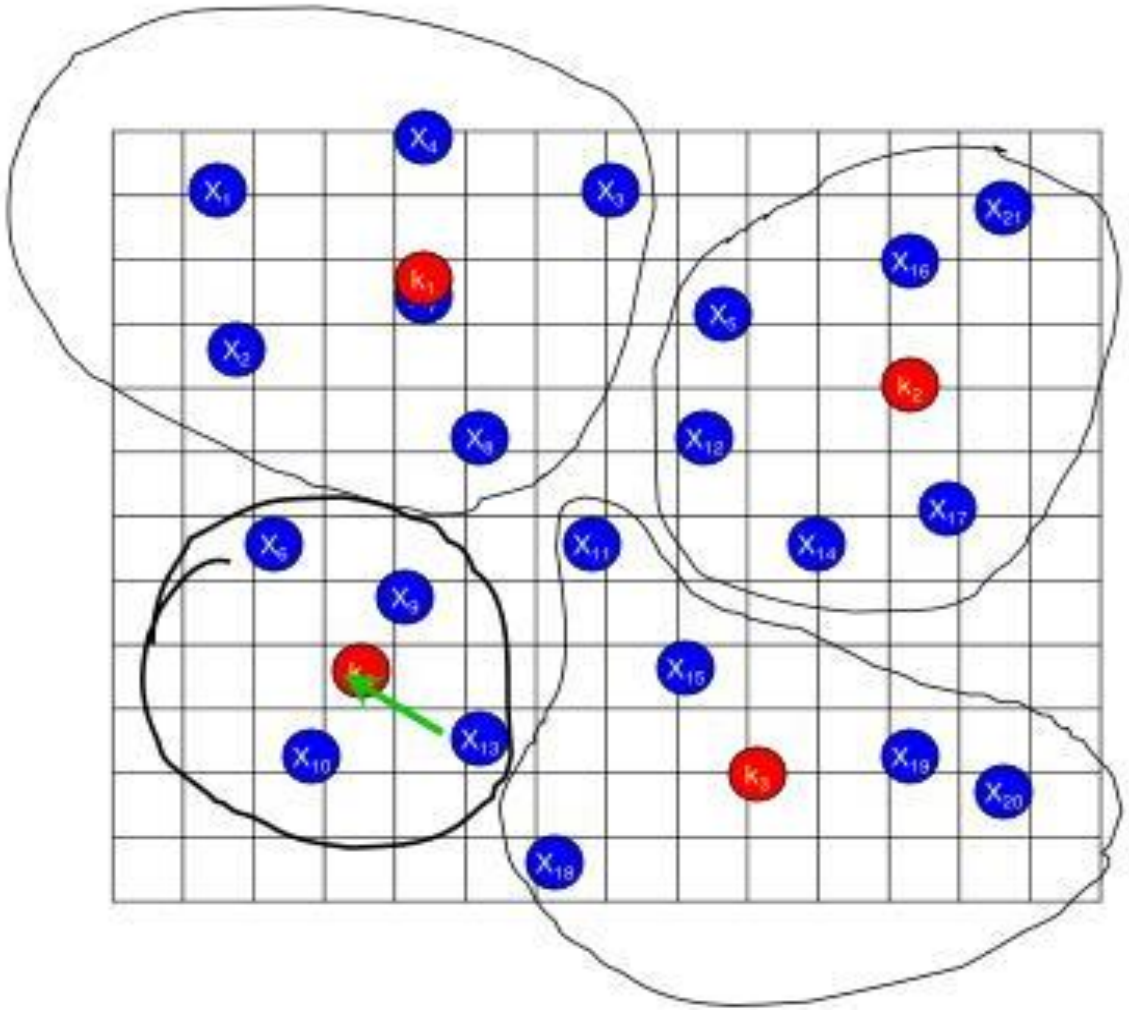
Ejemplo 2



Paso2:

Los puntos se mueven al clúster cuyo centro esté más cercano

Ejemplo 2



Paso3:

Se recalculan los centroides

Los pasos 1 al 3 se repiten hasta que no haya cambios en los centros de los clústeres.

El algoritmo termina

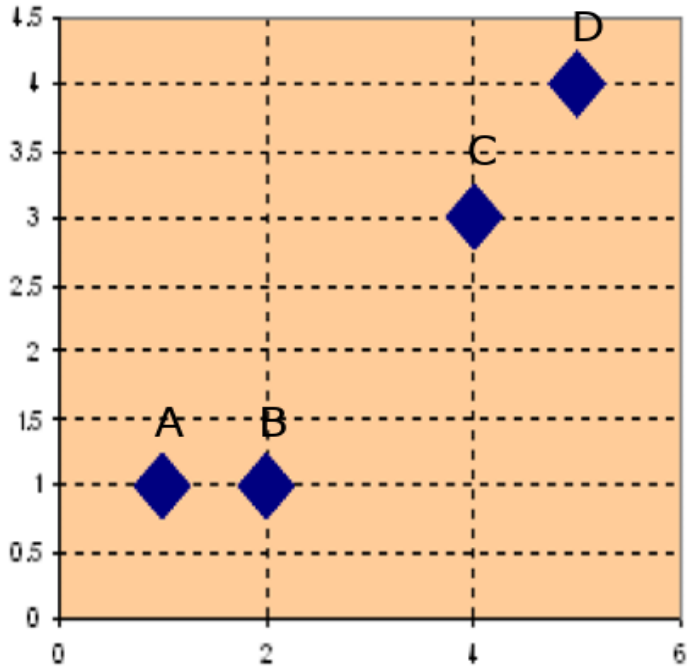
Ejemplo 3

funcionamiento del algoritmo k-means.

- https://www.youtube.com/watch?v=nXY6PxAaOk0

Ejemplo 4

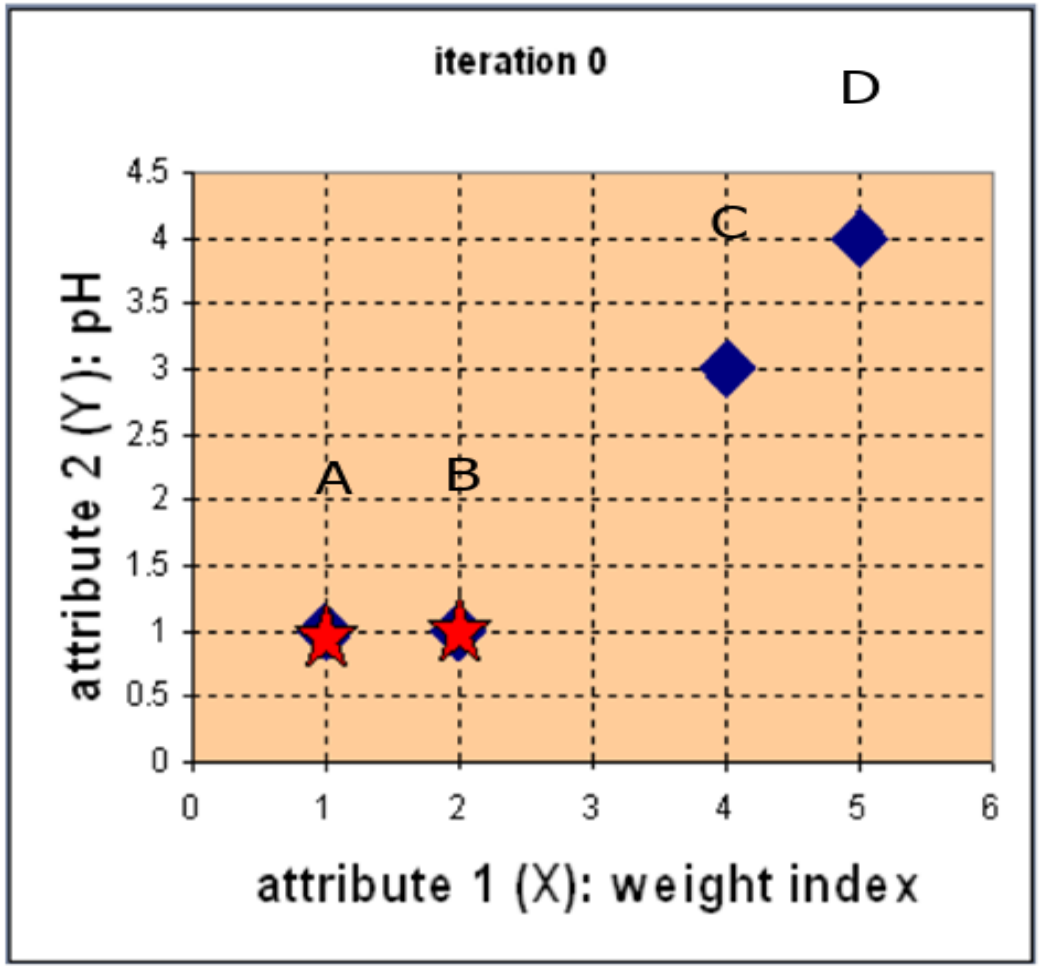
Supongamos que tenemos 4 tipos de medicamentos y cada uno tiene dos atributos (pH y peso). Nuestro objetivo es agrupar estos objetos en un grupo de medicamentos K=2.



Medicamento	pH	Peso
A	1	1
B	2	1
C	4	3
D	5	4

Ejemplo 4

Paso1: Elegir centroides iniciales y encontrar una partición inicial



$$c_1 = A, c_2 = B$$

$$\mathbf{D}^0 = \begin{bmatrix} 0 & 1 & 3.61 & 5 \\ 1 & 0 & 2.83 & 4.24 \end{bmatrix} \quad \begin{matrix} \mathbf{c}_1 = (1,1) & group-1 \\ \mathbf{c}_2 = (2,1) & group-2 \end{matrix}$$

$$\begin{matrix} A & B & C & D \end{matrix} \quad \text{Euclidean distance}$$

$$\begin{bmatrix} 1 & 2 & 4 & 5 \\ 1 & 1 & 3 & 4 \end{bmatrix} \quad \begin{matrix} X \\ Y \end{matrix}$$

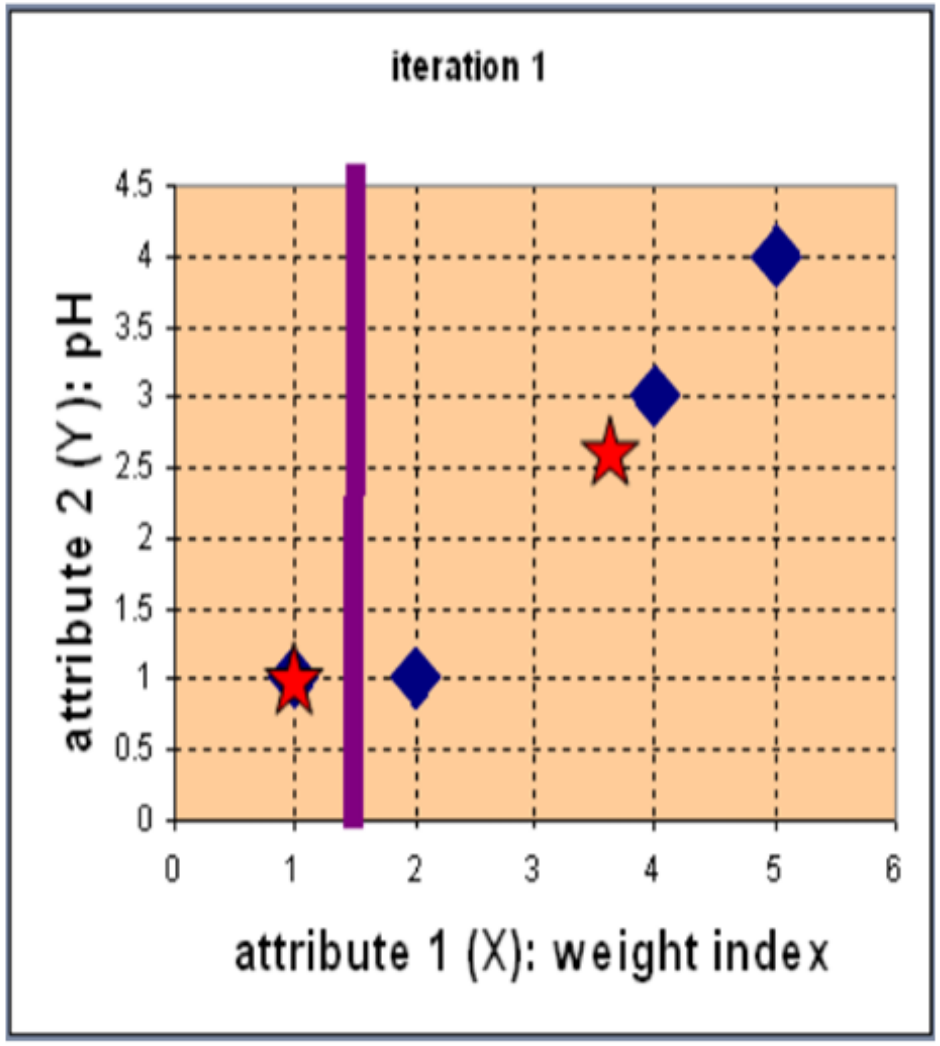
$$d(D,c_1) = \sqrt{(5-1)^2 + (4-1)^2} = 5$$

$$d(D,c_2) = \sqrt{(5-2)^2 + (4-1)^2} = 4.24$$

Asignar cada objeto al clúster con el centroide inicial más próximo

Ejemplo 4

Paso2: Calcular los nuevos centroides de la partición actual



Conociendo los miembros de cada clúster, calculamos los nuevos centroides basándonos en estas nuevas pertenencias

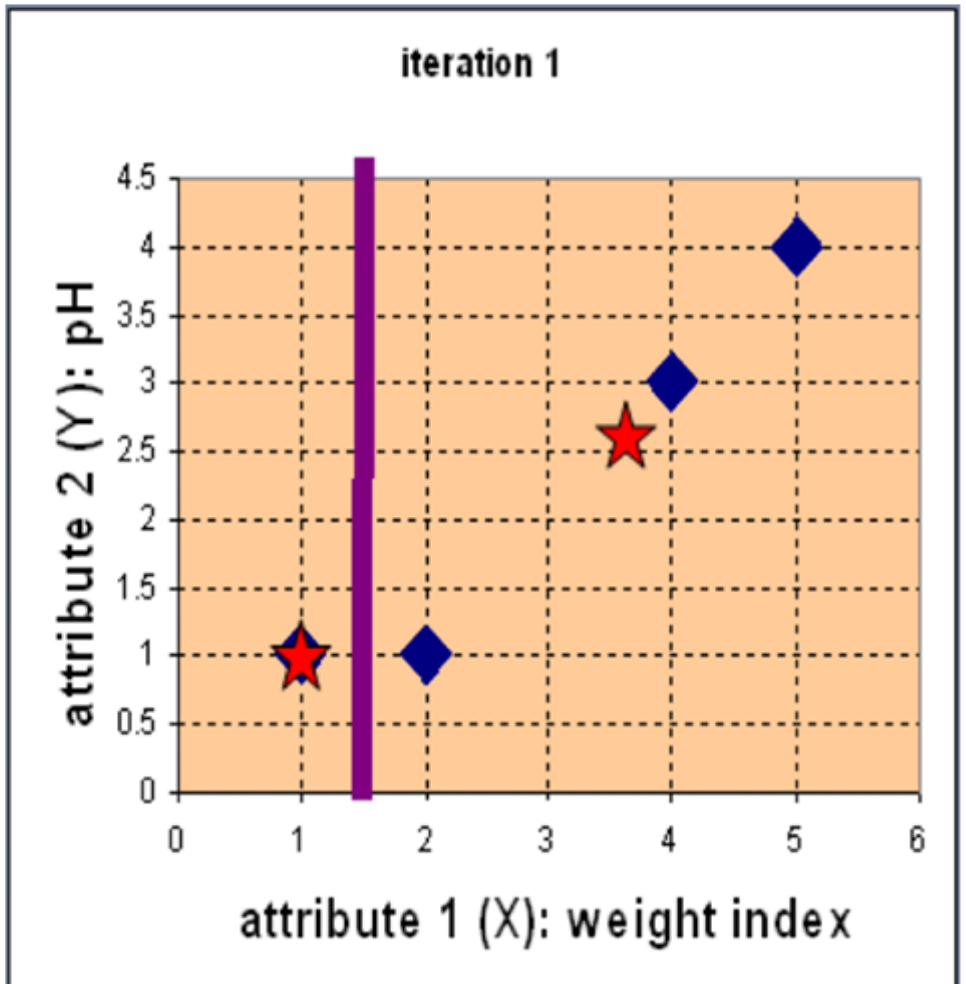
$$c_1 = (1,\ 1)$$

$$c_2 = \left(\frac{2+4+5}{3},\ \frac{1+3+4}{3}\right)$$

$$= \left(\frac{11}{3},\ \frac{8}{3}\right)$$

Ejemplo 4

Paso3: Renovar la pertenencia de los puntos sobre la base de los nuevos centroides



Calcular la distancia de todos los puntos a los nuevos centroides

$$D^1 = \begin{bmatrix} 0 & 1 & 3.61 & 5 \\ 3.14 & 2.36 & 0.47 & 1.89 \end{bmatrix} \quad \begin{matrix} c_1 = (1,1) & group-1 \\ c_2 = (\frac{11}{3}, \frac{8}{3}) & group-2 \end{matrix}$$

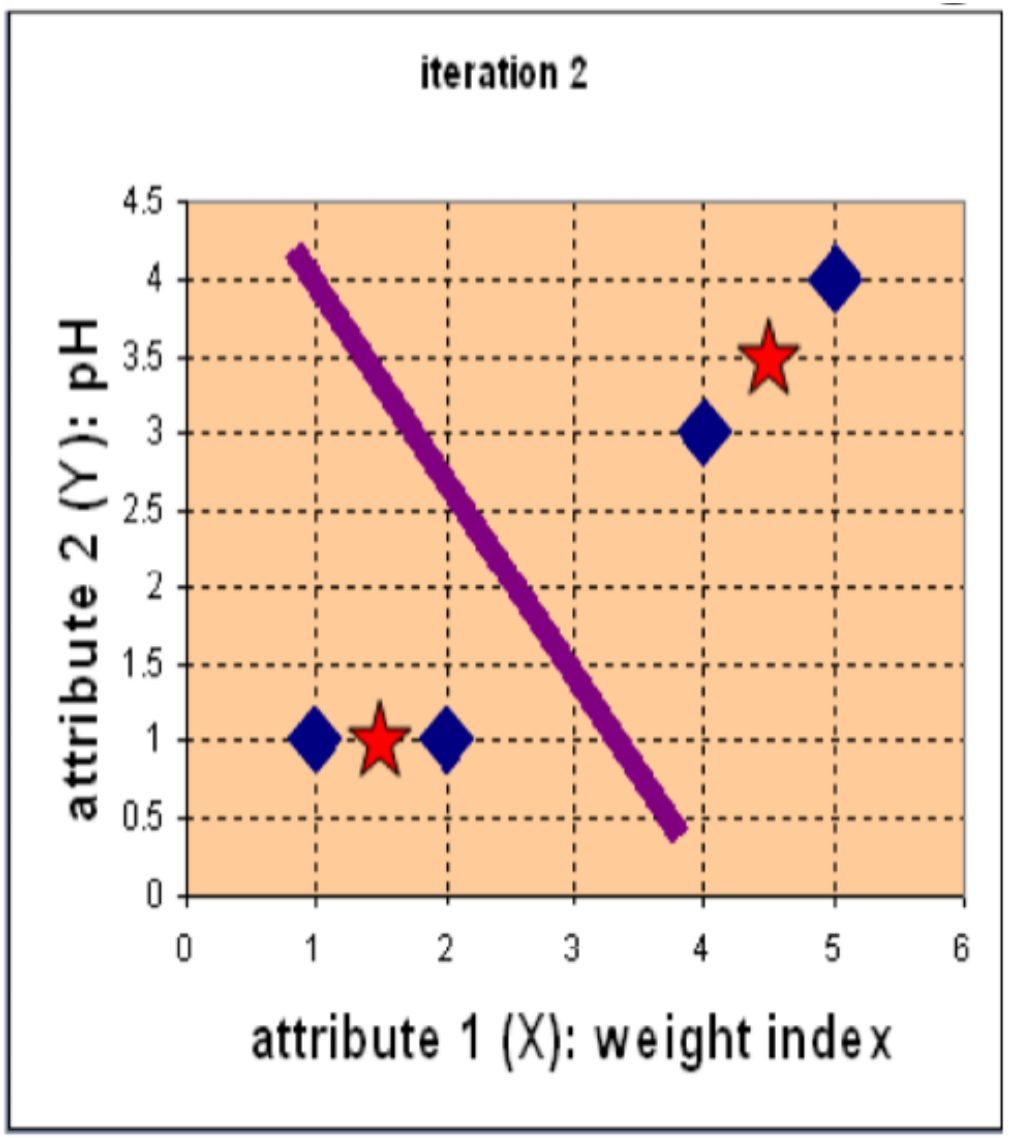
$$\begin{matrix} A & B & C & D \end{matrix}$$

$$\begin{bmatrix} 1 & 2 & 4 & 5 \\ 1 & 1 & 3 & 4 \end{bmatrix} \begin{matrix} X \\ Y \end{matrix}$$

Asignar la pertenencia de los datos

Ejemplo 4

Paso4: Repetir los pasos anteriores hasta la convergencia

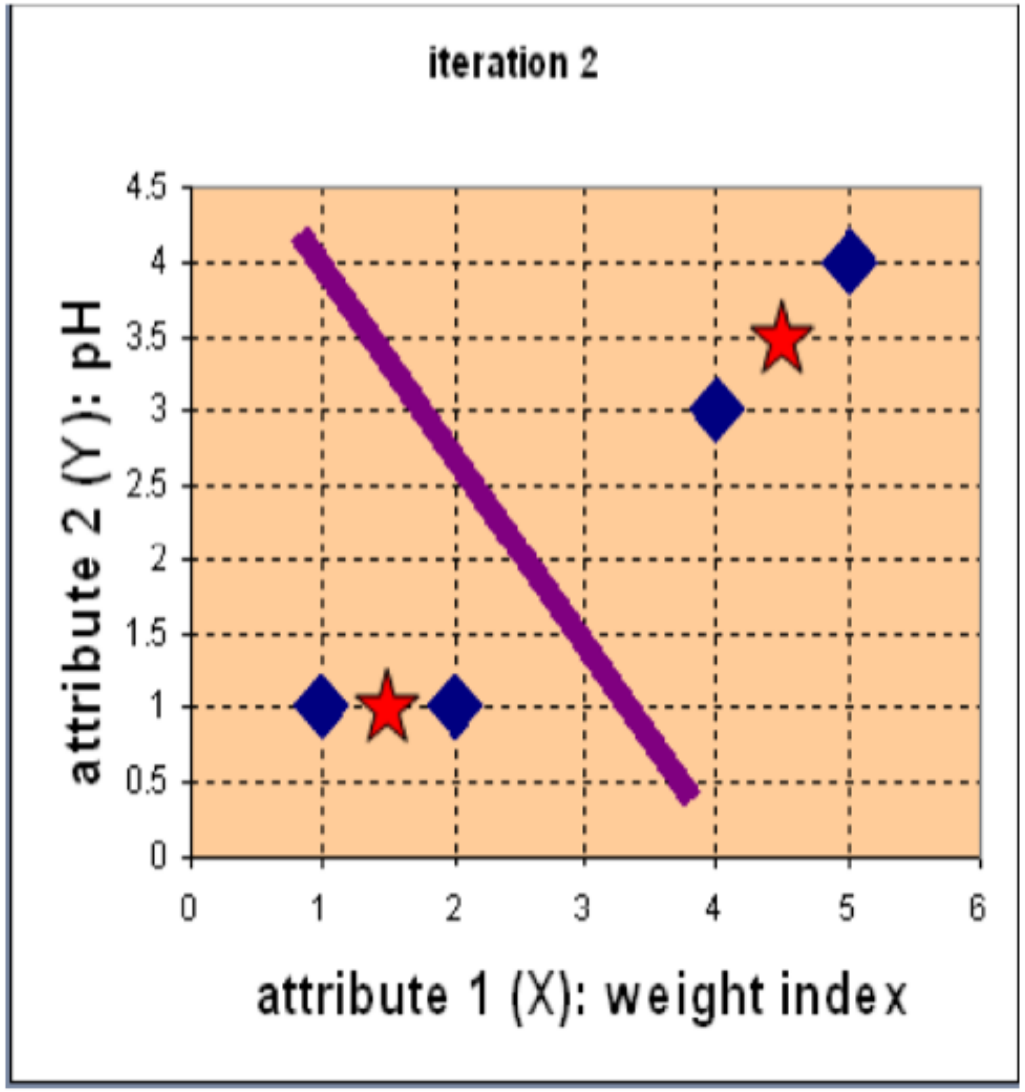


Conociendo los miembros de cada clúster, calculamos los nuevos centroides de cada grupo basándonos en estas nuevas pertenencias.

$$c_1 = \left(\frac{1+2}{2}, \frac{1+1}{2}\right) = (1\frac{1}{2}, 1)$$

$$c_2 = \left(\frac{4+5}{2}, \frac{3+4}{2}\right) = (4\frac{1}{2}, 3\frac{1}{2})$$

Ejemplo 4



Calcular la distancia de todos los puntos a los nuevos centroides

$$D^2 = \begin{bmatrix} 0.5 & 0.5 & 3.20 & 4.61 \\ 4.30 & 3.54 & 0.71 & 0.71 \end{bmatrix} \quad \begin{matrix} c_1 = (1\frac{1}{2}, 1) & group-1 \\ c_2 = (4\frac{1}{2}, 3\frac{1}{2}) & group-2 \end{matrix}$$

$$\begin{matrix} A & B & C & D \end{matrix}$$

$$\begin{bmatrix} 1 & 2 & 4 & 5 \\ 1 & 1 & 3 & 4 \end{bmatrix} \begin{matrix} X \\ Y \end{matrix}$$

Finalizar el proceso ya que no hay nuevas asignaciones. La pertenencia a cada grupo no cambia más.

Ejercicio

Para el conjunto de datos de medicamentos del ejemplo anterior, usar K-medias con la distancia de Manhattan para realizar análisis clúster con K=2, e inicializando los centroides a C1 = A and C2 = C.

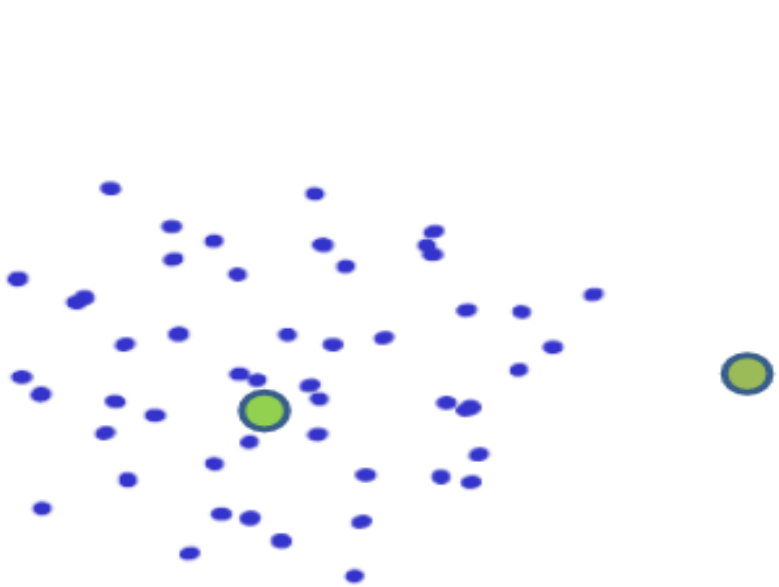
Contesta a las siguientes preguntas

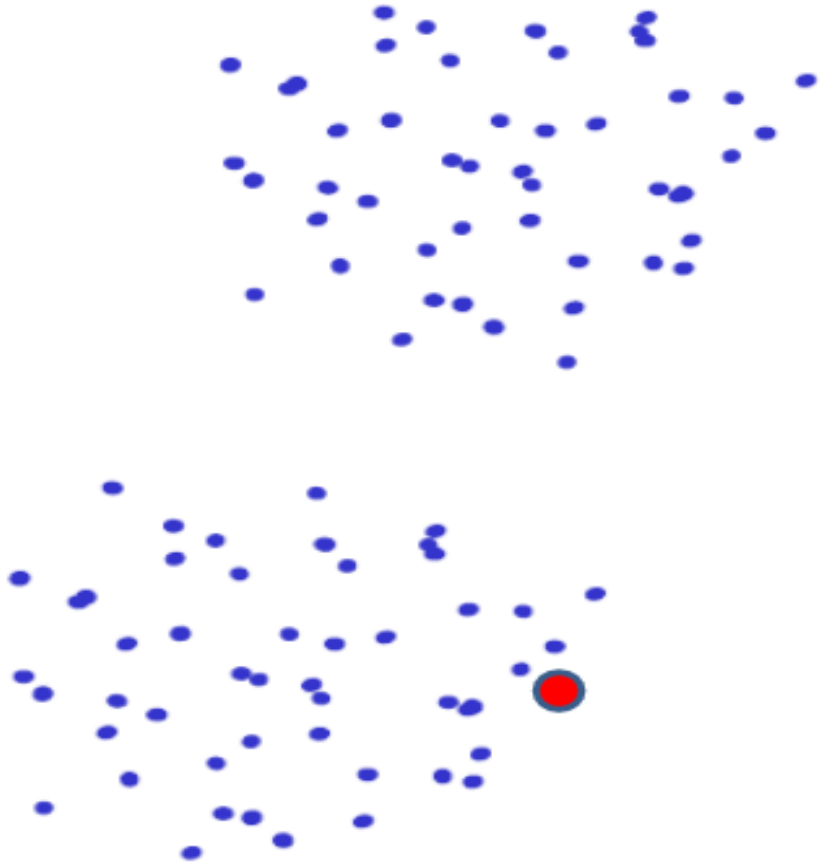
1. ¿Cuántos pasos se requieren para la convergencia?
2. Describe los dos clústeres después de la convergencia.
3. Cuáles son los centroides de los clústeres una vez alcanzada la convergencia?

Propiedades del algoritmo k-medias

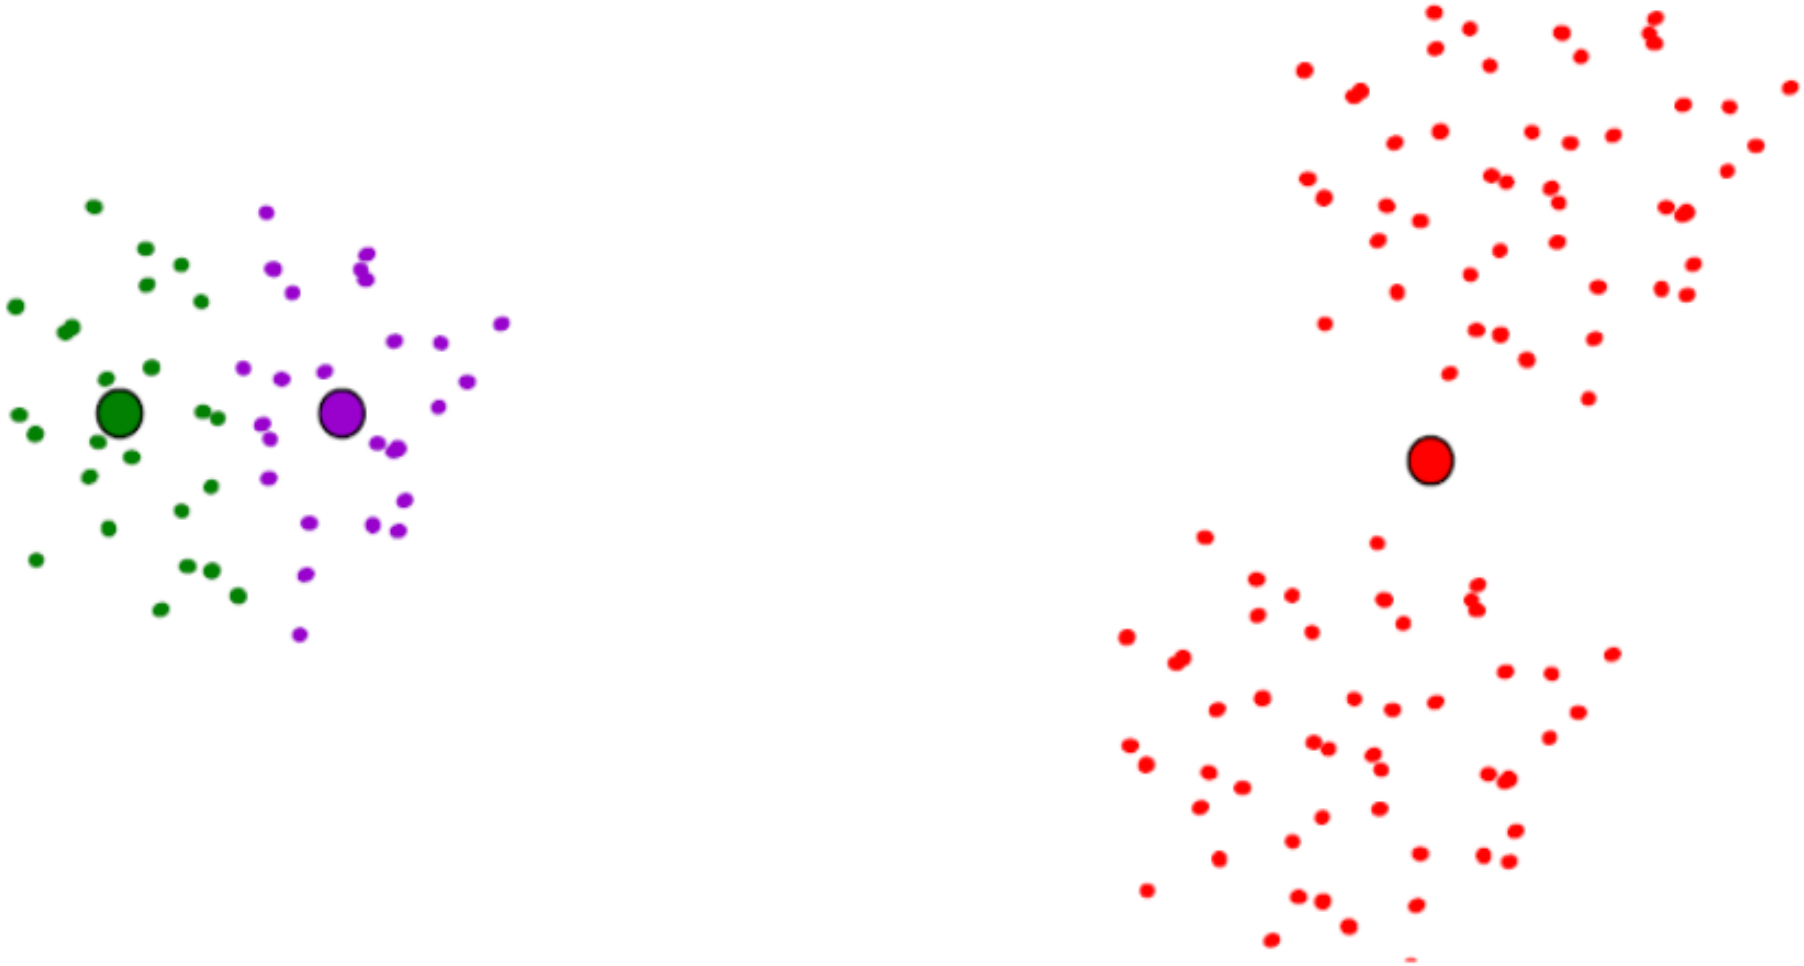
a) Es eficiente para grandes conjuntos de datos
b) Funciona con datos numéricos
c) Mínimos Locales.
d) Es altamente dependiente de los centroides iniciales

Inicialización





Fin del algoritmo



Propiedades del algoritmo k-medias

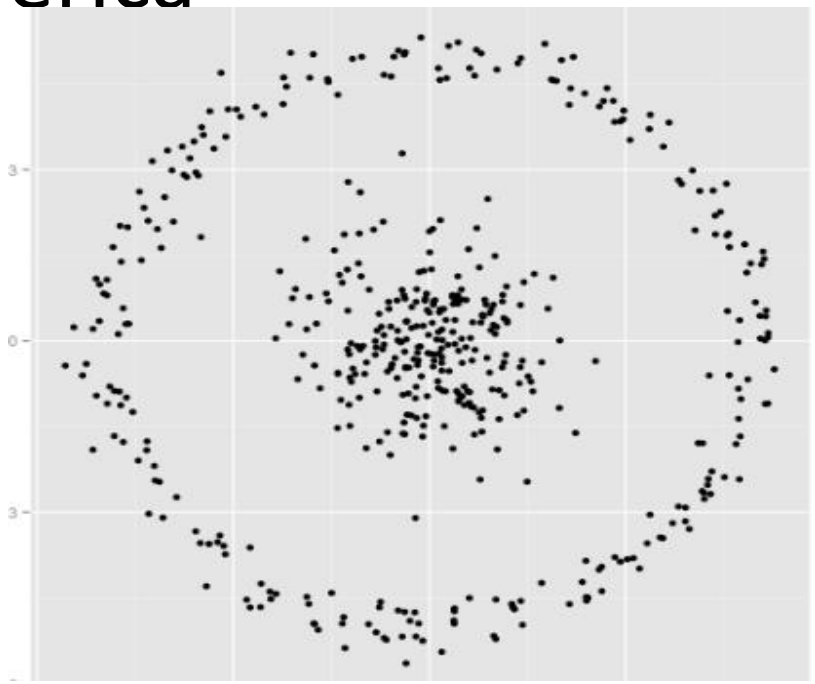
e) Sensible a los outliers



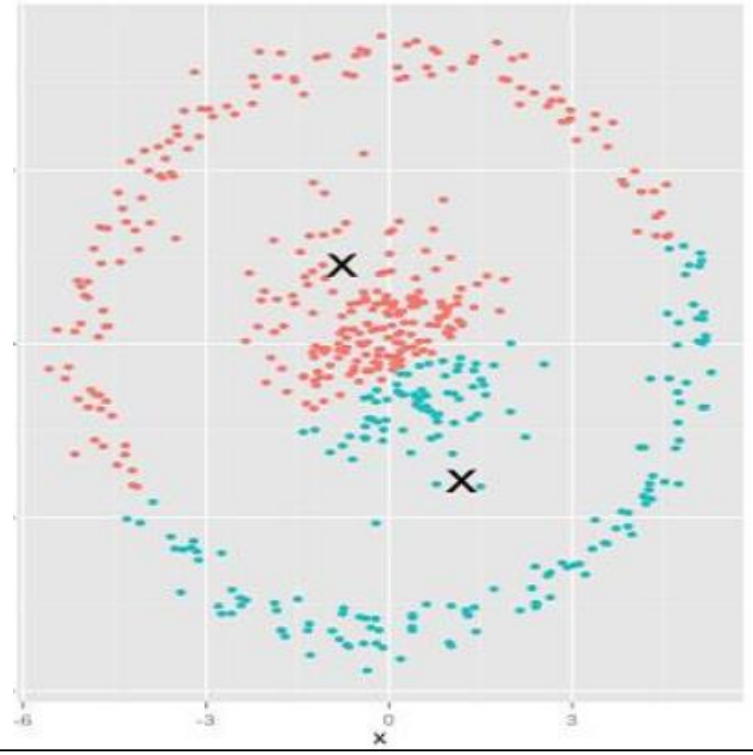
El preprocesamiento de los datos podría ayudar con el tratamiento de los outliers

Propiedades del algoritmo k-medias

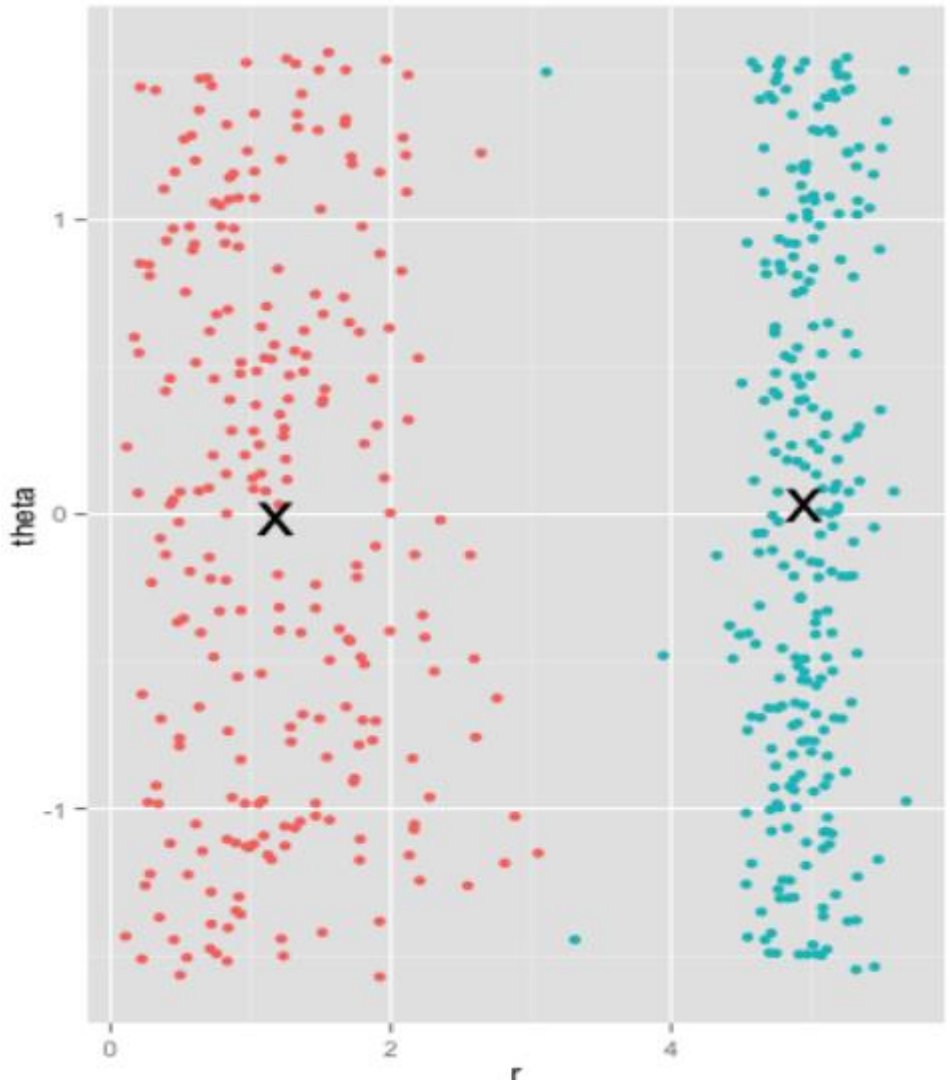
f) Puede tratar solo con datos cuya distribución es simétrica y esférica



un humano reconocería inmediatamente dos grupos



asignación que haría el algoritmo de las k-medias

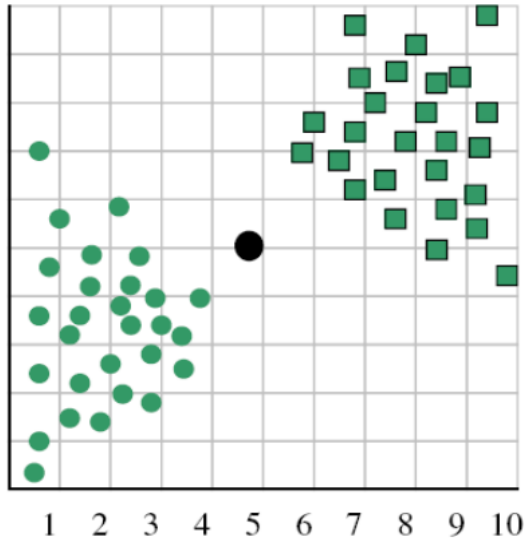


Transformando los datos en coordenadas polares, funciona el algoritmo de clustering

Propiedades del algoritmo k-medias

g) Número de clústeres

El valor de k (número de clústeres) es un hiperparámetro que debe ser especificado

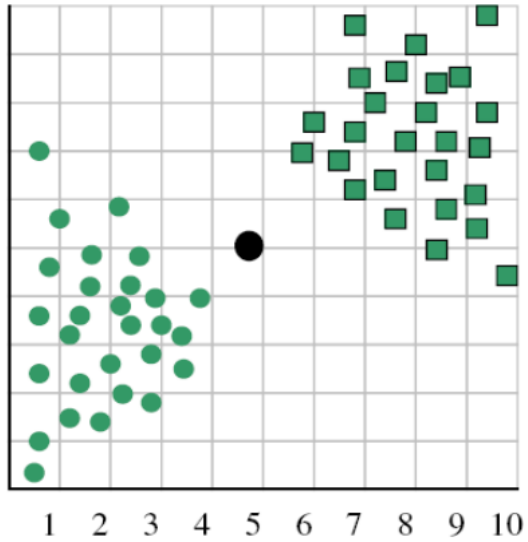


Cuando k=1 , la función de costo es 873.0

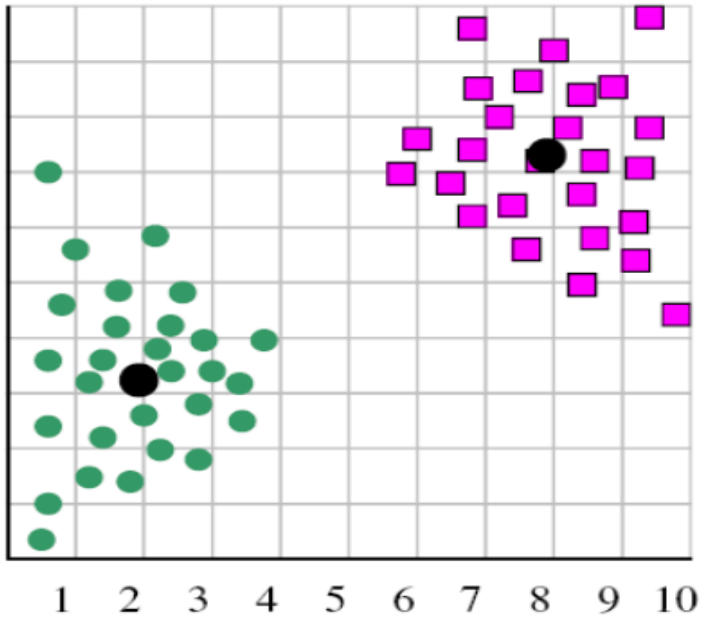
Propiedades del algoritmo k-medias

g) Número de clústeres

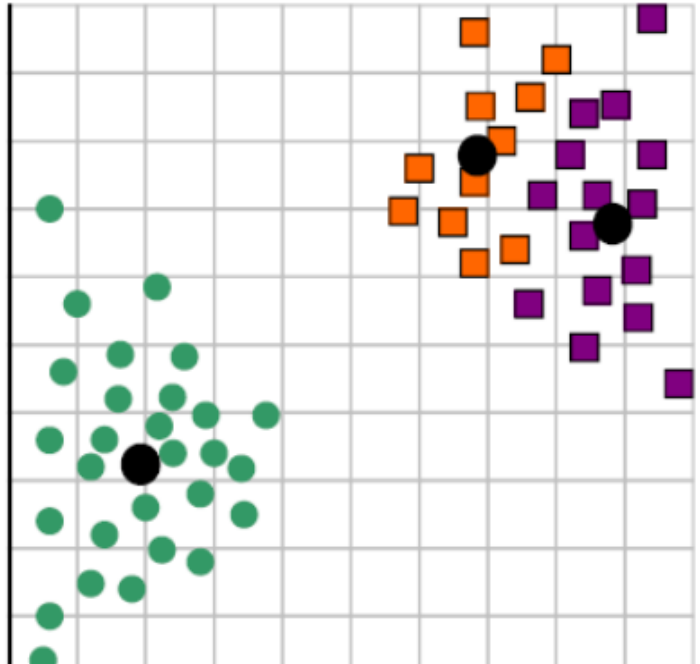
El valor de k (número de clústeres) es un hiperparámetro que debe ser especificado



Cuando k=1 , la función de costo es 873.0



Cuando k=2 , la función de costo es 173.1

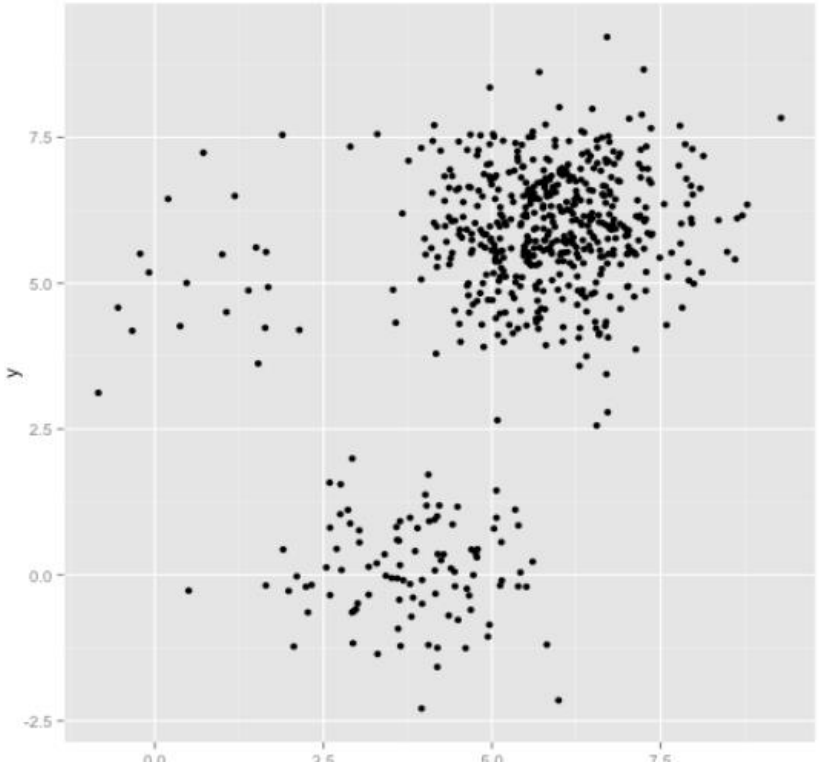


Cuando k=3 , la función de costo es 133.6

Propiedades del algoritmo k-medias

h) Clases desbalanceadas

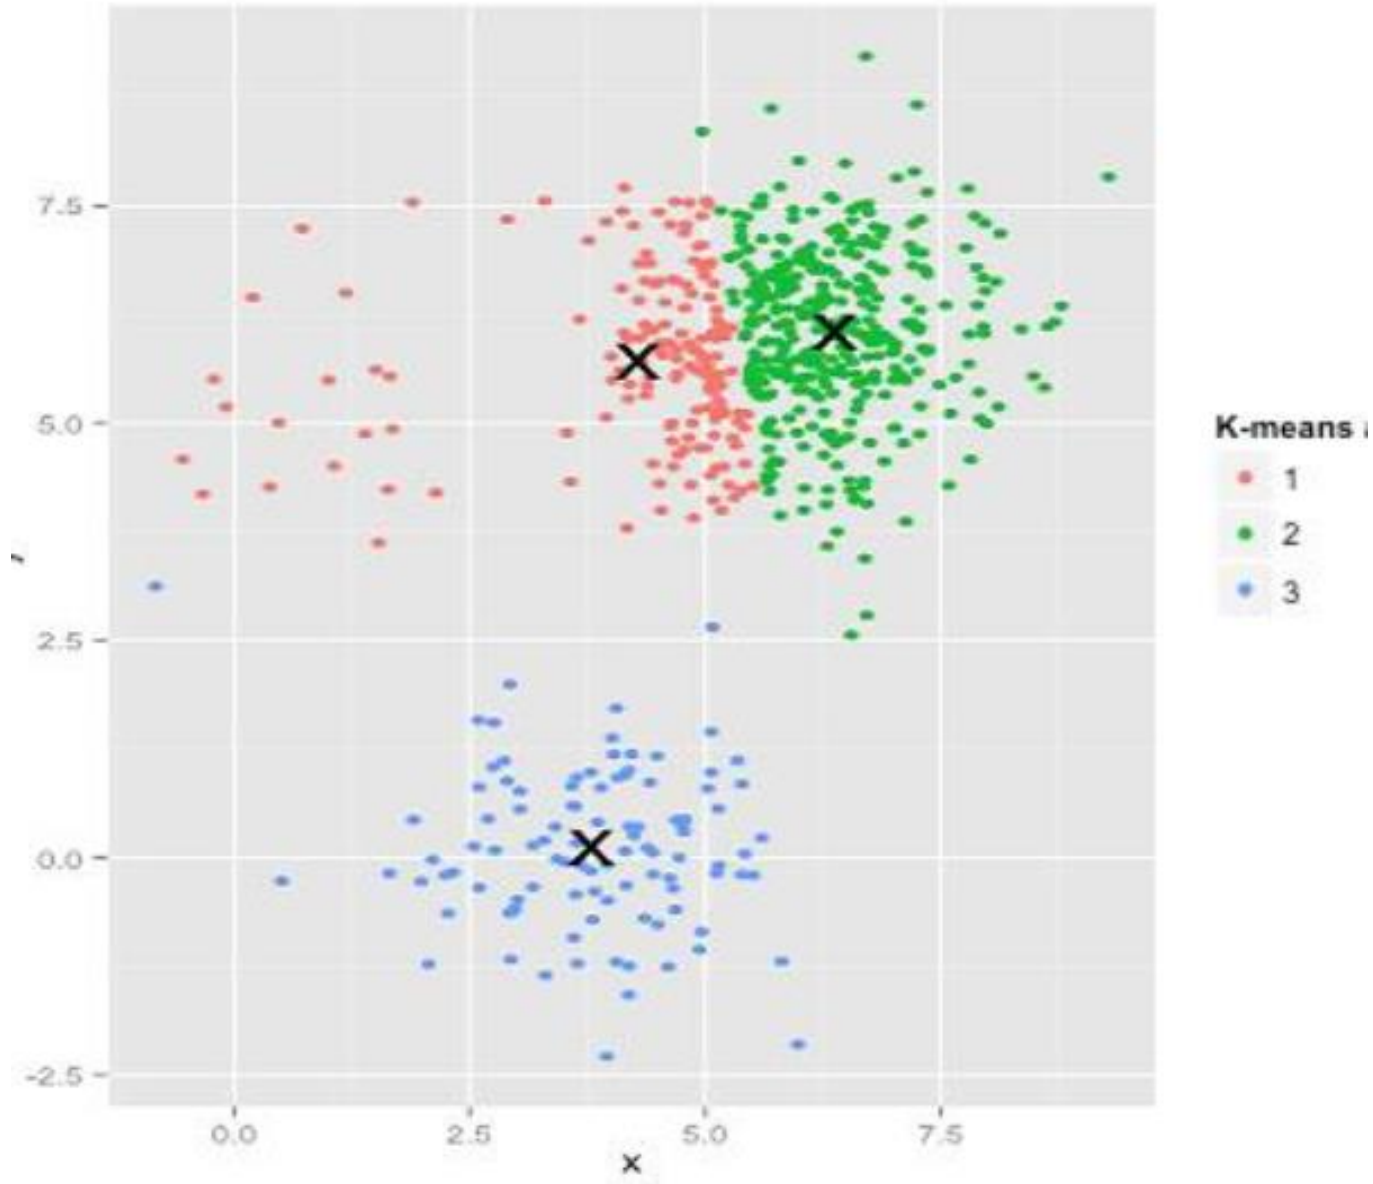
El valor de k (número de clústeres) es un hiperparámetro que debe ser especificado



Conjunto de clústeres, de tamaños

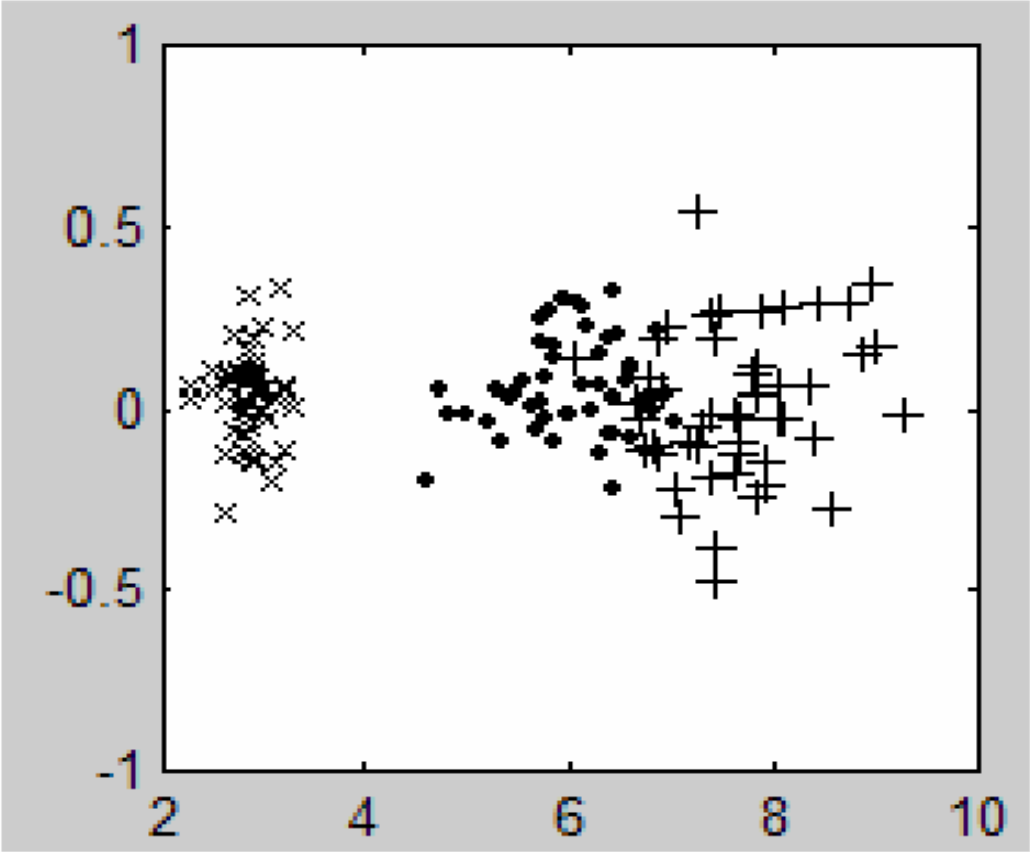
20, 100, 500.

Generado desde una distribución gaussiana multivariante


7.5
5.0
2.5
0.0
-2.5
0.0
2.5
5.0
7.5
x
K-means
1
2
3

Propiedades del algoritmo k-medias

i) Clases con solapamiento



Datos Iris. Una clase es linealmente separable de las otras dos