DBSCAN

Density-based spatial clustering of applications with noise

Agrupamiento espacial basado en densidad de aplicaciones con ruido

DBSCAN

Algoritmo de agrupamiento de datos basado en densidad porque encuentra un número de grupos (clústeres) comenzando por una estimación de la distribución de densidad de los puntos correspondientes.

También identifica valores atípicos o ruido que son puntos que no pertenecen a ningún grupo.

Ideas principales:

- un clúster es un área de alta densidad (no hay restricciones sobre su forma) rodeada por una de baja densidad
- no se necesita decidir el número de clusters
- se basa principalmente en una función métrica (normalmente la distancia euclídea), un radio ε y un mínimo de puntos N_{min}

Conceptos necesarios

- El $\boldsymbol{\varepsilon}$ **-vecindario** de un punto $\vec{x}_i$ se define como

$$N_\varepsilon(\vec{x}_i) = \left\{\vec{x}_j \in D : d(\vec{x}_i, \vec{x}_j) \leq \ \varepsilon\right\}$$

donde D es el conjunto de datos y $d(.,.)$ es cierta función de distancia.

- Un punto $\vec{x}_j$ es **vecino** del punto $\vec{x}_i$ si

$$d(\vec{x}_i, \vec{x}_j) \leq \ \varepsilon$$

Conceptos necesarios

- $\vec{x}_i$ es un **punto central** si está rodeado por al menos N_{min} puntos

$$N(d(\vec{x}_i, \vec{x}_j) \leq \varepsilon) \geq N_{min} \text{ (*)}$$

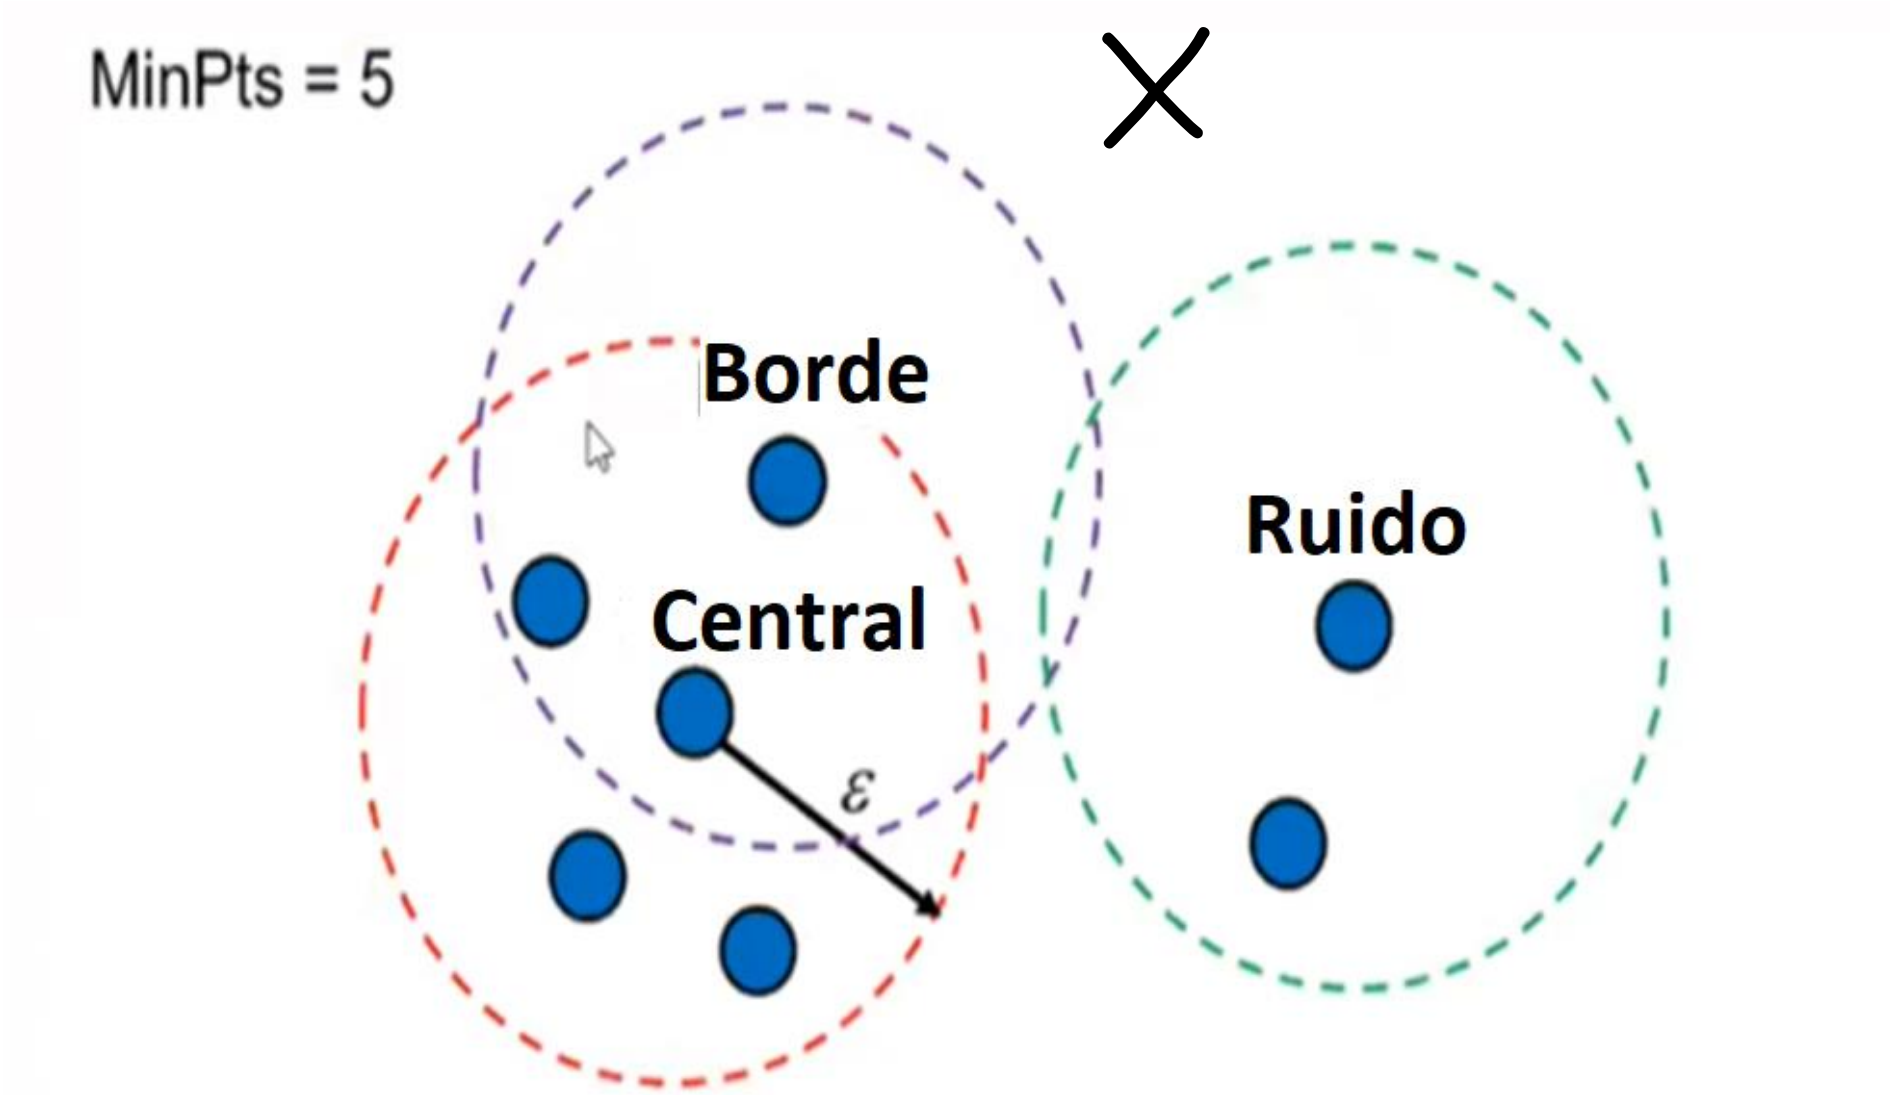
- Se pueden definir 3 tipos de puntos con el algoritmo DBSCAN:

Punto central: un punto con tantos o más vecinos como el número mínimo de puntos (*).

Punto de borde: un punto que tiene menos vecinos que el número mínimo de puntos, pero es vecino de un punto central.

Punto de ruido: ni un punto central ni un punto de borde.

Tipos de puntos con el algoritmo DBSCAN



Tipos de puntos con el algoritmo DBSCAN



Original Points



Point types: core, border and noise

Eps = 10, MinPts = 4

Conceptos necesarios

- Un punto $\vec{x}_j$ es **directamente alcanzable a la densidad** desde $\vec{x}_i$ (con respecto a ε y a N_{min}) si

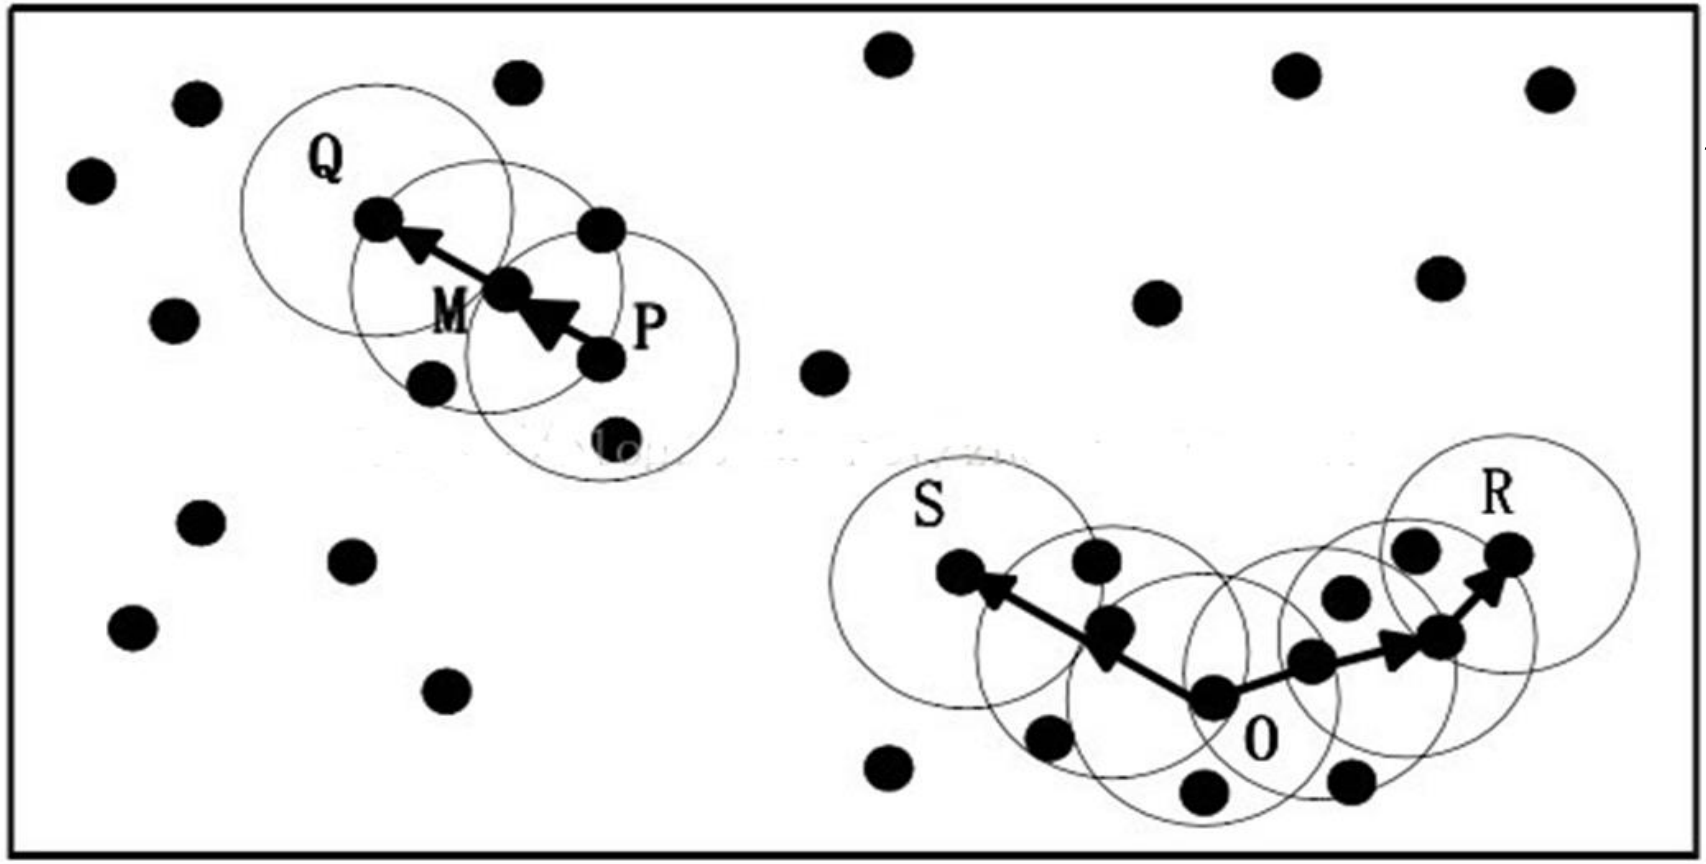
1) $\vec{x}_i$ es un punto central *y* $\vec{x}_j$ un vecino de $\vec{x}_i$, es decir, $\vec{x}_j \in N_\varepsilon(\vec{x}_i))$

2) $|N_\varepsilon(\vec{x}_i)| \geq N_{min}$

- Un punto $\vec{x}$ es **alcanzable por densidad** desde $\vec{y}$ si hay una secuencia ordenada de puntos $\vec{y} = \vec{x}_1, \vec{x}_2, \cdots, \vec{x}_j = \vec{x}$ tales que $\vec{x}_{l+1}$ es directamente alcanzable por densidad desde $\vec{x}_l$ con $l = 1,2, \cdots, j-1$.

Conceptos necesarios

- Dos puntos $\vec{x}_j$ y $\vec{x}_i$ están **densamente conectados** con respecto a ε y a N_{min} si existe $\vec{x}_k$ tal que ambos $\vec{x}_j$ y $\vec{x}_i$ son alcanzables por densidad desde $\vec{x}_k$ con respecto a ε y a N_{min}.



N_{min}=3

Puntos centrales:
M,P,O,R

M es directamente accesible a la densidad desde P
Q es densidad alcanzable desde P
P NO es densidad alcanzable desde Q
S,R son densidad alcanzable desde O
O, R y S están todos conectados por densidad (simétricos).

Conceptos necesarios

Sea D un conjunto de datos. Un **clúster** C con respecto a ε y a N_{min} es un subconjunto no vacío de D que satisface las siguientes condiciones:

- *maximalidad*

$\forall\, \vec{x}_i, \vec{x}_j \in D$, si $\vec{x}_j \in C$ y $\vec{x}_j$ es alcanzable por densidad desde $\vec{x}_i$ con respecto a ε y a N_{min} entonces $\vec{x}_j \in C$.

- *conectividad*

$\forall\, \vec{x}_i, \vec{x}_j \in C$, $\vec{x}_i$ y $\vec{x}_j$ están densamente conectados con respecto a ε y a N_{min} .

Algoritmo DBSCAN

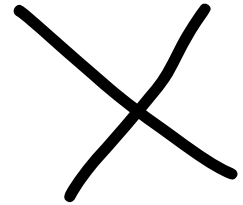
El algoritmo DBSCAN visita todos los puntos del conjunto de datos de entrenamiento y los marca como *visitados* a medida que avanza.

- Si un punto es un punto central, se inicia la primera clase (denominada clase 1). El punto central y sus vecinos se asignan a la clase 1. Luego, el algoritmo visita a sus vecinos para encontrar otro punto central y lo asigna a la clase 1. Este paso permite que la clase se expanda. El algoritmo para de expandir la clase 1 cuando se han visitado todos los puntos densamente alcanzables
- El algoritmo continúa visitando los puntos no visitados y comenzará una nueva clase si se encuentra otro punto central. Esta clase también se puede ampliar y así sucesivamente.
- Finalmente, todos los puntos que no están asignados a una clase son puntos de ruido.

Simulacion DBSCAN

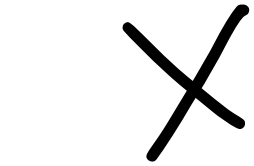
DBSCAN Explanation and Visualization - YouTube

Ventajas del algoritmo DBSCAN



- no requiere que el usuario especifique el número de clústeres
- puede encontrar cualquier forma de clústeres
- puede identificar los valores atípicos (*outliers*)

Desventajas del algoritmo DBSCAN



- No es un método absolutamente determinístico. Los objetos bordes, que son alcanzables desde más de un cluster pueden asignarse a uno u otro en función del orden en el que se visite los puntos
- No genera buenos resultados cuando la densidad de los grupos es muy distinta, ya que no es posible encontrar parámetros ε y N_{min} que sirvan para todos a la vez.