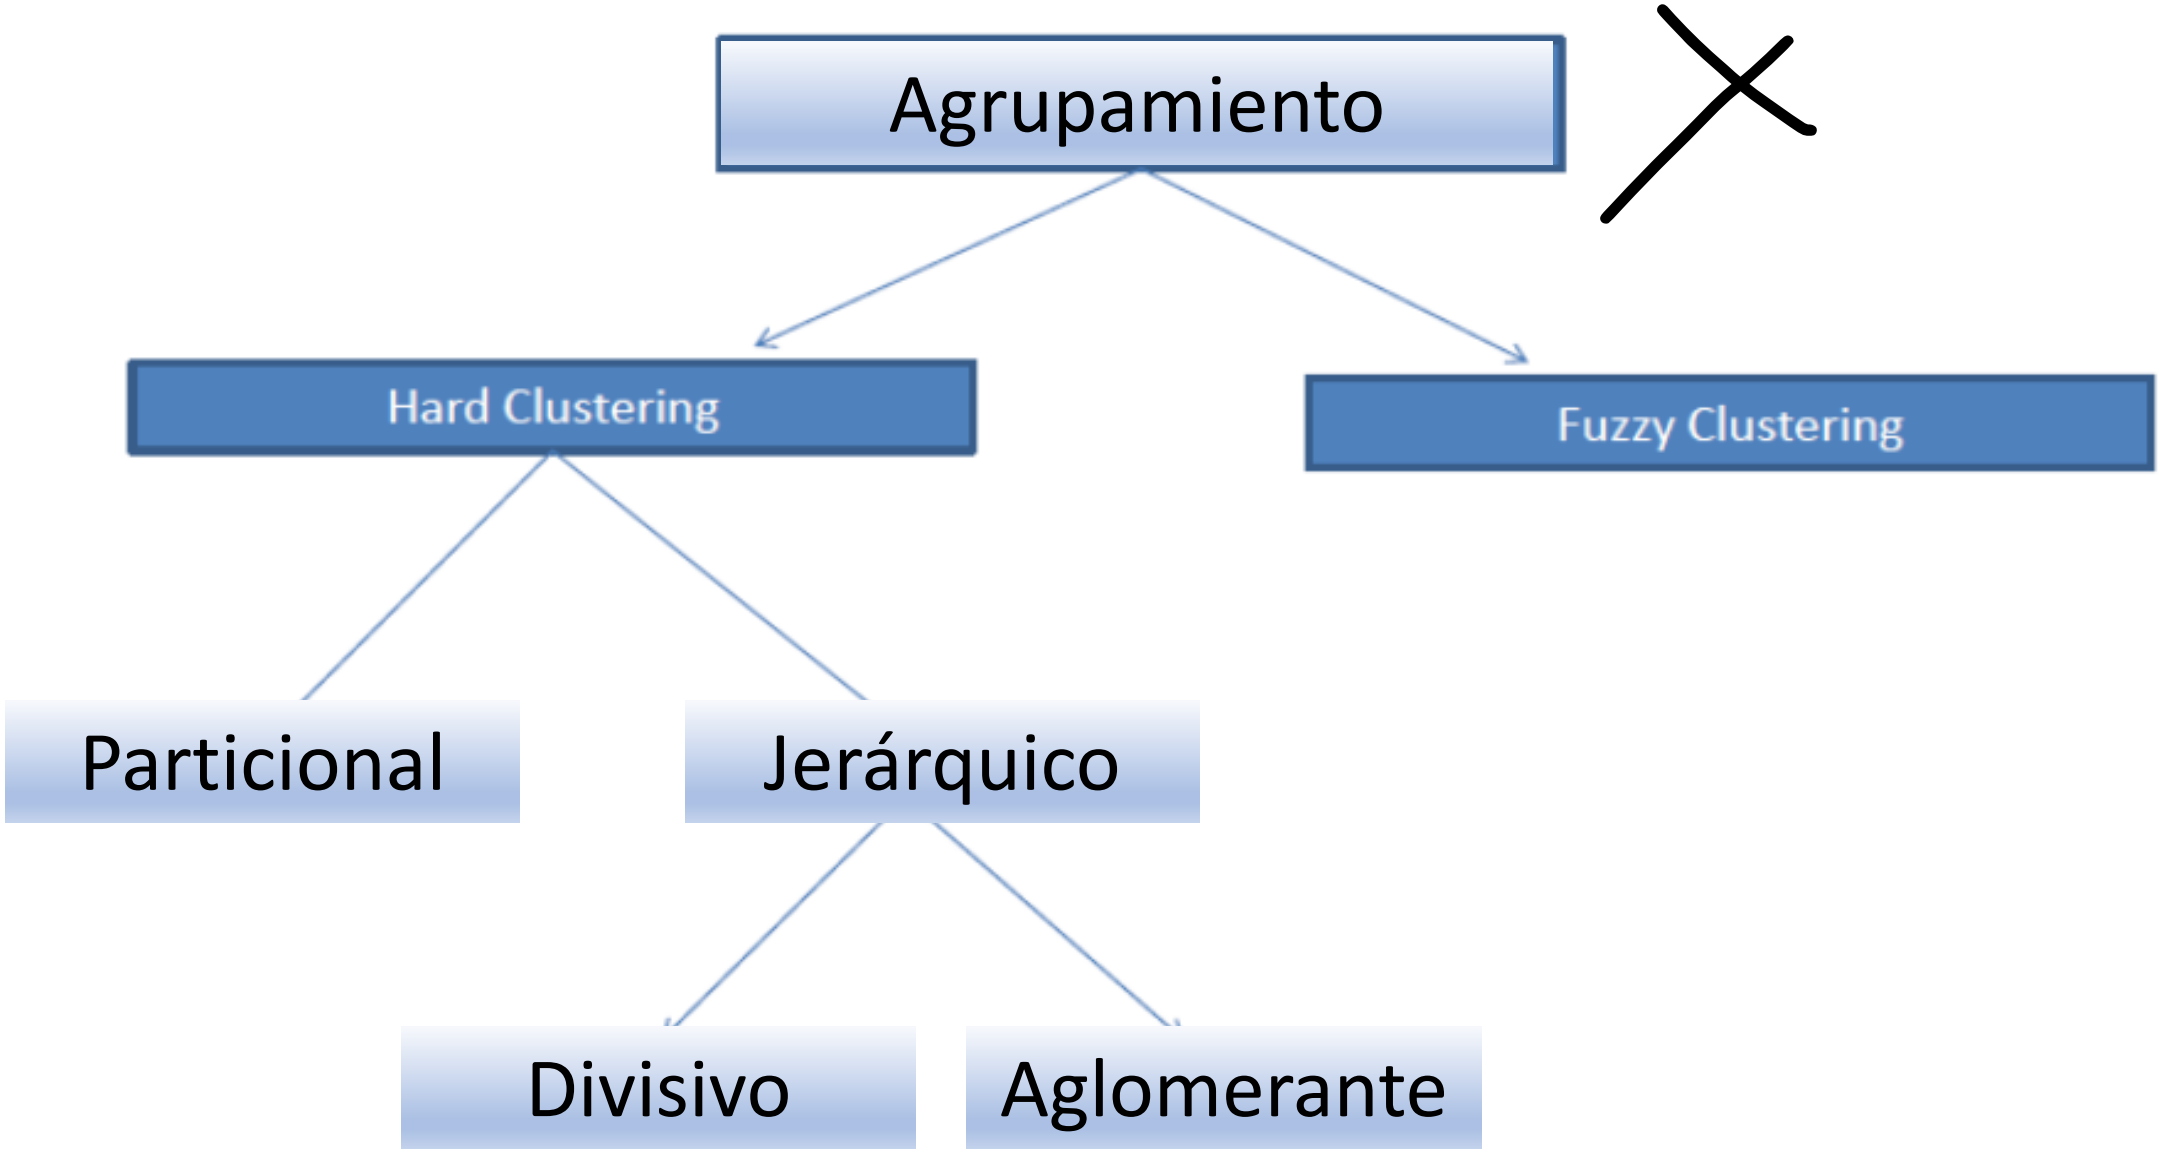
Clustering Jerárquico


Agrupamiento
Hard Clustering
Fuzzy Clustering
Particional
Jerárquico
Divisivo
Aglomerante



- **Algoritmo particional**

Divide el conjunto de datos en una sola partición

- **Algoritmo jerárquico**

divide un conjunto de datos en una secuencia de conjuntos anidados.

Clustering Jerárquico



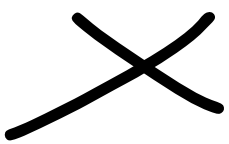
- **clustering jerárquico aglomerante**

Empieza con cada punto en un grupo solo y repite la fusion de los pares de clusteres más cercanos de acuerdo a algún criterio de similtud hasta que todos los datos esten en un solo cluster

- **clustering jerárquico divisivo**

Empieza con todos los puntos en un grupo y se repite la division de los grupos grandes en grupos más pequeños.

Desventajas del clustering jerárquico



- Los puntos que son incorrectamente agrupados en etapas iniciales no pueden ser recolocados
- Diferentes medidas de similaridad pueden conducir a diferentes resultados

Representación del Clustering Jerárquico

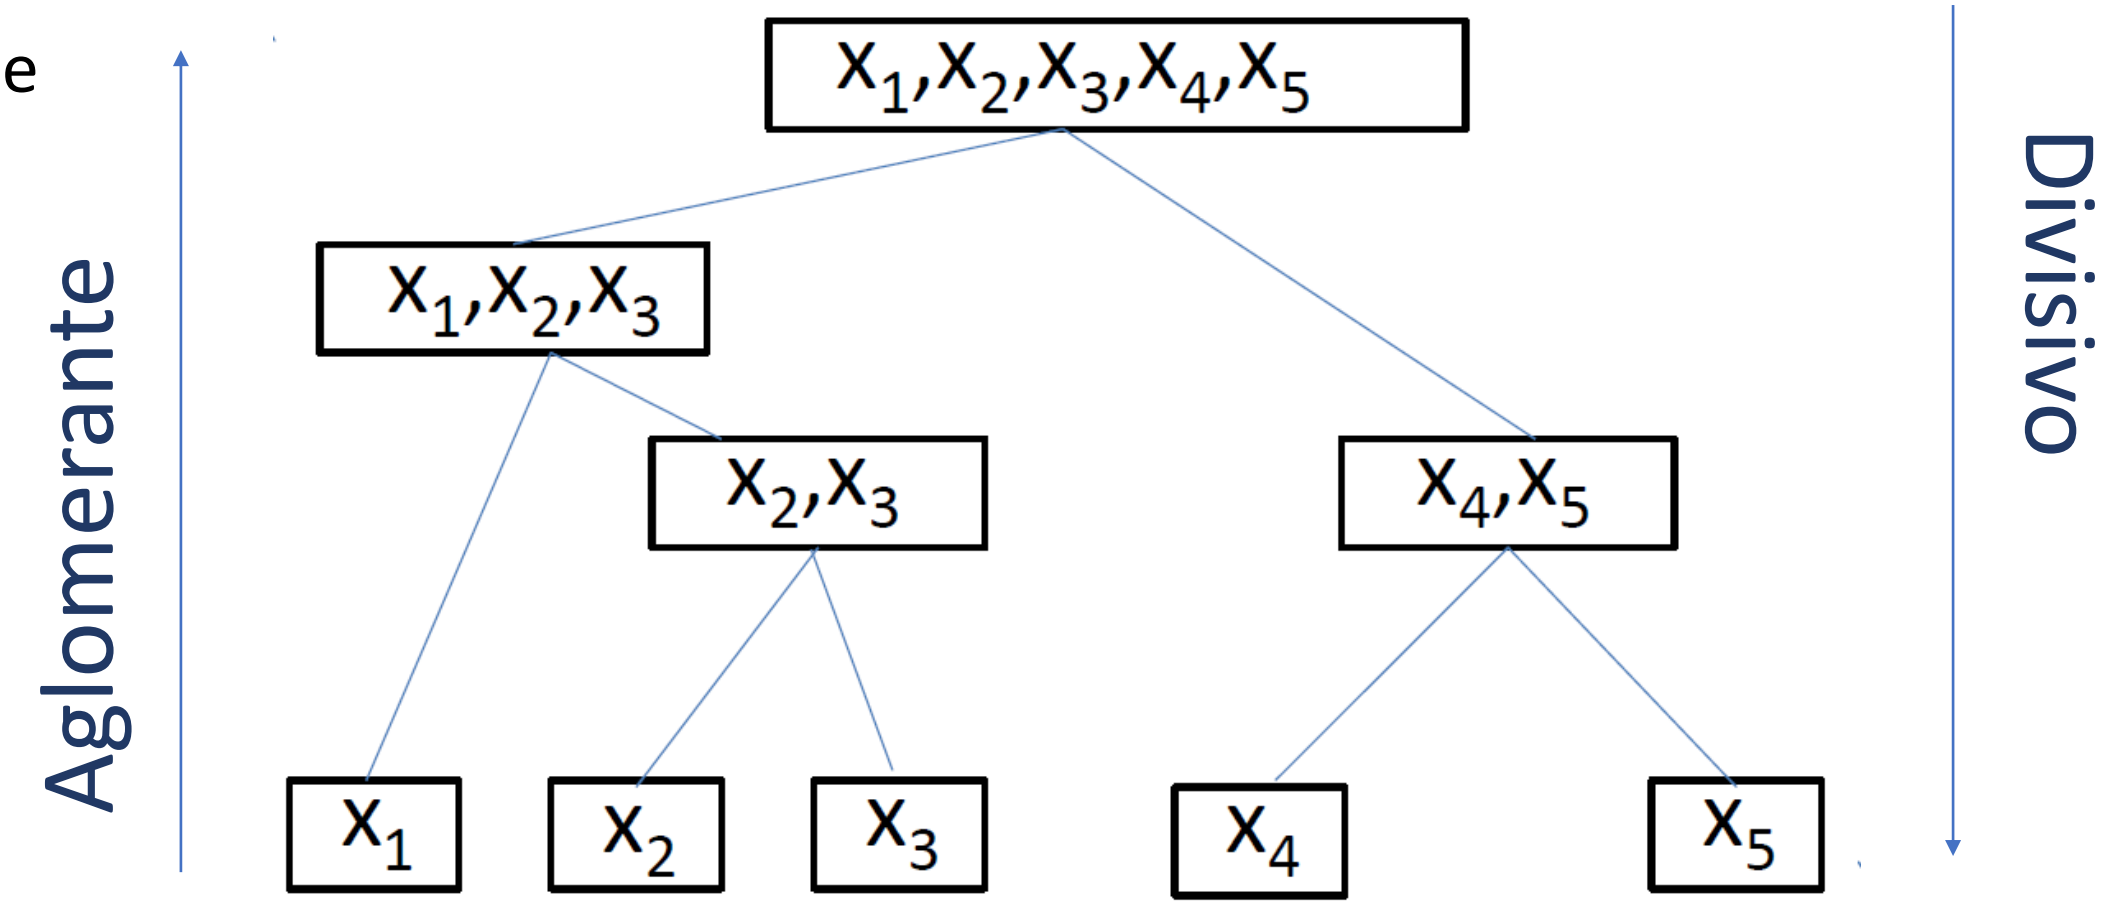
- **n-tree**

Sea $D = \{\vec{x}_1, \vec{x}_2, \cdots, \vec{x}_n\}$ un conjunto de puntos, n-tree sobre D es un conjunto T de subconjuntos de D que satisfacen las siguientes condiciones

1. $D \in T$
2. $\emptyset \in T$
3. $\{\vec{x}_i\} \in T$ para todo $i = 1,2 \cdots, n$
4. Si $A, B \in T$, entonces $A \cap B \in \{\emptyset, A, B\}$

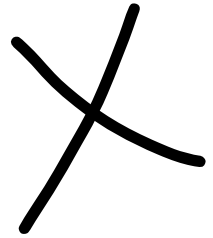
Representación del Clustering Jerárquico (Ejemplo)

5-tree



Representación del Clustering Jerárquico

- **Dendograma**



Es una función c: $[0, \infty] \longrightarrow E(D)^{(*)}$ tal que

$c(h) \subseteq c(h')$ si $h \leq h'$

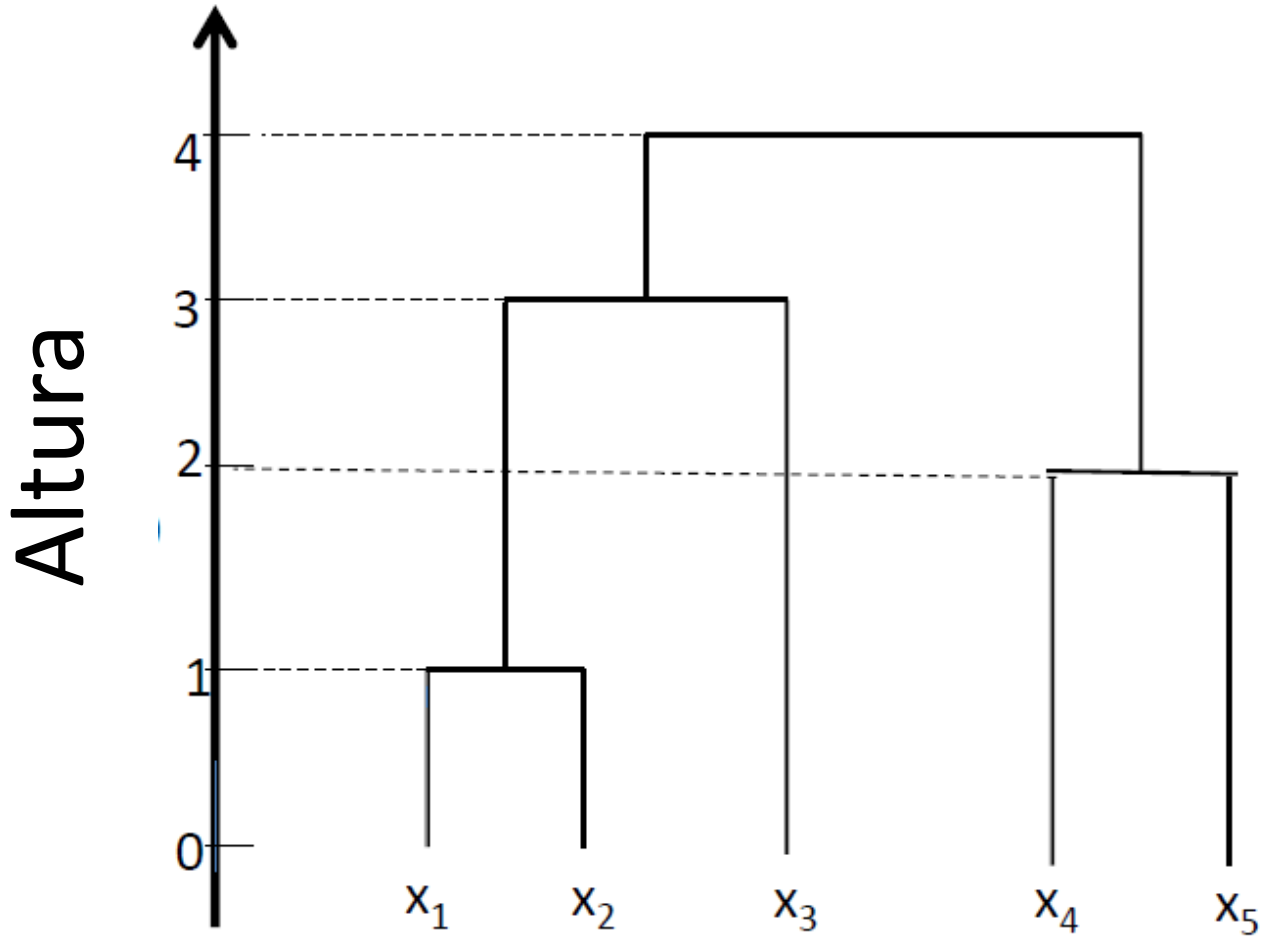
$c(h)$ al final es $D \times D$

$c(h + \delta)$= $c(h)$ para $\delta > 0$ pequeño

$^{(*)}$ $E(D)$ es el conjunto de relaciones de equivalencia sobre D, el conjunto de datos

Representación del Clustering Jerárquico Ejemplo

Dendograma de 5 puntos



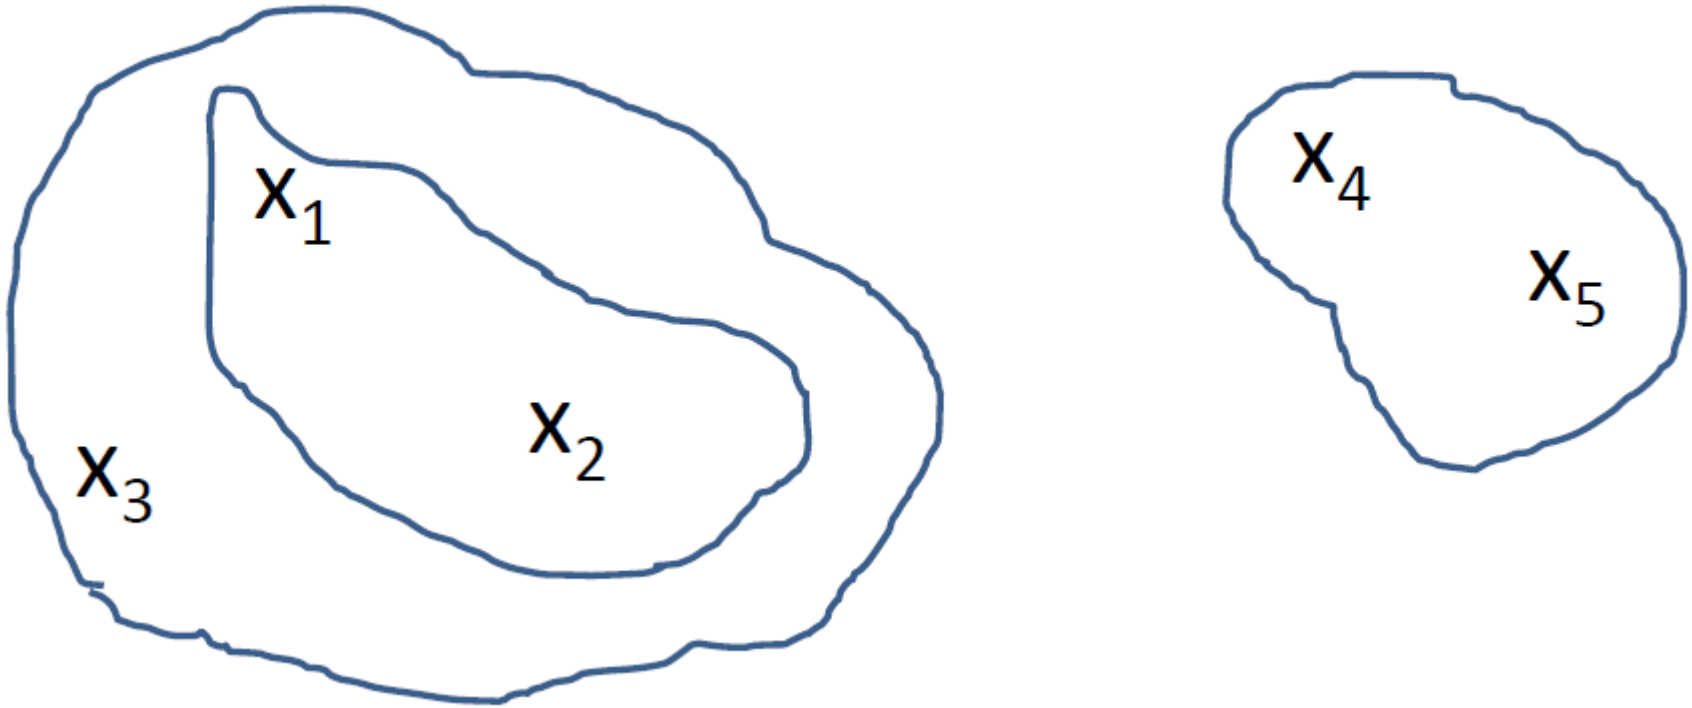
Representación del Clustering Jerárquico Ejemplo

$$C(h)=\begin{cases} \{(i,i): i = 1,2,3,4,5\} & if\ 0 \le h < 1 \\ \{(i,i).i = 3,4,5\} \cup \{(i,j): i,j = 1,2\} & if\ 1 \le h < 2 \\ \{(3,3)\} \cup \{(i,j): i,j = 1,2\} \cup \{(i,j): i = 4,5\} & if\ 2 \le h < 3 \\ \{(i,j): i = 4,5\} \cup \{(i,j): i = 1,2,3\} & if\ 3 \le h < 4 \\ \{(i,j): i = 1,2,34,5\} & if\ 4 \le h \end{cases}$$

---

función que contiene la información del dendograma anterior

Representación del Clustering Jerárquico Ejemplo

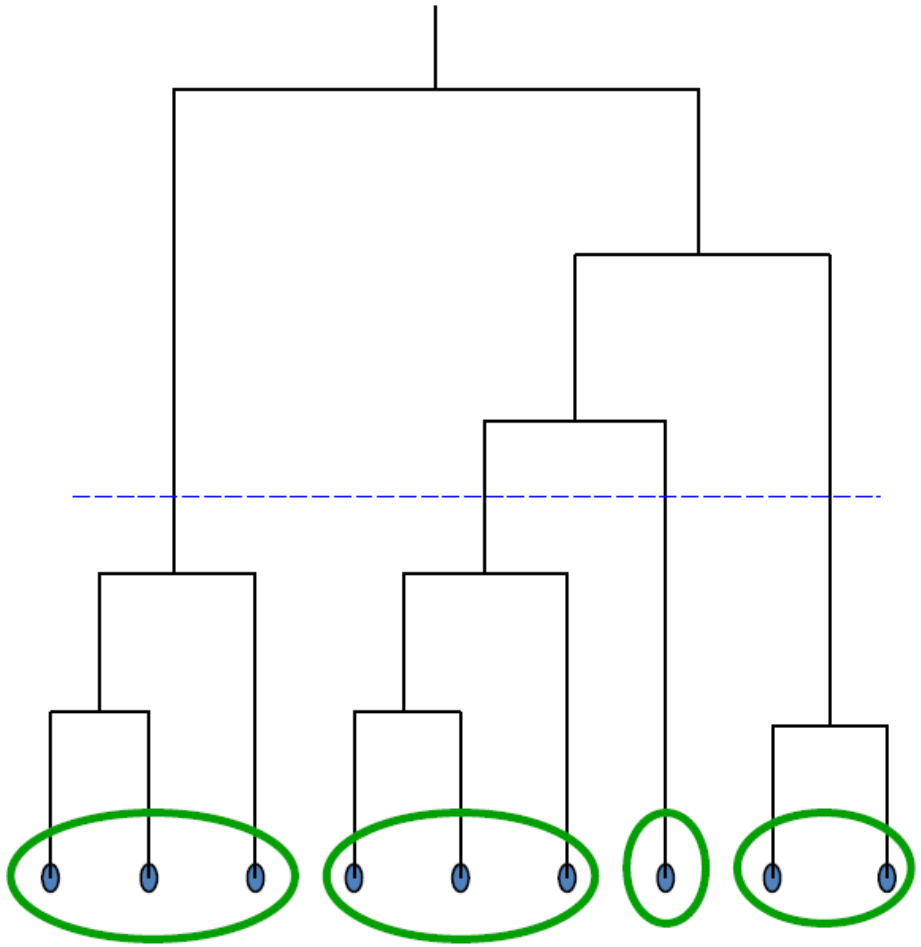


Representación del dendograma anterior

Clustering Jerárquico Aglomerante

- Usa una función de similitud para determinar la similitud entre dos instancias
- Empieza con todas las instancias en clústeres separados se va uniendo repetidamente los dos clústeres más similares hasta que solo haya un clúster
- El historial de unión de los clústeres forma un árbol binario o jerarquía

Clustering Jerárquico Aglomerante



El agrupamiento se obtiene cortando el dendograma a la altura deseada: cada componente conectada forma un grupo

Clustering Jerárquico Aglomerante

Consideremos n puntos de datos.

K=0 ; tenemos n grupos

K=1 ; los dos puntos que son más similares (o menos distantes) por lo que tenemos n-1 grupos

…

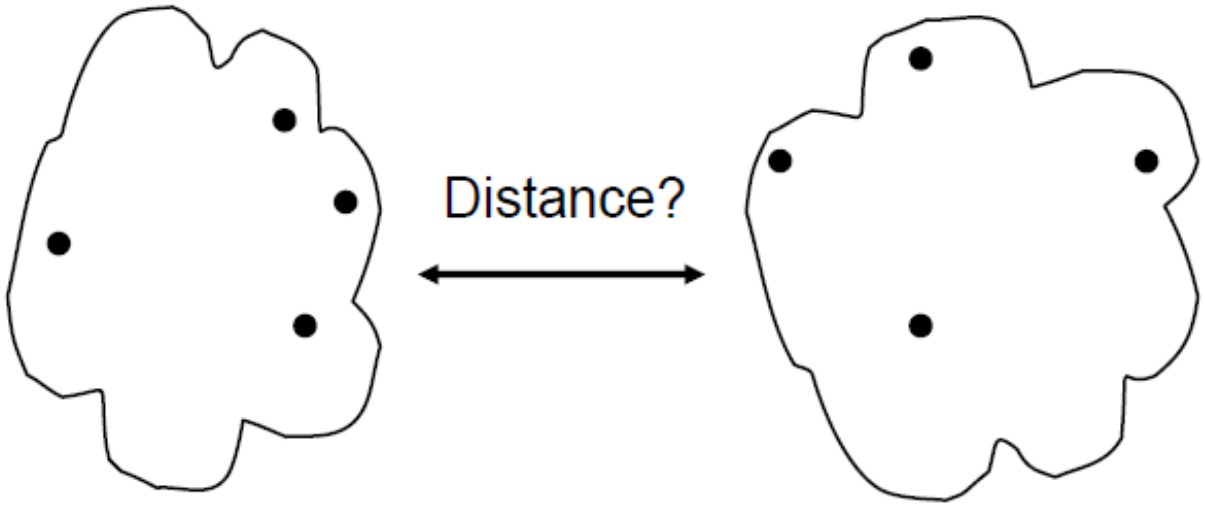
K=L ; los dos puntos (o grupos formados) con máxima similitud o mínima distancia, por lo que tenemos n-L grupos

….

K=n-1 tenemos solo un grupo con todos los puntos de datos

Clustering Jerárquico Aglomerante (par de clústeres más cercanos)

¿Cómo medir la distancia entre clústeres?



La distancia entre grupos generalmente se define en función de la distancia entre los objetos.

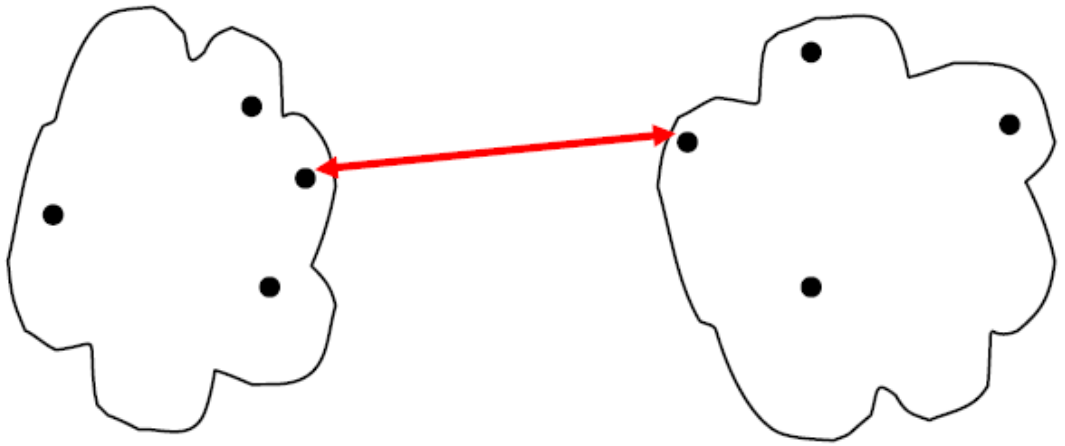
Clustering Jerárquico Aglomerante (par de clústeres más cercanos)

Hay muchas formas de definir *par de clústeres más cercanos*

- **Single-link (enlace simple)**: Distancia de los puntos más *cercanos*
- **Complete-link (enlace completo)**: Distancia entre los puntos más *lejanos*
- **Centroide**: Distancia entre los centroides
- **Average-link (enlace promedio):** Media de la distancia entre todos los pares de puntos

Distancia intergrupal
Single-link (enlace simple)

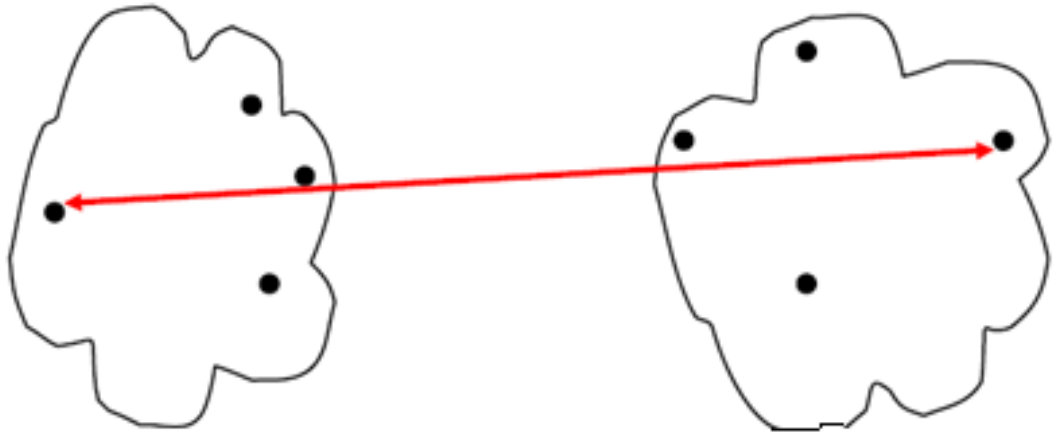
La distancia entre dos grupos se representa por la distancia entre los pares de datos más cúrvanos que pertenezcan a grupos diferentes



$$d_{\min}(C_i, C_j) = \min_{p \in C_i, q \in C_j} d(p, q)$$

Distancia entre grupos
Complete-link (enlace completo)

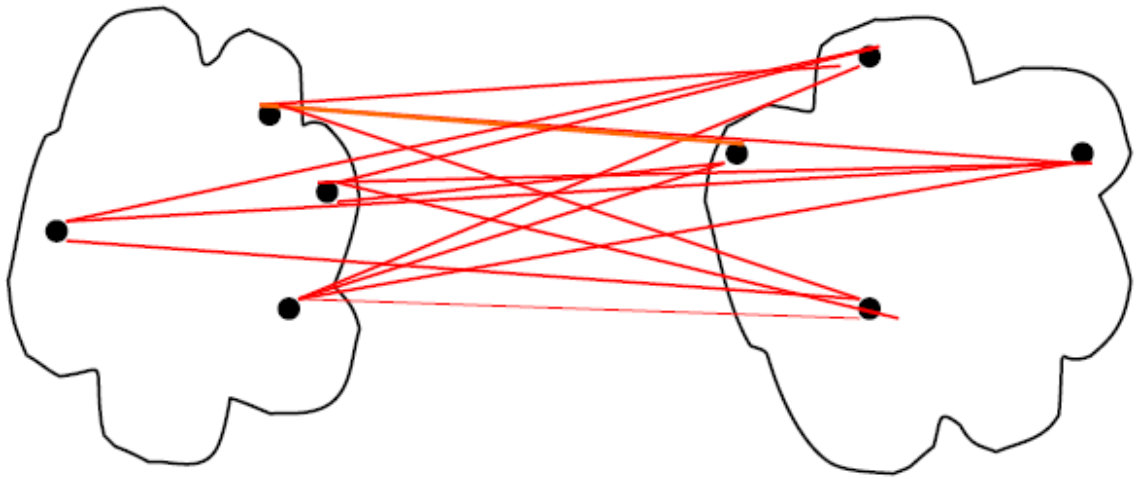
La distancia entre dos grupos se representa por la distancia de los datos más cercanos que pertenecen a diferentes grupos.



$$d_{\min}(C_i, C_j) = \max_{p \in C_i, q \in C_j} d(p, q)$$

Distancia entre grupos
Average-link (enlace promedio)

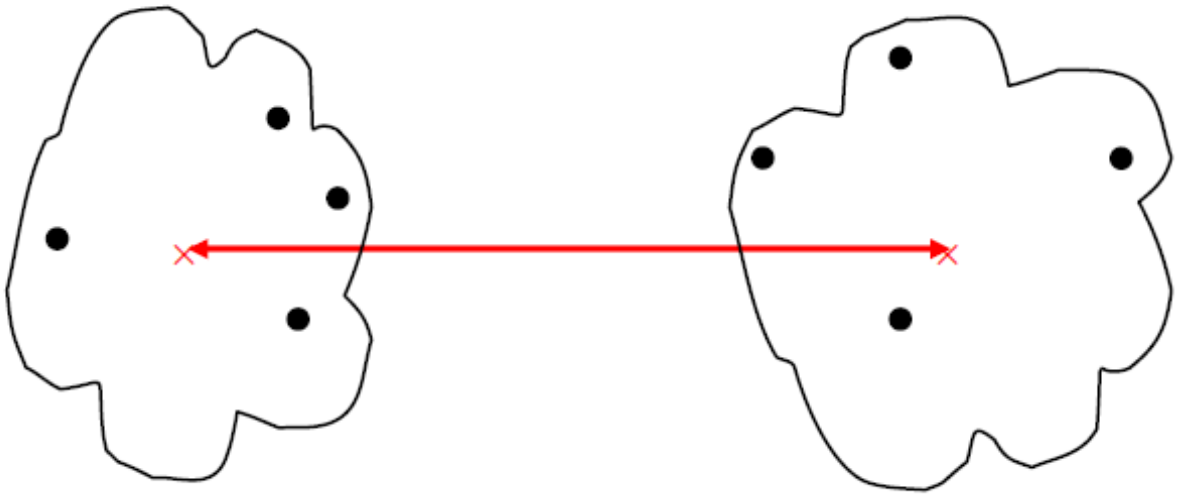
La distancia entre dos grupos se representa por la distancia media de todos los grupos que pertenezcan a grupos diferentes.



$$d_{\min}(C_i, C_j) = \underset{p \in C_i, q \in C_j}{avg} \; d(p,q)$$

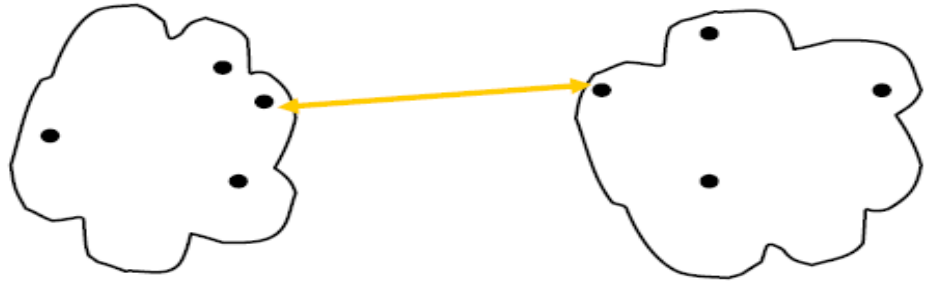
Distancia entre grupos
Centroid-link (enlace promedio)

La distancia entre dos grupos se representa por la distancia entre la media de los grupos.

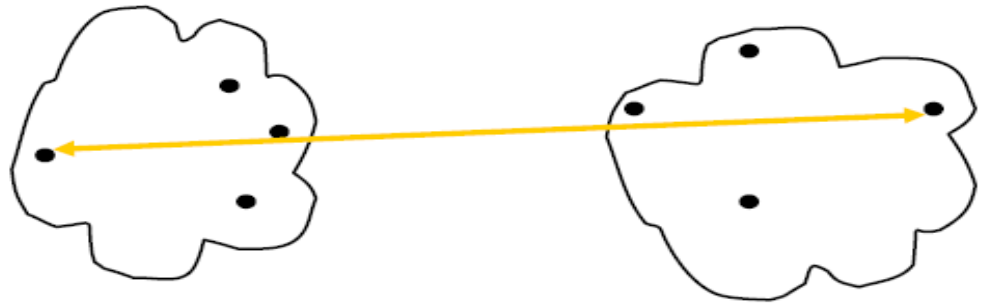


$$d_{\text{media}}(C_i, C_j) = d(m_i, m_j)$$

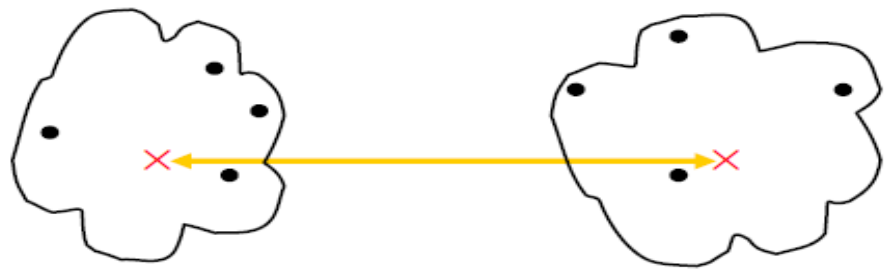
Single-link



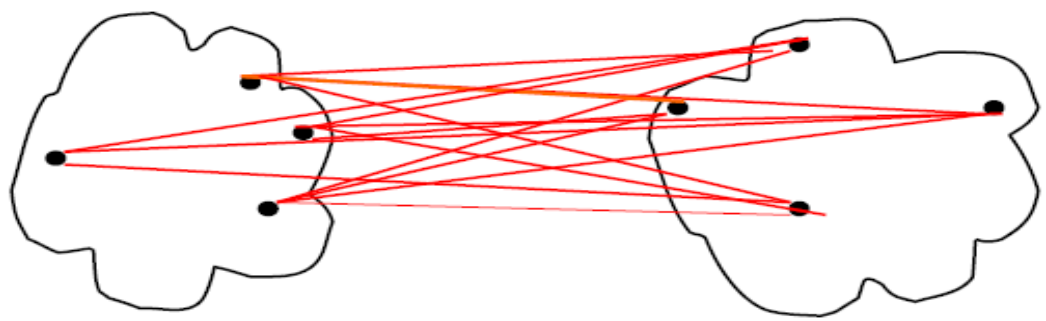
Complete-link



Centroid



Average-link



Distancia entre grupos
Método de Ward

- Este método busca minimizar la pérdida de información asociada cada fusión de grupos.
- La pérdida de información se cuantifica con el criterio del error cuadrático

$ESS(C) = \sum_{\vec{x} \in C}(\vec{x}\text{-}\mu(C))(\vec{x} - \mu(C))^t$ donde

$$\mu(C) = \frac{1}{C}\sum_{\vec{x} \in C} \vec{x}$$

Método de Ward

Supongamos que hay k grupos $C_1, C_2 \cdots, C_k$ en cierto nivel del agrupamiento. Entonces

$$ESS = \sum_{i=1}^{k} ESS(C_i)$$

A cada paso del método de Ward, se considera si la unión de cada par de grupos posible y se unen los dos grupos cuya fusión resulte en el mínimo aumento en la pérdida de información

Clustering jerárquico aglomerante
Single link

- Usa máxima similitud S entre pares de clústeres (o mínima distancia, D)

$$S(C_i, C_j) = \max_{\vec{x}\in C_i, \vec{y}\in C_j} s(\vec{x}, \vec{y}),\ D(C_i, C_j) = \min_{\vec{x}\in C_i, \vec{y}\in C_j} d(\vec{x}, \vec{y})$$

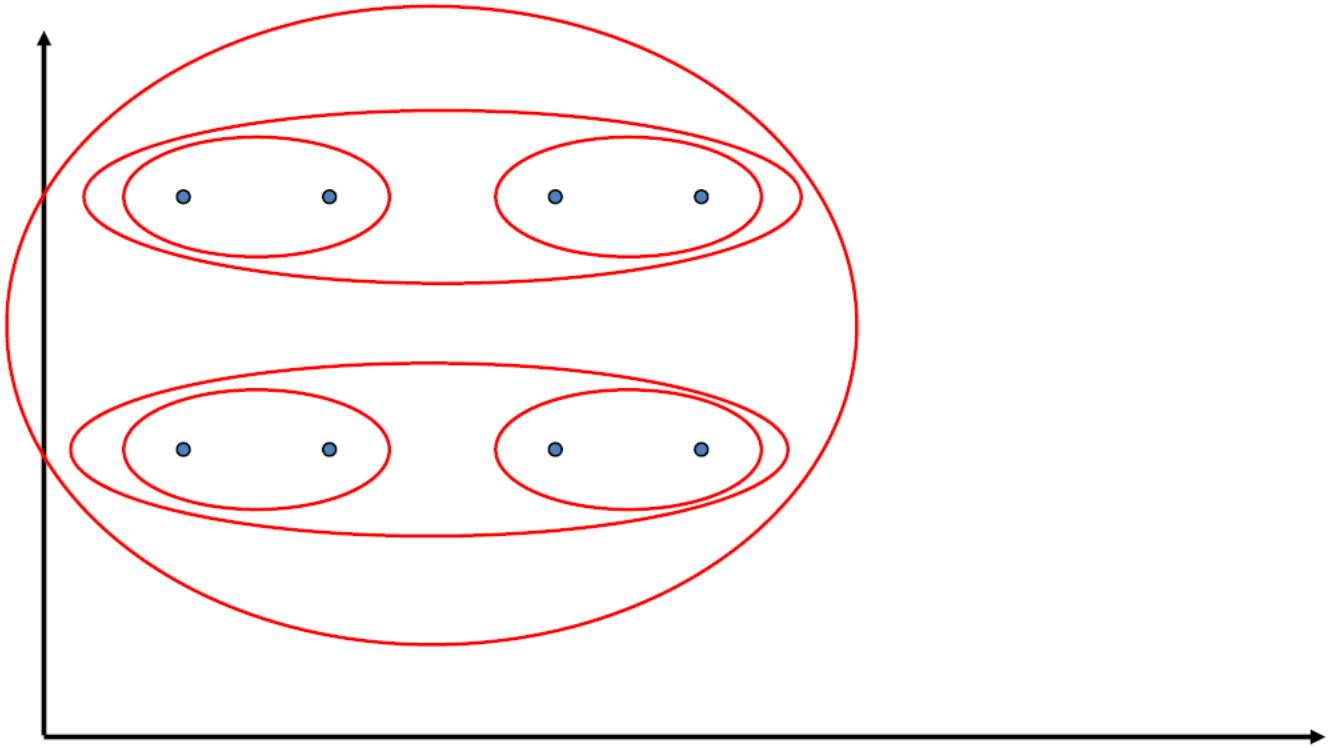
- Puede resultar en grupos alargados, debido al efecto de encadenamiento.
- Después de unir los grupos C_i y C_j , la similitud entre el grupo resultante y otro grupo C_k es

$$S\left(C_i \cup C_j, C_k\right) = \max(S(C_i, C_k), S(C_j, C_k))$$

o bien

$$D\left(C_i \cup C_j, C_k\right) = \min(D(C_i, C_k), D(C_j, C_k))$$

Single link
Ejemplo



Clustering jerárquico aglomerante
Complete link

- Usa máxima similitud S entre dos clústeres (o mínima distancia, D)

$$S(C_i, C_j) = \min_{\vec{x} \in C_i, \vec{y} \in C_j} s(\vec{x}, \vec{y}), D(C_i, C_j) = \max_{\vec{x} \in C_i, \vec{y} \in C_j} d(\vec{x}, \vec{y})$$

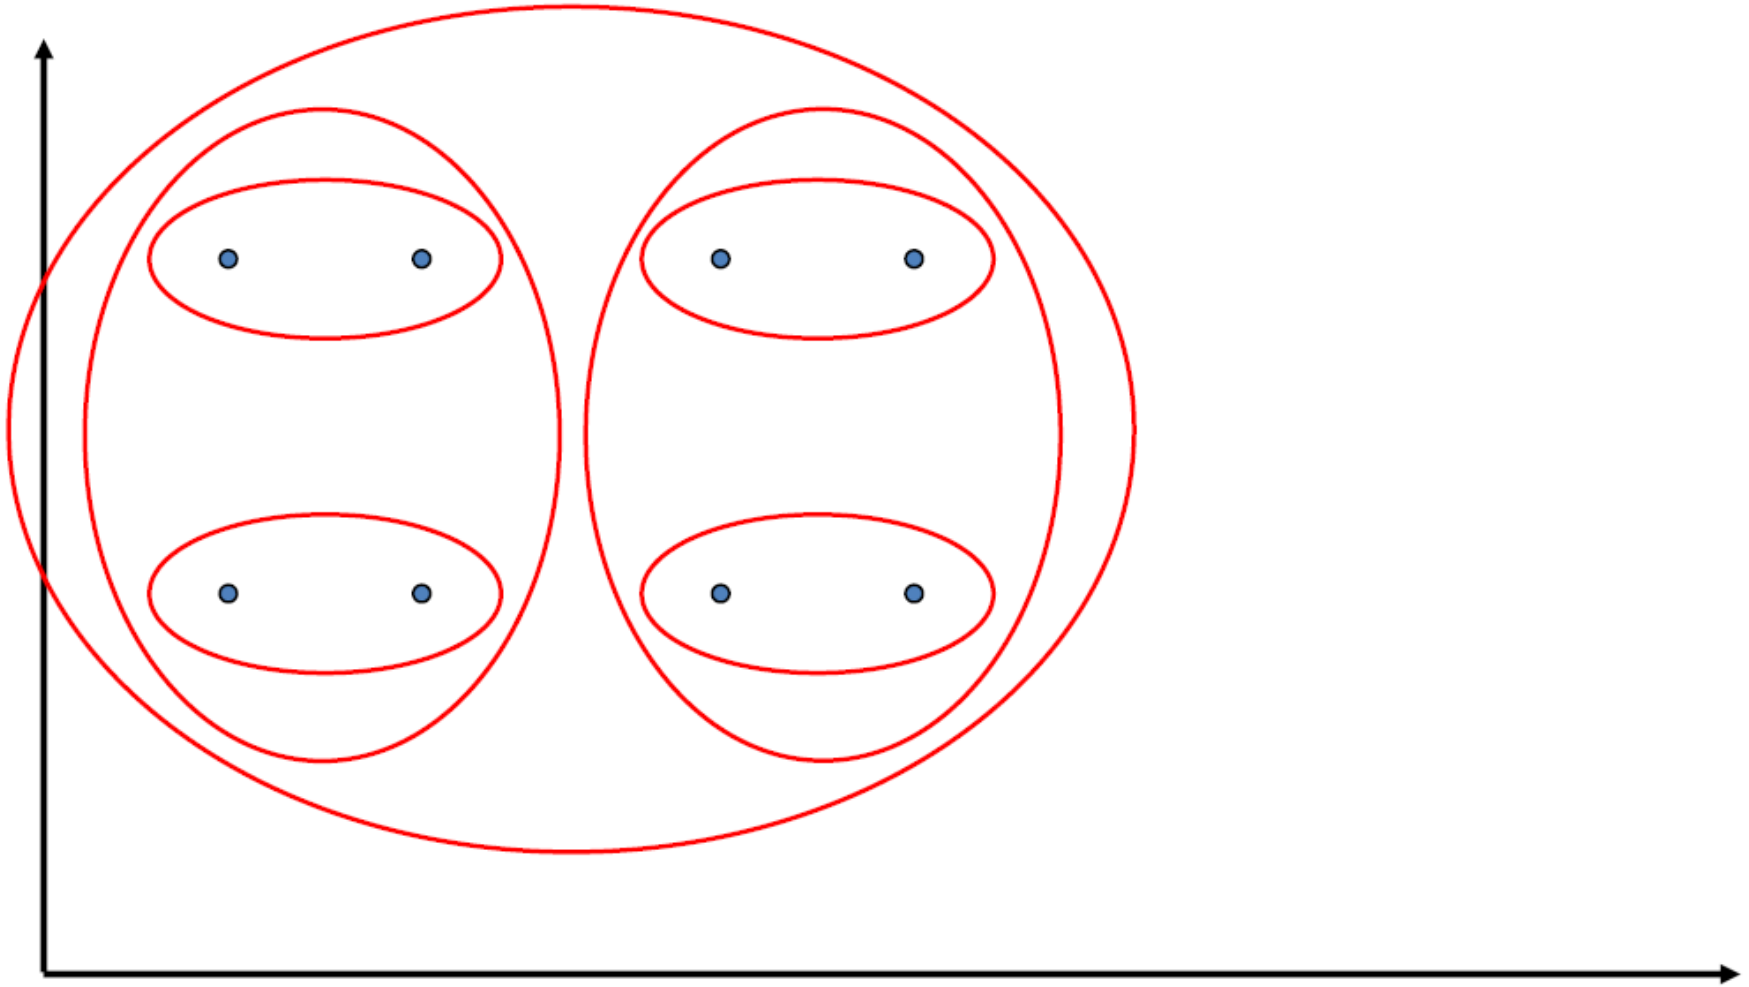
- Puede resultar en grupos más compactos y esféricos
- Después de unir los grupos C_i y C_j , la similitud entre el grupo resultante y otro grupo C_k es

$$S(C_i \cup C_j, C_k) = \min(S(C_i, C_k), S(C_j, C_k))$$

o bien

$$D(C_i \cup C_j, C_k) = \max(D(C_i, C_k), D(C_j, C_k))$$

Complete link
Ejemplo



Clustering jerárquico aglomerante
Average link

- La similitud S (distancia D) entre dos clústeres es igual a la similitud (distancia) media de todos los pares de puntos

$$D(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{\vec{x} \in C_i, \vec{y} \in C_j} d(\vec{x}, \vec{y})$$

y

$$D(C_i \cup C_j, C_k) = \frac{|C_i|}{|C_i|+|C_j|} D(C_i, C_k) + \frac{|C_j|}{|C_i|+|C_j|} D(C_j, C_k)$$

Clustering jerárquico aglomerante
Centroid link

- La similitud S (distancia D) entre dos clústeres es igual a la similitud (distancia) de sus centroides

$$D(C_i, C_j) = \frac{1}{|C_i||C_j|}\sum_{\vec{x}\in C_i,\vec{y}\in C_j} d(\vec{x},\vec{y}) - \frac{1}{2|C_i|^2}\sum_{\vec{x},\vec{y}\in C_i} d(\vec{x},\vec{y}) - - \frac{1}{2|C_j|^2}\sum_{\vec{x},\vec{y}\in C_j} d(\vec{x},\vec{y})$$

y

$$D\left(C_i \cup C_j, C_k\right) = \frac{|C_i|}{|C_i|+|C_j|} D(C_i, C_k) + \frac{|C_j|}{|C_i|+|C_j|} D\left(C_j, C_k\right) - \frac{|C_i||C_j|}{\left(|C_i|+|C_j|\right)^2} D(C_j, C_i)$$

Ejemplo:
Clustering Jerárquico aglomerante simple

- Dada la matriz de distancia inicial para 7 individuos

	A	B	C	D	E	F	G
A	0						
B	2,15	0					
C	0,7	1,53	0				
D	1,07	1,14	0,43	0			
E	0,85	1,38	0,21	0,29	0		
F	1,16	1,01	0,55	0,22	0,41	0	
G	1,56	2,83	1,86	2,04	2,02	2,05	0

- Nivel K=1

$Min\{d(C_i, C_j)\} = d(C, E) = 0.21,$

por lo que el primer clúster que se forma es (C, E).

- Nivel K=2

La matriz de distancia pasa a ser

	A	B	(C,E)	D	F	G
A	0					
B	2,15	0				
(C,E)	0,7	1,38	0			
D	1,07	1,14	0,29	0		
F	1,16	1,01	0,41	0,22	0	
G	1,56	2,83	1,86	2,04	2,05	0

Y aquí $Min\{d(C_i, C_j)\} = d(D, F) = 0.22$ por lo que se forma el cluster (D, F).

- Nivel K=3

Ahora la matriz de distancias es

	A	**B**	**(C,E)**	**(D,F)**	**G**
A	0				
B	2,15	0			
(C,E)	0,7	1,38	0		
(D,F)	1,07	1,01	0,29	0	
G	1,56	2,83	1,86	2,04	0

Y aquí $Min\{d(C_i, C_j)\} = d((C, E), (D, F)) = 0.29$ por lo que se forma el cluster ((C,E),(D, F)).

- Nivel K=4

Ahora la matriz de distancias es

	A	**B**	**((C,E),(D,F))**	**G**
A	0			
B	2,15	0		
((C,E),(D,F))	0,7	1,01	0	
G	1,56	2,83	1,86	0

Y aquí $Min\{d(C_i, C_j)\} = d(A,((C,E),(D,F))) = 0.7$ por lo que se forma el cluster (A,(C,E),(D, F)).

- Nivel K=5

Ahora la matriz de distancias es

	(A,((C,E),(D,F)))	**B**	**G**
(A,((C,E),(D,F)))	0		
B	1,01	0	
G	1,56	2,83	0

Y aquí $Min\{d(C_i, C_j)\} = d(B, \{A, (C, E), (D, F)\}) = 1.01$ por lo que se forma el clúster (B,A,(C,E),(D, F).

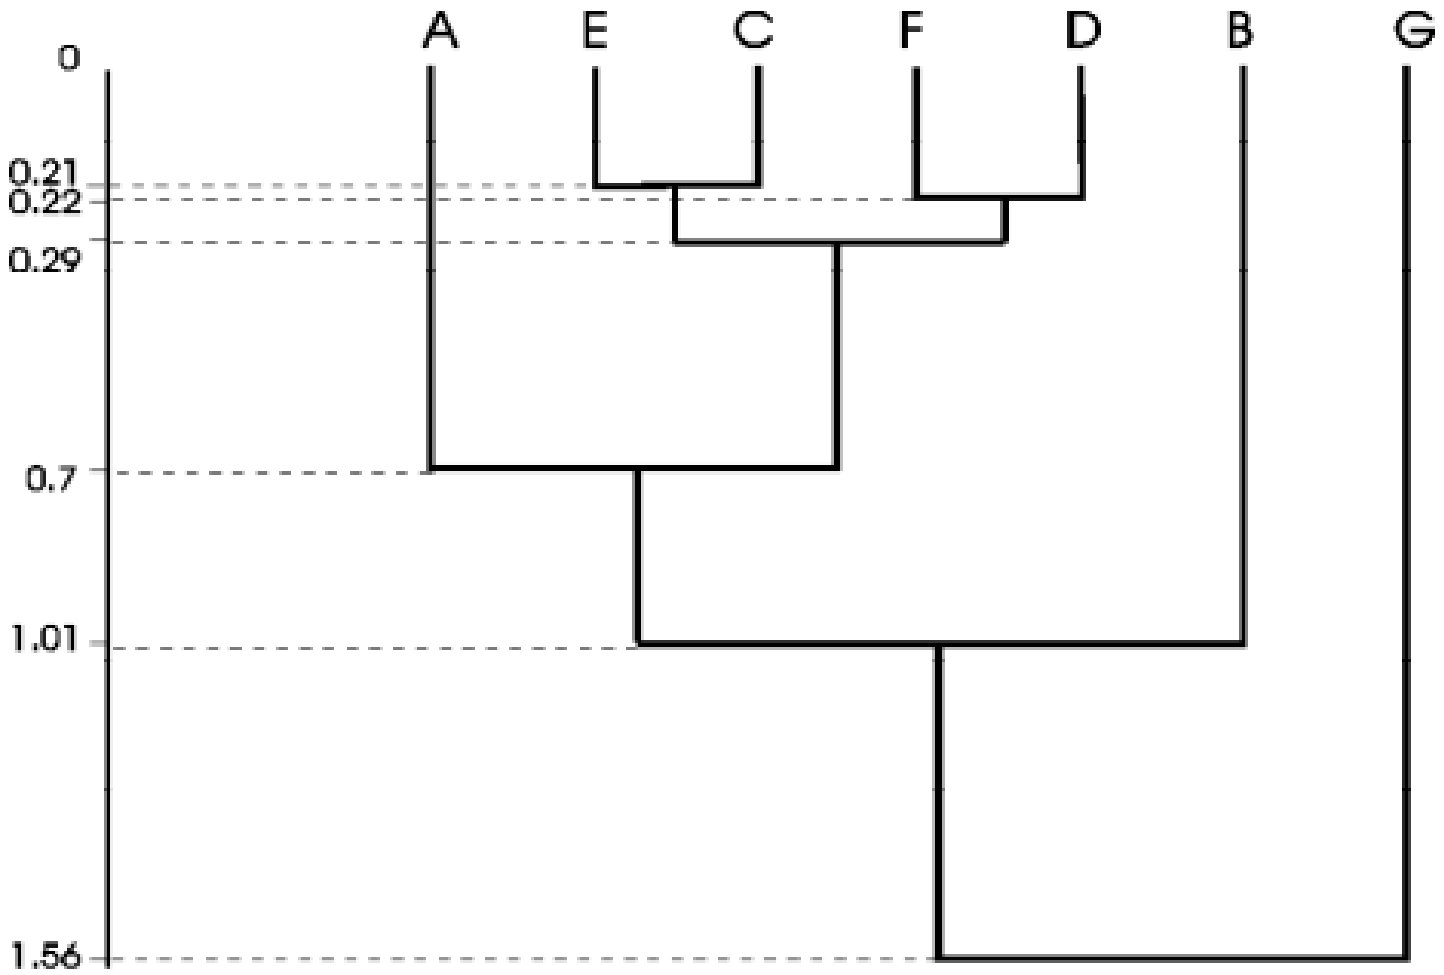
- Nivel K=6

Ahora la matriz de distancias es

	(B,(A,((C,E),(D,F))))	G
(B,(A,((C,E),(D,F))))	0	
G	1,56	0

Este será el último paso, en el cual, evidentemente, se tendrá un único clúster formado por los 7 individuos.

Método del aglomeramiento simple



Ejemplo:
Clustering Jerárquico aglomerante completo

- Dada la matriz de distancia inicial para 7 individuos

	A	B	C	D	E	F	G
A	0						
B	2,15	0					
C	0,7	1,53	0				
D	1,07	1,14	0,43	0			
E	0,85	1,38	0,21	0,29	0		
F	1,16	1,01	0,55	0,22	0,41	0	
G	1,56	2,83	1,86	2,04	2,02	2,05	0

- Nivel K=1

$Min\{d(C_i, C_j)\} = d(C, E) = 0.21,$

por lo que el primer clúster que se forma es (C, E).

- Nivel K=2

La matriz de distancia pasa a ser

	A	B	(C,E)	D	F	G
A	0					
B	2,15	0				
(C,E)	0,85	1,53	0			
D	1,07	1,14	0,43	0		
F	1,16	1,01	0,55	0,22	0	
G	1,56	2,83	2,02	2,04	2,05	0

Y aquí $Min\{d(C_i, C_j)\} = d(D, F) = 0.22$ por lo que se forma el cluster (D, F).

- Nivel K=3

Ahora la matriz de distancias es

	A	**B**	**(C,E)**	**(D,F)**	**G**
A	0				
B	2,15	0			
(C,E)	0,85	1,53	0		
(D,F)	1,16	1,14	0,55	0	
G	1,56	2,83	2,02	2,05	0

Y aquí $Min\{d(C_i, C_j)\} = d((C, E), (D, F)) = 0.55$ por lo que se forma el cluster ((C,E),(D, F)).

- Nivel K=4

Ahora la matriz de distancias es

	A	B	((C,E),(D,F))	G
A	0			
B	2,15	0		
((C,E),(D,F))	1,16	1,53	0	
G	1,56	2,83	2,05	0

Y aquí $Min\{d(C_i, C_j)\} = d(A,(C,E),(D,F))) = 1.16$ por lo que se forma el cluster (A,(C,E),(D, F)).

- Nivel K=5

Ahora la matriz de distancias es

	(A,((C,E),(D,F)))	**B**	**G**
(A,((C,E),(D,F)))	0		
B	2,15	0	
G	2,05	2,83	0

Y aquí $Min\{d(C_i, C_j)\} = d(G, \{A, (C, E), (D, F)\}) = 2.05$ por lo que se forma el clúster (G,A,(C,E),(D, F).

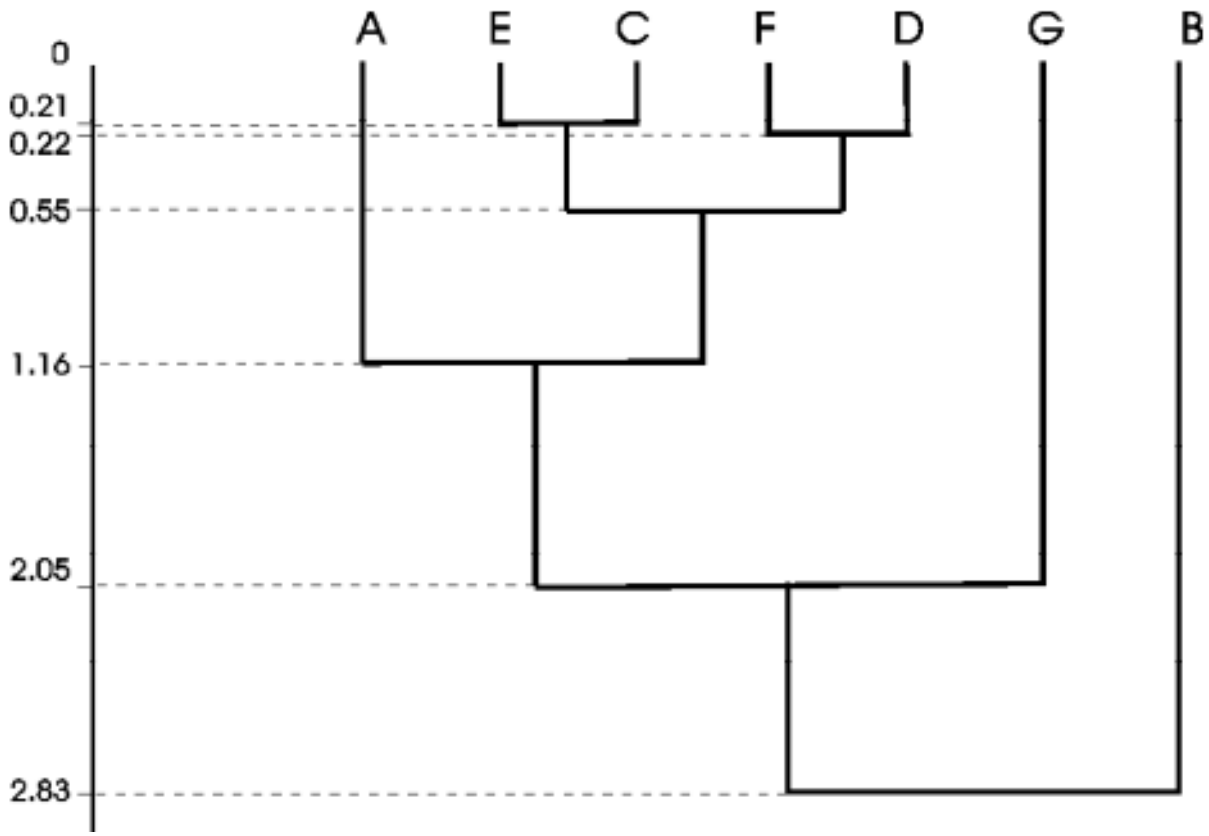
- Nivel K=6

Ahora la matriz de distancias es

	(G,(A,((C,E),(D,F))))	B
(G,(A,((C,E),(D,F))))	0	
B	2,83	0

Este será el último paso, en el cual, evidentemente, se tendrá un único clúster formado por los 7 individuos.

Método del aglomeramiento completo



Ejemplo:
Clustering Jerárquico aglomerante promedio

- Dada la matriz de distancia inicial para 7 individuos

	A	B	C	D	E	F	G
A	0						
B	2,15	0					
C	0,7	1,53	0				
D	1,07	1,14	0,43	0			
E	0,85	1,38	0,21	0,29	0		
F	1,16	1,01	0,55	0,22	0,41	0	
G	1,56	2,83	1,86	2,04	2,02	2,05	0

- Nivel K=1

$Min\{d(C_i, C_j)\} = d(C, E) = 0.21,$

por lo que el primer clúster que se forma es (C, E).

- Nivel K=2

La matriz de distancia pasa a ser

	A	**B**	**(C,E)**	**D**	**F**	**G**
A	0					
B	2,15	0				
(C,E)	0,775	1,455	0			
D	1,07	1,14	0,36	0		
F	1,16	1,01	0,48	0,22	0	
G	1,56	2,83	1,94	2,04	2,05	0

Y aquí $Min\{d(C_i, C_j)\} = d(D, F) = 0.22$ por lo que se forma el cluster (D, F).

- Nivel K=3

Ahora la matriz de distancias es

	A	**B**	**(C,E)**	**(D,F)**	**G**
A	0				
B	2,15	0			
(C,E)	0,775	1,455	0		
(D,F)	1,115	1,075	0,42	0	
G	1,56	2,83	1,94	2,045	0

Y aquí $Min\{d(C_i, C_j)\} = d((C, E), (D, F)) = 0.42$ por lo que se forma el clúster ((C,E),(D, F)).

- Nivel K=4

Ahora la matriz de distancias es

	A	**B**	**((C,E),(D,F))**	**G**
A	0			
B	2,15	0		
((C,E),(D,F))	0,945	1,265	0	
G	1,56	2,83	1,9925	0

Y aquí $Min\{d(C_i, C_j)\} = d(A,((C,E),(D,F))) = 0.945$ por lo que se forma el clúster (A,(C,E),(D, F)).

- Nivel K=5

Ahora la matriz de distancias es

	(A,((C,E),(D,F)))	**B**	**G**
(A,((C,E),(D,F)))	0		
B	1,7075	0	
G	1,77625	2,83	0

Y aquí $Min\{d(C_i, C_j)\} = d(B, \{A, (C, E), (D, F)\}) = 1.7075$ por lo que se forma el clúster (B,A,(C,E),(D, F).

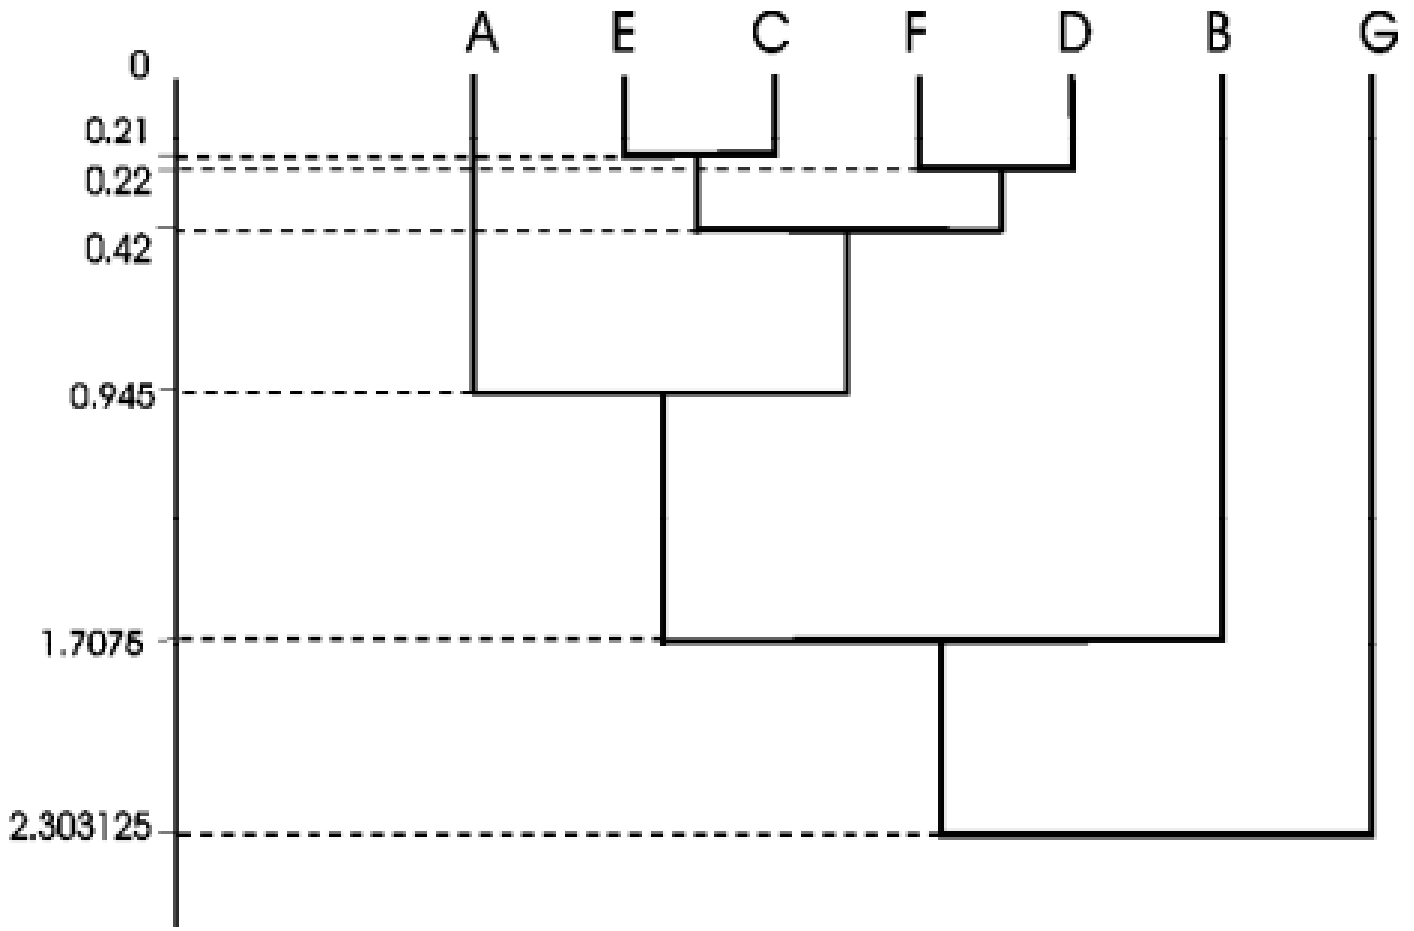
- Nivel K=6

Ahora la matriz de distancias es

	(B,(A,((C,E),(D,F))))	G
(B,(A,((C,E),(D,F))))	0	
G	2,303125	0

Este será el último paso, en el cual, evidentemente, se tendrá un único clúster formado por los 7 individuos.

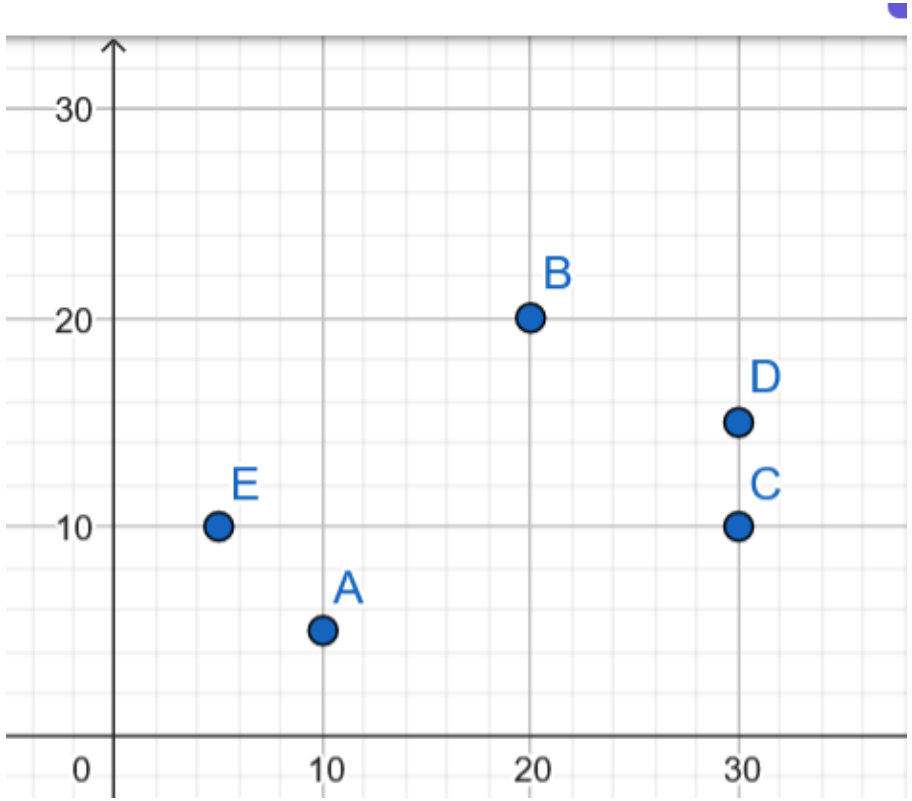
Método del aglomeramiento promedio



Ejemplo:
Clustering Jerárquico aglomerante centroide

- Consideremos los siguientes individuos sobre los cuales se han medido dos variables y apliquemos el método del centroide

Individuo	X_1	X_2
A	10	5
B	20	20
C	30	10
D	30	15
E	5	10



- Nivel K=1

Matriz de distancias euclídea al cuadrado

	A	B	C	D	E
A	0				
B	325	0			
C	425	200	0		
D	500	125	25	0	
E	50	325	625	650	0

Se unen los puntos C y D y el centroide del clúster (C,D) es (30,12.5)

- Nivel K=2

Matriz de distancias euclídea al cuadrado

	A	B	(C,D)	E
A	0			
B	325	0		
(C,D)	456,25	156,25	0	
E	50	325	631,25	0

Se unen los puntos A y E y el centroide del clúster (A,E) es (7.5,7.5)

- Nivel K=3

Matriz de distancias euclídea al cuadrado

	(A,E)	B	(C,D)
(A,E)	0		
B	312,5	0	
(C,D)	531,25	156,25	0

Se unen los clusters (A,E) y B y el centroide del clúster {(A,E),B} es (26.66,15)

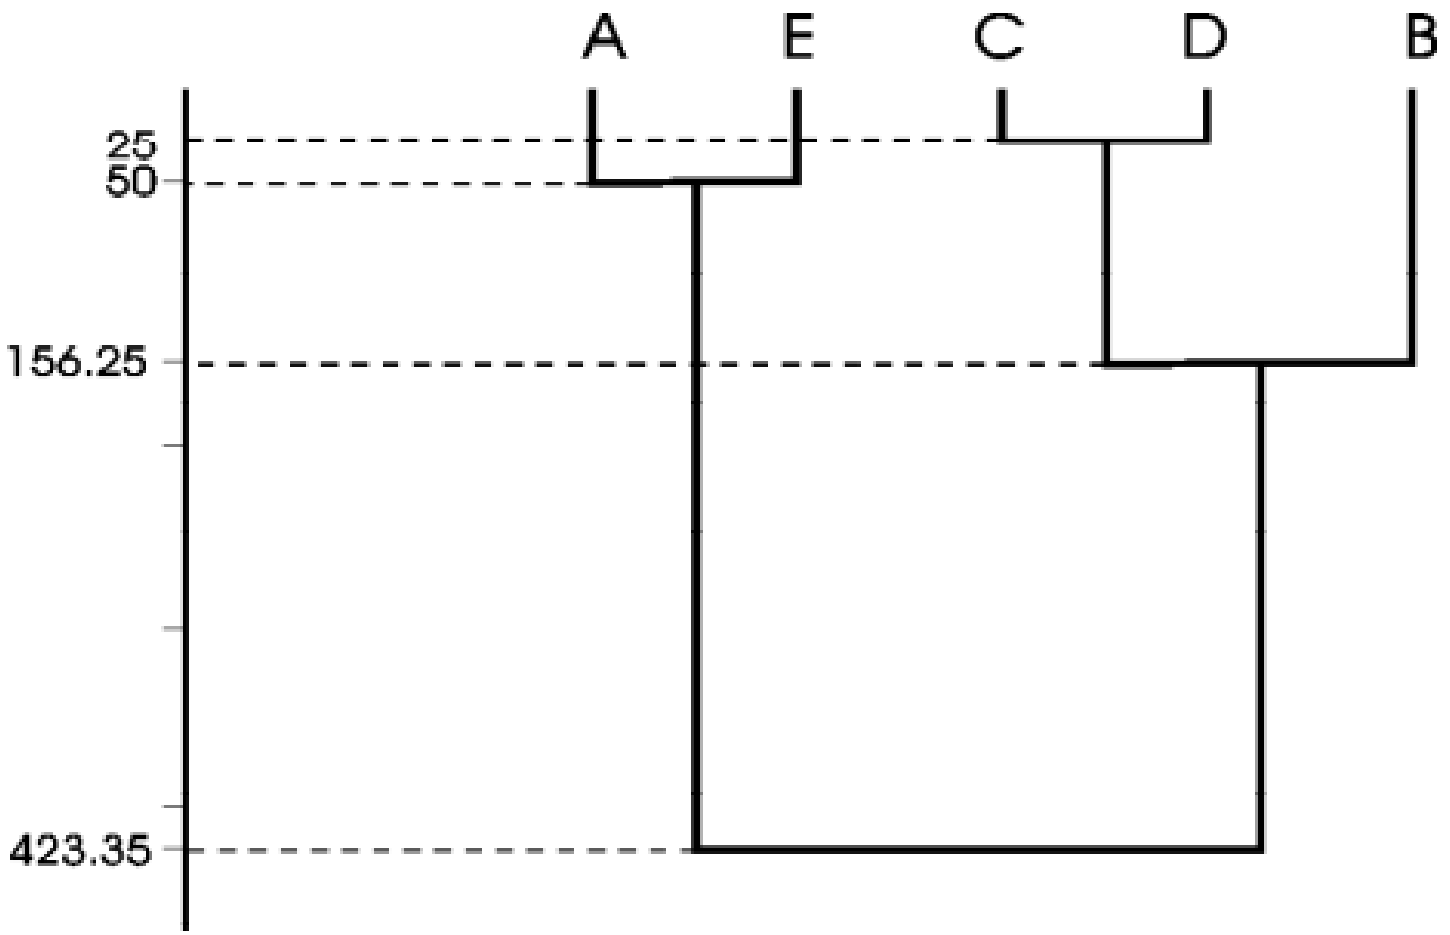
- Nivel K=4

Matriz de distancias euclídea al cuadrado

	(A,E)	(B,C,D)
(A,E)	0	
(B,C,D)	423,35	0

Completándose la jerarquía y el centroide del clúster es (19,12)

Método del centroide



Ejemplo:
Método de Ward

- Consideremos los individuos del ejemplo anterior

$Individuo$	X_1	X_2
A	10	5
B	20	20
C	30	10
D	30	15
E	5	10

- Nivel 1

En este primer paso se calculan las $\binom{5}{2}$=10 combinaciones

Partición	*Centroides*	E_k	E	ΔE
$(A,B),C,D,E$	$C_{AB}=(15,12{,}5)$	$E_{AB}=162{,}5$ $E_C=E_D=E_E=0$	162,5	162,5
$(A,C),B,D,E$	$C_{AC}=(20,7{,}5)$	$E_{AC}=212{,}5$ $E_B=E_D=E_E=0$	212,5	212,5
$(A,D),B,C,E$	$C_{AD}=(20,10)$	$E_{AD}=250$ $E_B=E_C=E_E=0$	250	250
$(A,E),B,C,D$	$C_{AE}=(7{,}5,7{,}5)$	$E_{AE}=25$ $E_B=E_C=E_D=0$	25	25
$(B,C),A,D,E$	$C_{BC}=(25,15)$	$E_{BC}=100$ $E_A=E_D=E_E=0$	100	100
$(B,D),A,C,E$	$C_{BD}=(25,17{,}5)$	$E_{BD}=62{,}5$ $E_A=E_C=E_E=0$	62,5	62,5
$(B,E),A,C,D$	$C_{BE}=(12{,}5,15)$	$E_{BE}=162{,}5$ $E_A=E_C=E_D=0$	162,5	162,5
$(C,D),A,B,E$	$C_{CD}=(30,12{,}5)$	$E_{CD}=12{,}5$ $E_A=E_B=E_E=0$	12,5	12,5
$(C,E),A,B,D$	$C_{CE}=(17{,}5;10)$	$E_{CE}=312{,}5$ $E_A=E_B=E_D=0$	312,5	312,5
$(D,E),A,B,C$	$C_{DE}=(17{,}5;12{,}5)$	$E_{DE}=325$ $E_A=E_B=E_C=0$	325	325

En esta etapa se unen los elementos C y D.

La configuración actual es (C, D), A, B, E

- Nivel 2

En este paso se calculan $\binom{4}{2}$=6 combinaciones

Partición	*Centroides*	E_k	E	ΔE
$(A,C,D),B,E$	$C_{ACD}=(23{,}33,10)$	$E_{ACD}=316{,}66$ $E_B=E_E=0$	316,66	304,16
$(B,C,D),A,E$	$C_{BCD}=(26{,}66,15)$	$E_{BCD}=116{,}66$ $E_A=E_E=0$	116,66	104,16
$(C,D,E),A,B$	$C_{CDE}=(21{,}66,11{,}66)$	$E_{CDE}=433{,}33$ $E_A=E_B=0$	433,33	420,83
$(A,B),(C,D),E$	$C_{AB}=(15,12{,}5)$ $C_{CD}=(30,12{,}5)$	$E_{AB}=162{,}5$ $E_{CD}=12{,}5$ $E_E=0$	175	162,5
$(A,E),(C,D),B$	$C_{AE}=(7{,}5,7{,}5)$ $C_{CD}=(30,12{,}5)$	$E_{AE}=25$ $E_{CD}=12{,}5$ $E_B=0$	37,5	25
$(B,E),(C,D),A$	$C_{BE}=(12{,}5,15)$ $C_{CD}=(30,12{,}5)$	$E_{BE}=162{,}5$ $E_{CD}=12{,}5$ $E_A=0$	175	162,5

En esta etapa se unen los elementos A y E.

La configuración actual es (C, D), (A,E), B

- Nivel 3

En este paso se calculan

$\binom{3}{2}$=3 combinaciones

Partición	*Centroides*	E_k	E	ΔE
$(A, C, D, E), B$	$C_{ACDE} = (18{,}75, 10)$	$E_{ACDE} = 568{,}75$ $E_B = 0$	568,75	531,25
$(A, B, E), (C, D)$	$C_{ABE} = (11{,}66, 11{,}66)$ $C_{CD} = (30, 12{,}5)$	$E_{ABE} = 233{,}33$ $E_{CD} = 12{,}5$	245,8	208,3
$(A, E), (B, C, D)$	$C_{AE} = (7{,}5, 7{,}5)$ $C_{BCD} = (26{,}66, 15)$	$E_{AE} = 25$ $E_{BCD} = 116{,}66$	141,66	104,16

En esta etapa se unen los elementos B y (C,D).

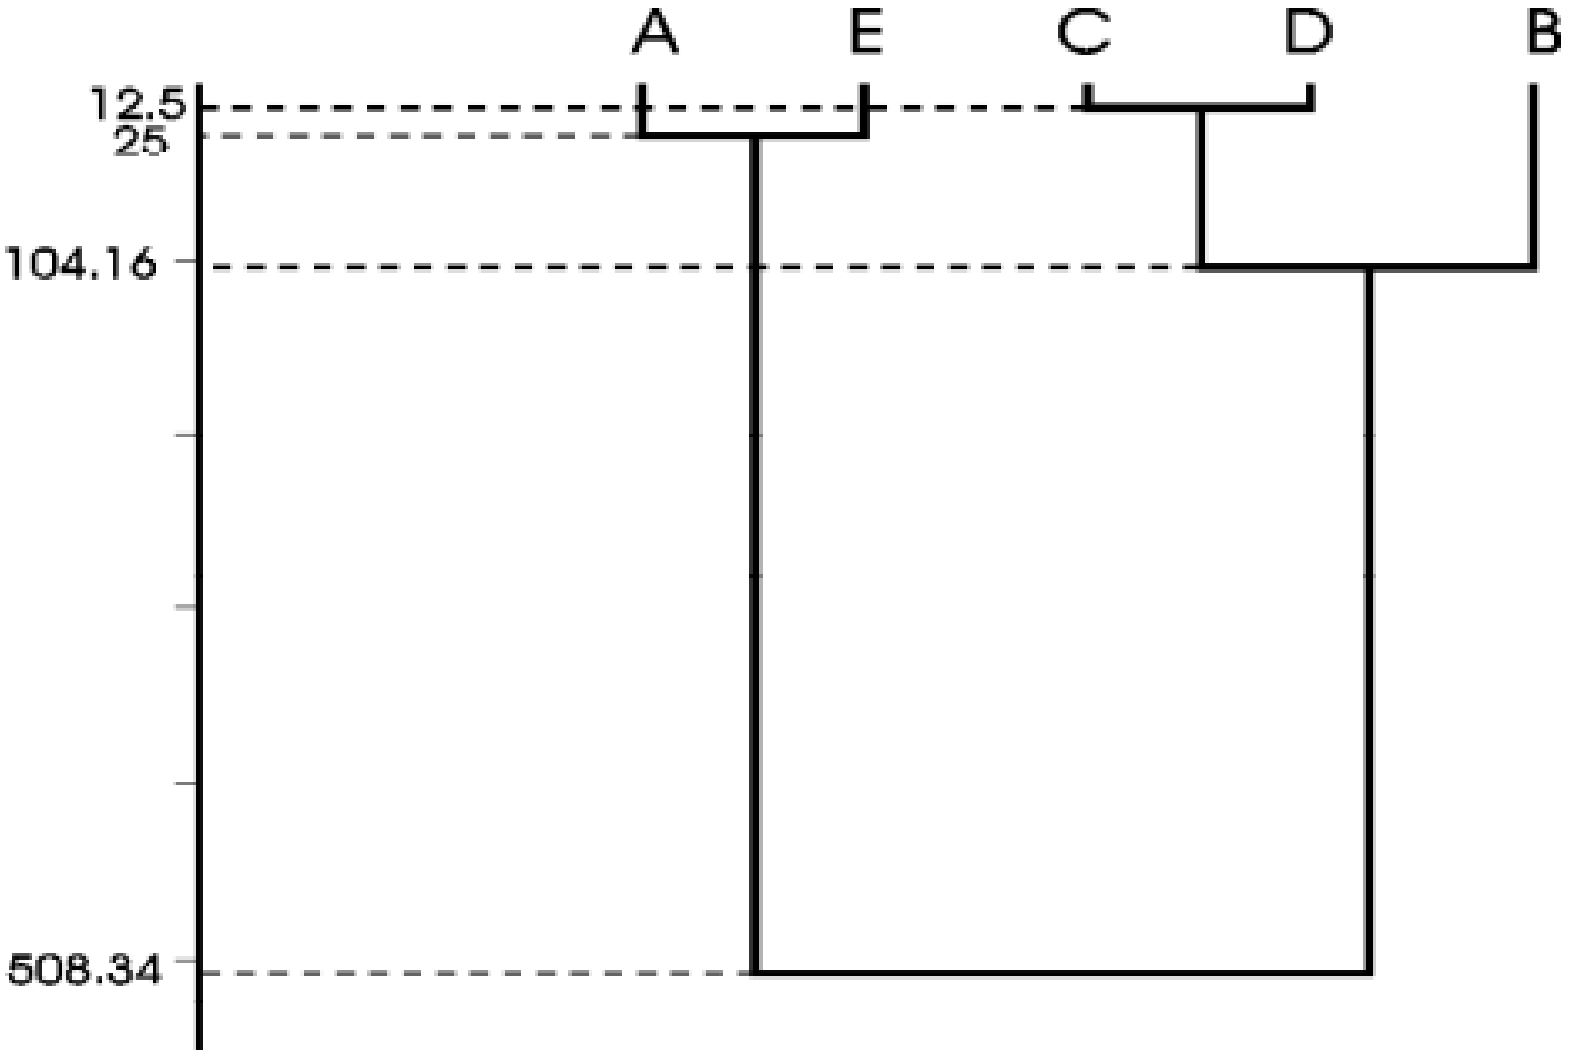
La configuración actual es (B, C, D), (A, E)

- Nivel 4

En este paso se unirán los dos clústeres existentes. Los valores del centroide y de los incrementos de las distancias serán los siguientes

$Partición$	$Centroide$	E	ΔE
(A, B, C, D, E)	$C_{ABCDE} = (19, 12)$	650	$508{,}34$

↘ Método de Ward



Clustering Jerárquico Divisivo

- Comienzan con un conglomerado que engloba a todos los casos tratados y, a partir de este grupo inicial, a través de sucesivas divisiones, se van formando grupos cada vez menores.
- Al final del proceso se tienen tantas agrupaciones como casos han sido tratados

Tipos de Clustering Jerárquico Divisivo

- Monotéticos, los cuales dividen los datos sobre la base de un solo atributo y suelen emplearse cuando los datos son de tipo binario.
- Politéticos, cuyas divisiones se basan en los valores tomados por todas las variables.

Clustering Jerárquico Divisivo (Método de división de clústeres)

- Se comienza con la eliminación del grupo principal de aquel individuo cuya distancia sea mayor, o cuya similitud sea menor, al clúster formado por los restantes individuos, tomando como base para calcular dichas distancias o similitudes cualquiera de los procedimientos anteriormente descritos en los métodos aglomerantes. Así se tiene un clúster unitario y otro formado por los restantes individuos
- A continuación se añadirá al clúster unitario aquel elemento cuya distancia (similitud) total al resto de los elementos que componen su actual clúster menos la distancia (similitud) al clúster anteriormente formado sea máxima (mínima). Cuando esta diferencia sea negativa dicho elemento no se añade
- Se repite el proceso sobre los dos subgrupos

Ejemplo Politético

- Dada la matriz de distancias

	A	B	C	D	E	F	G
A	0						
B	2,15	0					
C	0,7	1,53	0				
D	1,07	1,14	0,43	0			
E	0,85	1,38	0,21	0,29	0		
F	1,16	1,01	0,55	0,22	0,41	0	
G	1,56	2,83	1,86	2,04	2,02	2,05	0

Seguiremos el criterio de maximizar distancias para dividir los grupos

- Paso 1: Las distancias de cada individuo al clúster formado por el resto es

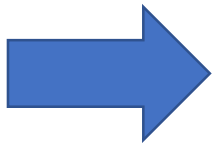
A	0,7
B	1,01
C	0,21
D	0,22
E	0,21
F	0,22
G	1,56



Tenemos dos clústeres
{G} y {A,B,C,D,F}

- Paso 2: calculamos la distancia de cada individuo del clúster principal al resto, la distancia de cada individuo de dicho grupo al nuevo clúster {G} formado así como la diferencia entre ambas

Indiv.	*Distancia en el grupo principal*	*Distancia al nuevo cluster*	*Diferencia*
A	0,7	1,56	−0,86
B	1,01	2,83	−1,82
C	0,21	1,86	−1,65
D	0,22	2,04	−1,82
E	0,21	2,02	−1,81
F	0,22	2,05	−1,83

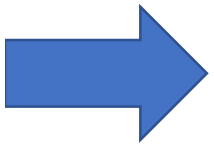


Tenemos tres clústeres {G}, {B} y {A,C,D,F}

ningún elemento se añadirá al clúster anterior, por lo que se divide el grupo principal, empezando por el individuo B

- Paso 3: volvemos a calcular la distancia entre cada individuo del clúster (A,C,D,E,F) así como la distancia de cada individuo de dicho grupo al nuevo clúster formado y la diferencia entre ambas.

Indiv.	*Distancia en el grupo principal*	*Distancia al nuevo cluster*	*Diferencia*
A	0,7	2,15	−1,45
C	0,21	1,53	−1,32
D	0,22	1,14	−0,92
E	0,21	1,38	−1,17
F	0,22	1,01	−0,79

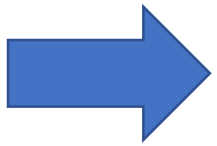


Tenemos cuatro clústeres {G}, {B}, {A} y {C,D,E,F}

ningún individuo se añadirá al nuevo clúster formado. Ahora se divide el clúster (A, C, D, E, F) por el individuo A.

- Paso 4: calculamos la distancia entre cada individuo del clúster (C,D,E,F) así como la distancia de cada individuo de dicho grupo al nuevo clúster formado y la diferencia entre ambas.

Indiv.	*Distancia en el grupo principal*	*Distancia al nuevo cluster*	*Diferencia*
C	0,21	0,7	−0,49
D	0,22	1,07	−0,85
E	0,21	0,85	−0,64
F	0,22	1,16	−0,94

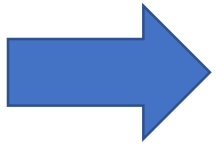


Tenemos cuatro clústeres {G}, {B}, {A}, {D} y {C,E,F}

Ningún elemento se añadirá al clúster formado por el individuo A. Elegimos ahora el individuo D (también podríamos haber elegido el F).

- Paso 5: calculamos la distancia entre cada individuo del clúster (C,E,F) así como la distancia de cada individuo de dicho grupo al nuevo clúster formado y la diferencia entre ambas.

Indiv.	*Distancia en el grupo principal*	*Distancia al nuevo cluster*	*Diferencia*
C	0,21	0,43	−0,22
E	0,21	0,29	−0,08
F	0,41	0,22	0,19



Tenemos cuatro clústeres {G}, {B}, {A}, {D,F} y {C,E}

Se tiene que el individuo F se suma al individuo D. Comprobamos que no se suma otro

Indiv.	*Distancia en el grupo principal*	*Distancia al nuevo cluster*	*Diferencia*
C	0,21	0,43	−0,22
E	0,21	0,29	−0,08

Se tiene que el individuo F se suma al individuo D. Comprobamos que no se suma otro

Indiv.	*Distancia en el grupo principal*	*Distancia al nuevo cluster*	*Diferencia*
C	0,21	0,43	−0,22
E	0,21	0,29	−0,08

- Paso 6

El proceso se seguiría ahora descomponiendo los dos clústeres que quedan, a saber, (D, F) y (C, E), empezando con el primero de ellos pues es el que más distancia presenta entre sus elementos.

~~Ejemplo Monotético~~

- se tienen 5 individuos sobre los cuales se miden tres variables de tipo binario

X_1	X_2	X_3
0	1	1
1	0	0
1	1	1
1	1	0
0	0	1

usaremos el criterio basado en los estadísticos del tipo χ2 obtenidos a partir de la tabla de doble entrada para cada par de variables

$$\chi^2_{jk} = \frac{(ad - bc)^2 N}{(a + b)(a + c)(b + d)(c + d)}$$

y tomar la variable k tal que $\sum_{j \neq k} \chi^2_{jk}$ sea máximo.

Criterios alternativos a *Max* χ^2_{jk}

Max $\sqrt{\chi^2_{jk}}$

Max $\sum |ad - bc|$

Max $\sum (ad - bc)^2$

Ejemplo

- los estadísticos χ2 para cada par de variables

$$\chi^2_{12} = \frac{45}{24} = 1{,}875 \qquad \chi^2_{13} = \frac{80}{36} = 2{,}22 \qquad \chi^2_{23} = \frac{20}{24} = 0{,}83$$

- Elegir la variable k tal que χ^2_{jk} se mayor

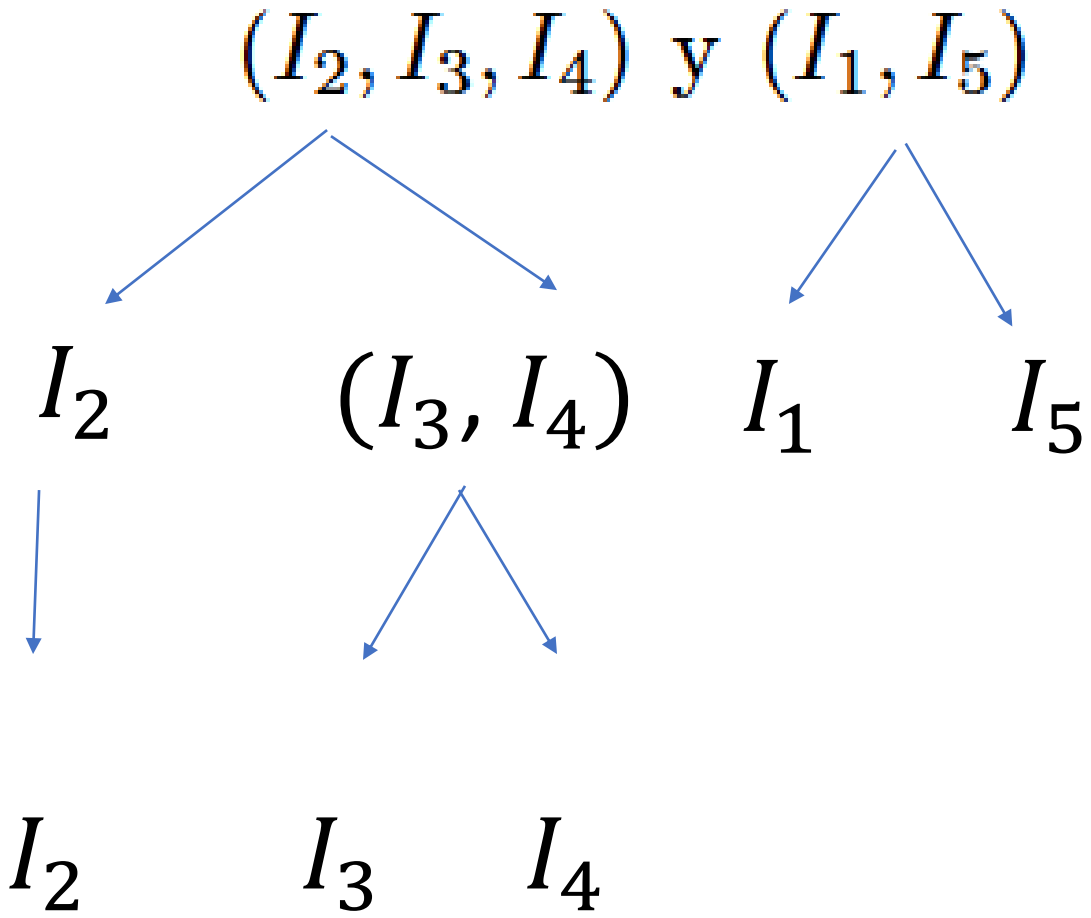
$$\chi^2_{12} + \chi^2_{13} = 4{,}09$$
$$\chi^2_{12} + \chi^2_{23} = 2{,}7$$
$$\chi^2_{13} + \chi^2_{23} = 3{,}05$$

entonces la división se basará en la determinación de quien posee la característica asociada a la variable X1 y quien no

Entonces los clústeres formados son (I_2, I_3, I_4) y (I_1, I_5).

Ejemplo

Se sigue aplicando, forma sucesiva, este criterio a ambos subgrupos



Ejemplo

- https://www.ugr.es/~gallardo/pdf/cluster-3.pdf