Validación de un agrupamiento

¿cómo evaluar la “bondad” de los grupos resultantes?

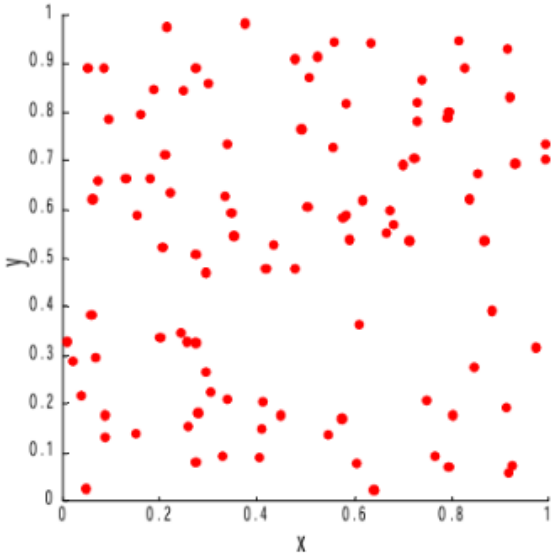
Validación de un agrupamiento

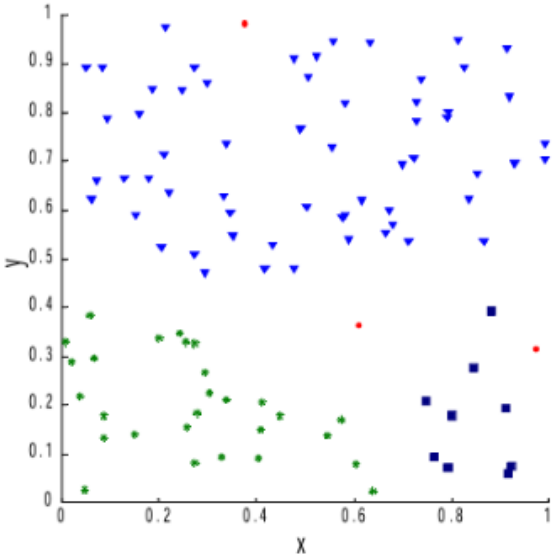
Razones por las que evaluar una determinada formación de grupos

- evitar tener patrones con ruido
- comparar distintos algoritmos de agrupamiento
- comparar dos agrupamientos diferentes
- comparar dos grupos

Grupos encontradas en datos aleatorios

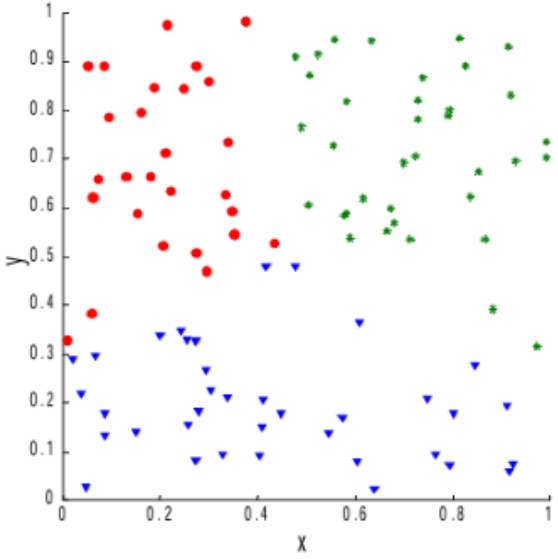
Random Points

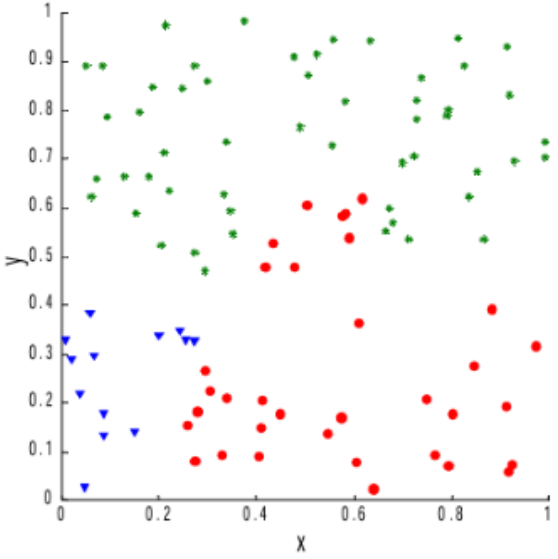




DBSCAN

K-means





Complete Link

Utilidad de la validación de un agrupamiento

1. Determinar la tendencia de agrupamiento de un conjunto de datos, es decir, distinguir si realmente existe una estructura no aleatoria en los datos
2. Comparar los resultados de un análisis de clústeres con resultados conocidos externamente, por ejemplo, con etiquetas de clase dadas externamente.
3. Evaluar cómo de bien se ajustan los resultados de un análisis de clústeres a los datos sin hacer referencia a información externa (Utilizar únicamente los datos)
4. Comparar los resultados de dos conjuntos diferentes de análisis clúster para determinar cuál es mejor.
5. Determinar el número correcto de clústeres

Medidas para evaluar un agrupamiento

Las medidas numéricas que se aplican para juzgar diversos aspectos de la validez del agrupamiento se clasifican en los tres tipos siguientes:

Métricas de validación externas: se utiliza para medir en qué medida las etiquetas de los clústeres coinciden con las etiquetas de clase proporcionadas externamente.

Métricas de validación internas : se utiliza para medir la bondad de una estructura de agrupamiento sin tener en cuenta información externa.

Métricas de validación relativas: se utiliza para comparar dos agrupaciones diferentes.

No tienen una métrica propia, sino que reutilizan las internas o externas.

Medidas para evaluar un agrupamiento

Métricas de validación externas

Ejemplos

- Accuracy (exactitud): número de ejemplos etiquetados correctamente
- Entropía: grado en que los grupos previstos están formados por objetos que pertenecen a una sola clase, en lugar de a muchas clases
- Pureza: grado en que un clúster previsto contiene objetos de una sola clase.
- Información mutua: mide cuánta información comparten dos particiones.
- Jaccard Coefficient , Rand Statistic , Folkes and Mallows Index , Odds Ratio…

Medidas para evaluar un agrupamiento

Métricas de validación internas

Ejemplos

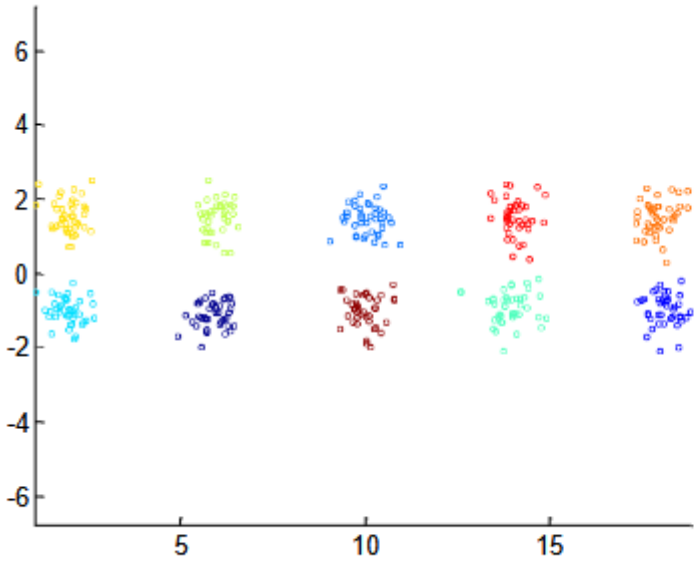
- SSE, la suma de los cuadrados de los errores que incorpora las distancias euclidianas al cuadrado entre cada punto de un clúster determinado y el centroide de dicho clúster
- Medida de validación de Ray and Turi's, Coeficientes Silueta,..

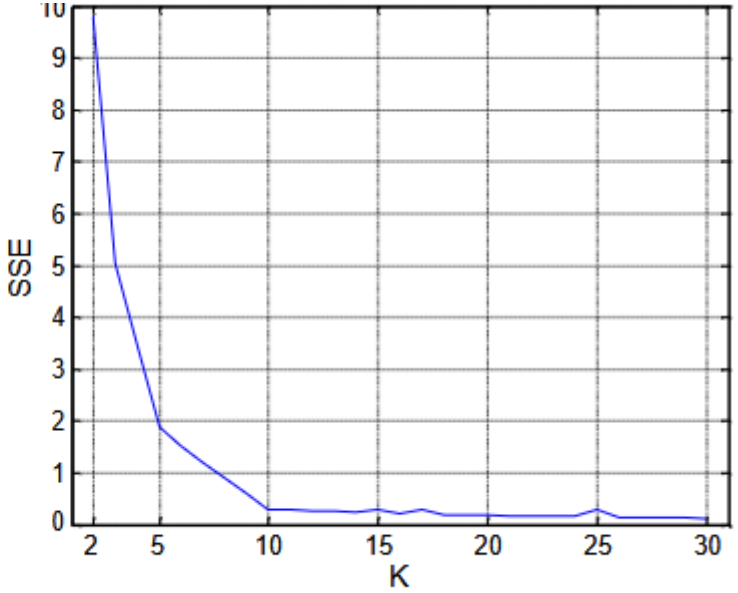
Métricas de validación relativas: se utiliza para comparar dos agrupaciones diferentes.

A menudo se utiliza un índice externo o interno para esta función

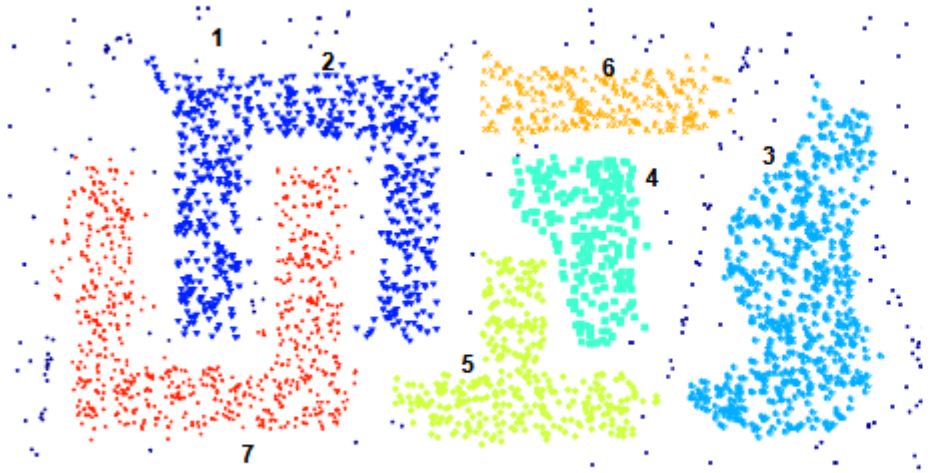
Medidas Internas: Error cuadrático

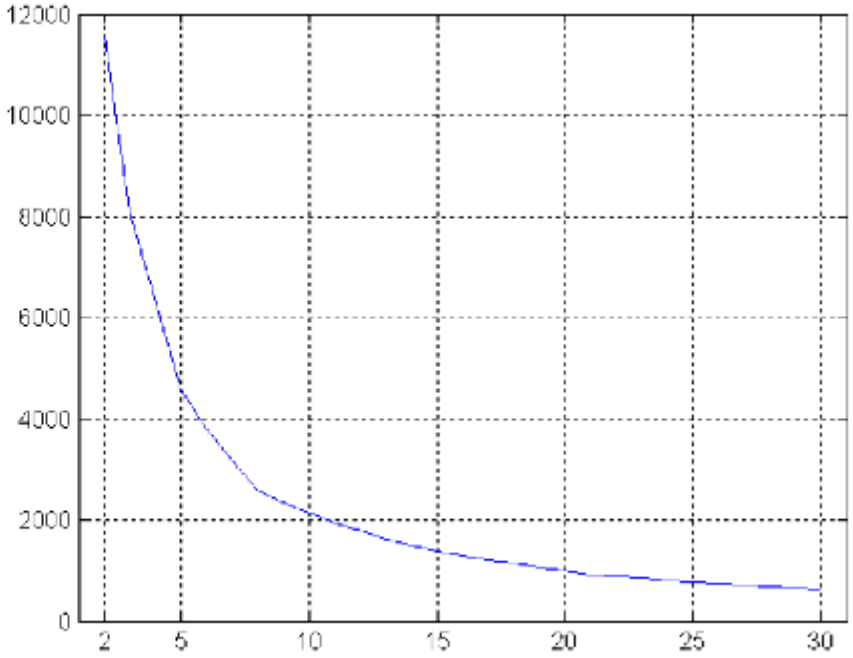
- En determinados casos los grupos no están bien separados
- Índice interno: se utiliza para medir la bondad de una estructura de agrupamiento sin tener en cuenta la información externa
- El error cuadrático medio es una medida útil para comparar dos agrupaciones o dos grupos
- Se podría usar también para determinar el número de grupos





Medidas Internas: Error cuadrático





Error cuadrático para datos más complejos

Medidas Internas: Cohesión y Separación

- **Cohesión del clúster**: mide cuan estrechamente relacionados están los objetos en un clúster

- La cohesión se mide por la suma de cuadrados dentro del grupo.

Ejemplo: within cluster sum of squares

$$WSS = \sum_{i} \sum_{\vec{x} \in C_i} (\vec{x} - \vec{m}_i)^2$$

- **Separación de grupos**: mide lo distinto o bien separado que está un grupo de otros grupos

-La separación se mide por la suma de los cuadrados entre los grupos.

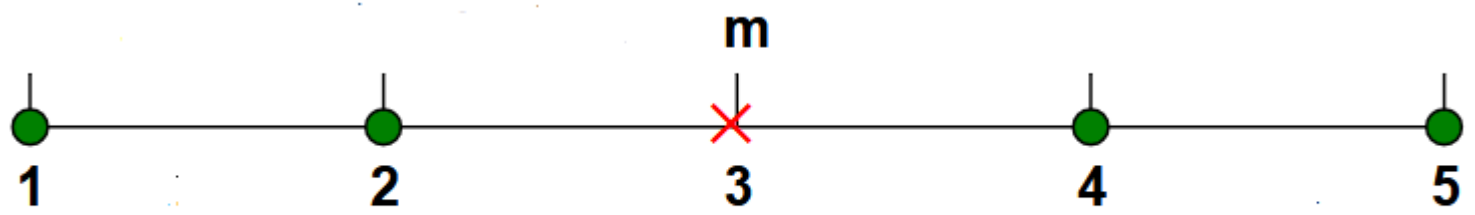
Ejemplo: between cluster sum of squares

$BSS = \sum_i |C_i| (\vec{m} - \vec{m}_i)^2$, donde $|C_i|$ es el tamaño del grupo i

Medidas Internas: Cohesión y Separación

BBS+WWS=CONSTANTE

Ejemplo



K=1 cluster:

$$WSS = (1-3)^2 + (2-3)^2 + (4-3)^2 + (5-3)^2 = 10$$

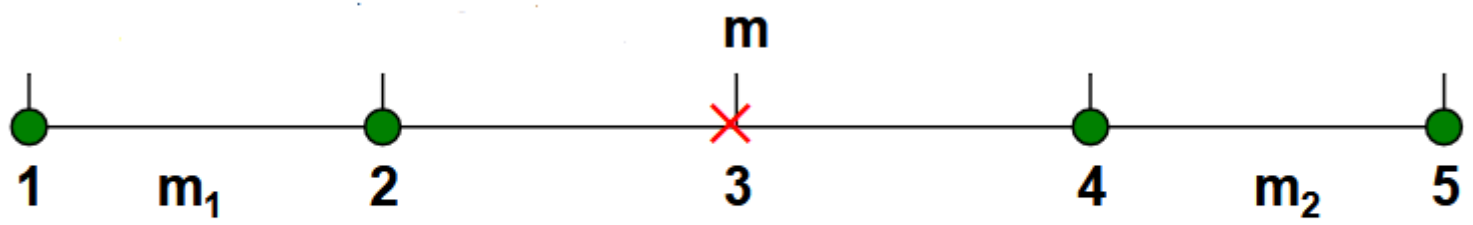
$$BSS = 4 \times (3-3)^2 = 0$$

$$Total = 10 + 0 = 10$$

Medidas Internas: Cohesión y Separación

BBS+WWS=CONSTANTE

Ejemplo



K=2 clusters:

$$WSS = (1-1.5)^2 + (2-1.5)^2 + (4-4.5)^2 + (5-4.5)^2 = 1$$

$$BSS = 2 \times (3-1.5)^2 + 2 \times (4.5-3)^2 = 9$$

$$Total = 1 + 9 = 10$$

Medidas Internas: Cohesión y Separación

Definición de Cohesión de Clúster General para datos.

Sea $X = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots \boldsymbol{x}_n\}$, un conjunto de datos con $\boldsymbol{x}_i \in \mathbb{R}^m$ y sea una partición en k conjuntos disjuntos $C = \{C_1, C_2, \ldots, C_k\}$ de los datos con sus correspondientes prototipos o representantes $\{\boldsymbol{c}_1, \boldsymbol{c}_2, \ldots, \boldsymbol{c}_k\}$.

Entonces la **cohesión** del cluster C_p es

$$cohesion(C_p) = \sum_{\boldsymbol{x}_i \in C_p} d(\boldsymbol{x}_i, \boldsymbol{c}_p)$$

donde d es cualquier función distancia o similitud.

Medidas Internas: Cohesión y Separación

Definición de Separación de Clúster General para datos.

Sea $X = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots \boldsymbol{x}_n\}$, un conjunto de datos con $\boldsymbol{x}_i \in \mathbb{R}^m$ y sea una partición en k conjuntos disjuntos $C = \{C_1, C_2, \ldots, C_k\}$ de los datos con sus correspondientes prototipos o representantes $\{\boldsymbol{c}_1, \boldsymbol{c}_2, \ldots, \boldsymbol{c}_k\}$. Entonces la **separación** entre los clústeres C_p y C_q es

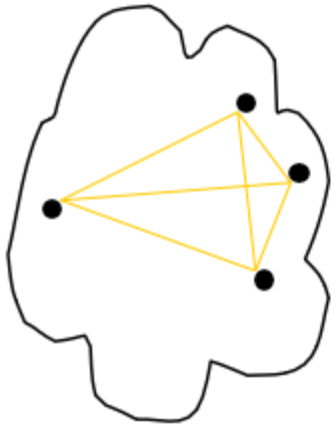
$$separacion(C_p, C_q) = \sum_{\boldsymbol{x}_i \in C_p} d(\boldsymbol{c}_p, \boldsymbol{c}_q)$$

donde d es cualquier función distancia o similitud.

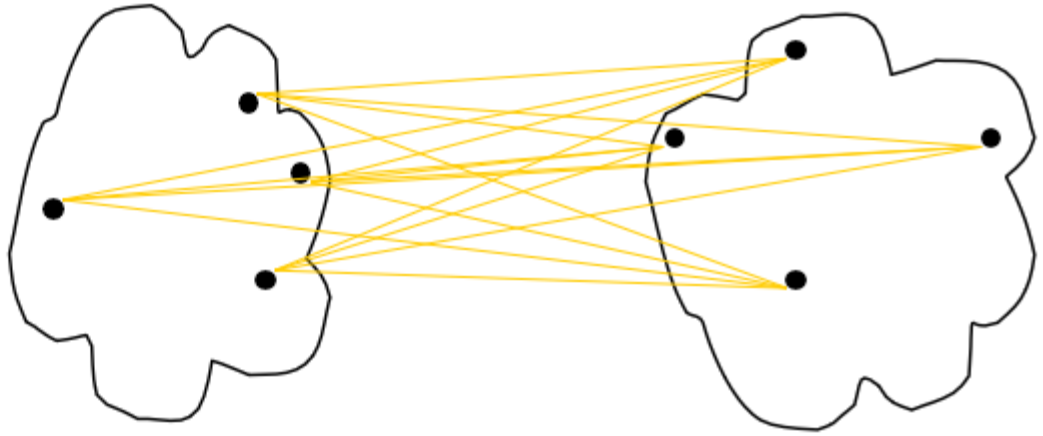
Medidas Internas: Cohesión y Separación

También se puede utilizar un enfoque basado en gráficos de proximidad para la cohesión y la separación.

- La cohesión del clúster es la suma del peso de todos los enlaces dentro de un clúster.
- La separación de clústeres es la suma de los pesos entre los nodos del clúster y los nodos fuera del clúster.



Cohesión



Separación

Medidas Internas: Índice Silueta

- El índice Silueta combina ambas ideas : Cohesión y Separación.
- Se puede usar para puntos individuales, para cada clúster, para todo el agrupamiento.

Medidas Internas: Índice Silueta

Índice Silueta para un punto individual i

- Calcular

  $a(i) =$ distancia media de i a todos los puntos de su cluster

- Calcular

  $b(i) =$ minimo de la distancia media de i a todos los puntos de otro clúster

- Calcular el índice Silueta

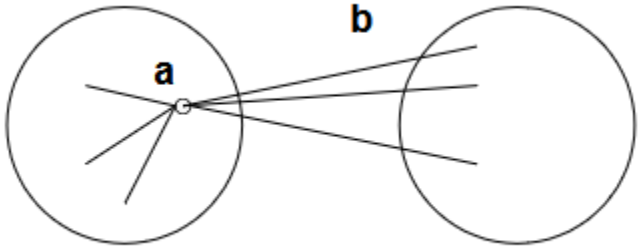
s(i) =1- $\frac{a(i)}{b(i)}$ si a(i) < b(i) o s$(i) = \frac{b(i)}{a(i)}$ - 1 si a(i) > b(i) (caso poco usual)

Lo cual es equivalente a

s$(i) = \frac{b(i)-a(i)}{max\{a(i),b(i)\}}$ si |a(i) − b(i)|>0,

s$(i) = 0$ si a(i) = b(i)

De la definición queda claro que -1≤ $(i) \leq 1$



Medidas Internas: Índice Silueta

- s(i) cercano a 1 significa que el dato está agrupado apropiadamente
- s(i) cerca de -1, sería más apropiado si el dato se agrupara en su grupo vecino.
- s(i) cerca de cero significa que el dato está en el borde de dos grupos naturales.

Medidas Internas: Índice Silueta

- El s(i) promedio de todos los datos de un grupo es una medida de lo estrechamente agrupados que están todos los datos en el grupo.
- El s(i) promedio de todos los datos del conjunto de datos es una medida de cuán apropiadamente se han agrupado los datos.

Journal of Computational and Applied Mathematics 20 (1987) 53–65
North-Holland

Silhouettes: a graphical aid to the interpretation and validation of cluster analysis

Peter J. ROUSSEEUW
University of Fribourg, ISES, CH-1700 Fribourg, Switzerland

Received 13 June 1986
Revised 27 November 1986

Example(silhoutte coefficient)

Table 1
Dissimilarities between twelve countries, obtained by averaging the result of a survey among political science students

Country	Dissimilarities to other countries										
	BEL	BRA	CHI	CUB	EGY	FRA	IND	ISR	USA	USS	YUG
BRA	5.58										
CHI	7.00	6.50									
CUB	7.08	7.00	3.83								
EGY	4.83	5.08	8.17	5.83							
FRA	2.17	5.75	6.67	6.92	4.92						
IND	6.42	5.00	5.58	6.00	4.67	6.42					
ISR	3.42	5.50	6.42	6.42	5.00	3.92	6.17				
USA	2.50	4.92	6.25	7.33	4.50	2.25	6.33	2.75			
USS	6.08	6.67	4.25	2.67	6.00	6.17	6.17	6.92	6.17		
YUG	5.25	6.83	4.50	3.75	5.75	5.42	6.08	5.83	6.67	3.67	
ZAI	4.75	3.00	6.08	6.67	5.00	5.58	4.83	6.17	5.67	6.50	6.92

BEL(belgica),BRA(brasil), CHI(china), CUB(cuba),
EGY(Egipt),FRA(france), IND(india), ISR(israel), USA(estadosunidos),
(USS)rusia, (YUG)yugoslavia

Example(silhoutte coefficient)

- K-means method for k=2 results in

cluster 1: BEL, BRA, EGY, FRA, ISR, USA, ZAI
cluster 2: CHI, CUB, IND, USS, YUG

- K-means for k=3

cluster 1: BEL, EGY, FRA, ISR, USA
cluster 2: BRA, IND, ZAI
cluster 3: CHI, CUB, USS, YUG

Example(silhoutte coefficient)

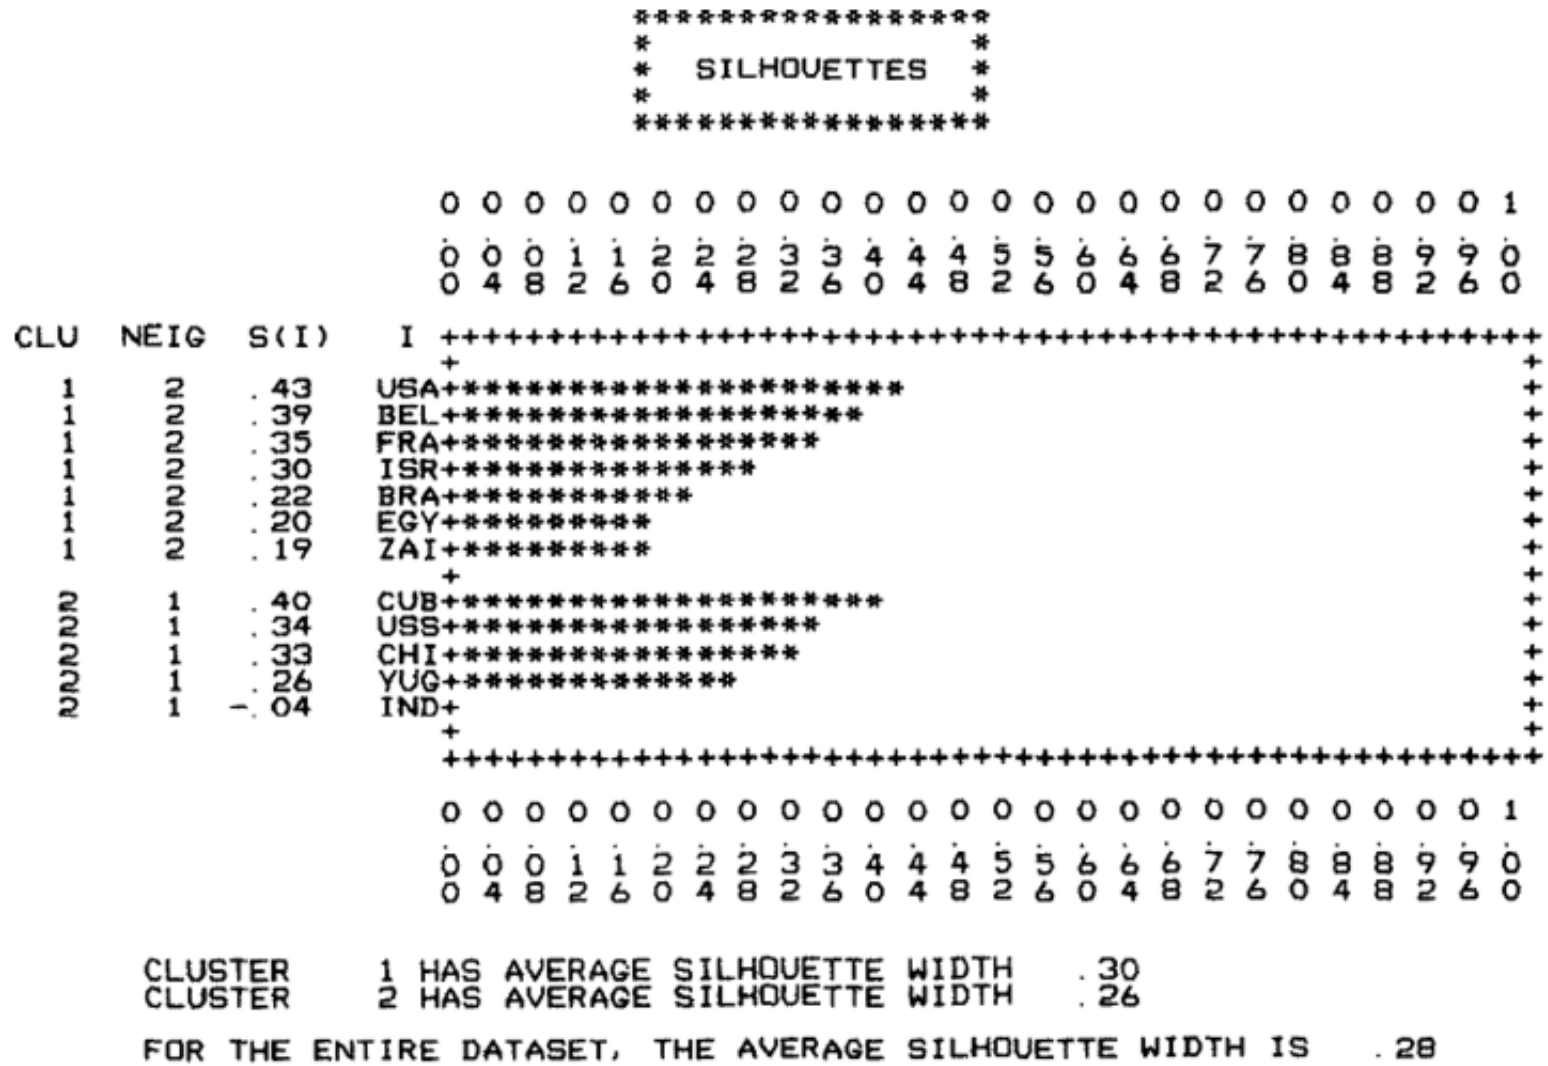
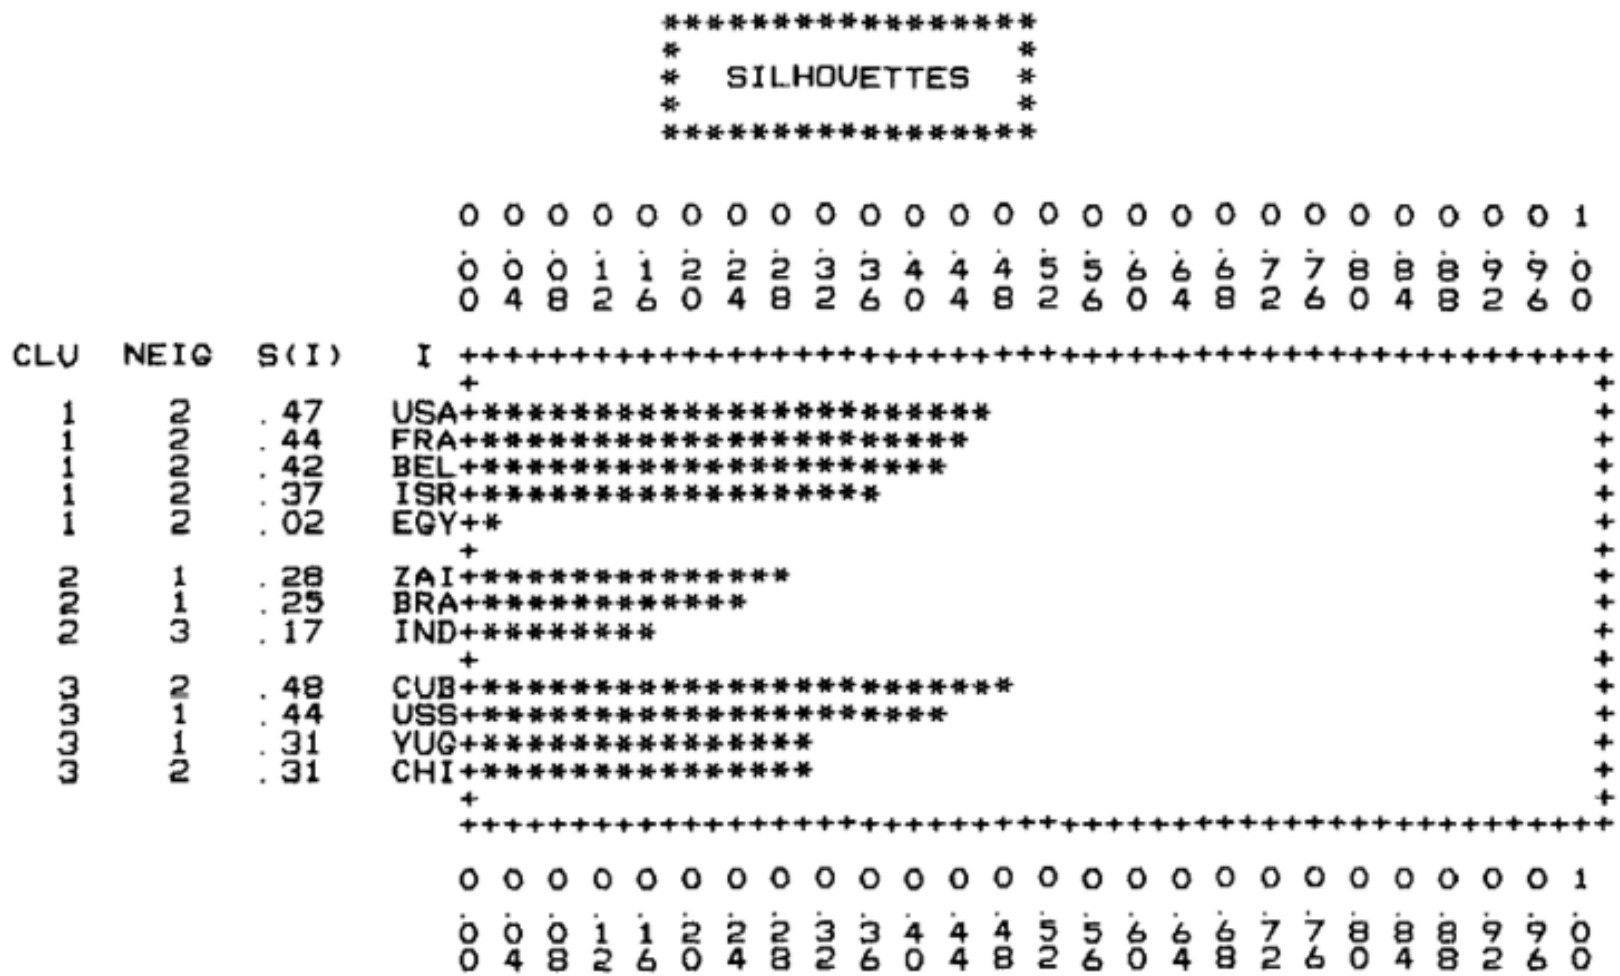


Fig. 2. Silhouettes of a clustering with $k = 2$ of the twelve countries data of Table 1.

Example(silhoutte coefficient)



CLUSTER 1 HAS AVERAGE SILHOUETTE WIDTH .34
CLUSTER 2 HAS AVERAGE SILHOUETTE WIDTH .24
CLUSTER 3 HAS AVERAGE SILHOUETTE WIDTH .38

FOR THE ENTIRE DATASET, THE AVERAGE SILHOUETTE WIDTH IS .33

Medidas Internas: Índice de Ray y Turi

- Penaliza clústeres **muy dispersos** (mala cohesión).
- Penaliza clústeres **muy cercanos entre sí** (mala separación).
- Combina ambas cosas en un solo valor.

$$V=\frac{M_{intra}}{M_{inter}}$$

donde

$$M_{intra} = \frac{1}{n} SSE(C) = \frac{1}{n} \sum_i \sum_{\vec{x} \in C_i} (\vec{x} - \vec{m}_i)^2,$$

$$M_{inter} = \min_{1 \le i \le j \le k} \left\| \vec{m}_i - \vec{m}_j \right\|^2$$

Cuanto mejor es la agrupación más pequeño es el valor del índice

Características del Índice de Ray y Turi

- No funciona bien con clústeres no esféricos, si los grupos tienen formas alargadas, densidades distintas o estructuras complejas, la métrica pierde fiabilidad.
- Sensible a la escala de los datos, si las variables no están normalizadas, el índice puede dar resultados engañosos
- Depende fuertemente de la distancia entre centroides, esto penaliza métodos donde los centroides no representan bien la estructura (DBSCAN, clustering jerárquico no centrado, etc.)
- Menos usado y menos estudiado, tiene menos respaldo empírico y menos interpretaciones estándar.

Medidas Internas: Índice DB (Davies-Bouldin)

El índice evalúa los algoritmos de agrupamiento y garantiza que el mínimo del valor del índice se determina como el número óptimo de clústeres

$$S_i = \frac{1}{k} \sum_{i=1, i \neq j}^{k} \left(\frac{\sigma_i + \sigma_j}{d(c_i, c_j)} \right)$$

k es el número de clústeres

σ_i es la distancia promedio entre cada punto en el clúster i y el centroide del clúster

σ_j es la distancia promedio entre cada punto en el clúster j y el centroide del clúster

$d(c_i, c_j)$ es la distancia entre los centroides de los dos clústeres

Valores pequeños para el índice DB indica clústeres compactos, y cuyos centros estas bien separados los unos de los otros.

A Cluster Separation Measure

May 1979 · IEEE Transactions on Pattern Analysis and Machine Intelligence
PAMI-1(2):224 - 227

DOI:10.1109/TPAMI.1979.4766909

Source · IEEE Xplore

Authors:

David L. Davies



Don Bouldin
University of Tennessee at Knoxville

Ventajas del Índice de Davies-Bouldin

1. Es un métrica relativa, es decir, se puede usar para comparar los resultados de agrupamiento de diferentes algoritmos sobre el mismo conjunto de datos.
2. Tiene una clara interpretación: a menor valor del índice más compactos y bien separados están los grupos.
3. Es relativamente simple de calcular.
4. Proporciona una medida global de la calidad de un agrupamiento.

Limitaciones del Índice de Davies-Bouldin

1. Es sensible a los outliers y al ruido en los datos .
2. No tiene en cuenta la estructura o distribución de los datos, como los grupos dentro de grupos o las relaciones no lineales.
3. Sólo considera las distancias por pares entre los centroides del grupo y los miembros del grupo.
4. No es muy apropiado para clusters que no están bien separados

Medidas Internas: Índice de Dunn

- El índice de Dunn es la relación entre la distancia más pequeña entre las observaciones que no están en el mismo grupo y la distancia más grande dentro del grupo.
- El índice de Dunn tiene un valor entre cero e infinito
- El valor máximo del índice de Dunn es lo que nos interesa

Medidas Internas: Índice de Dunn

- distancia mínima entre puntos de diferentes clústeres

$$d_{min}=\min_{k\neq k'} d_{kk'}$$

donde la distancia entre los clústeres C_k y $C_{k'}$ se mide por la distancia entre sus puntos más cercanos

$$d_{kk'}=\min_{i\in I_k, j\in I_{k'}} \left\| M_i^k - M_j^{k'} \right\|$$

- distancia máxima dentro del clúster

$$d_{max}=\max_{1\leq k\leq K} D_k$$

donde D_k es la mayor distancia que separa dos puntos distintos en el grupo C_k (a veces llamado el diámetro del grupo)

$$D_k=\max_{i,j\in I_k, i\neq j} \left\| M_i^k - M_j^k \right\|$$

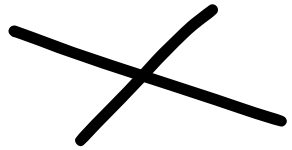
Medidas Internas: Índice de Dunn

el índice de Dunn se define como el cociente entre la distancia mínima y la distancia máxima, así:

$$C = \frac{d_{min}}{d_{max}}$$

Por lo tanto, un valor alto indica un mejor rendimiento del algoritmo de agrupamiento.

Propiedades del Índice de Dunn



ventajas

✓ computo simple

✓ buen funcionamiento en grupos bien separados

inconvenientes

✓computación es costosa en conjuntos de datos extensos

✓ tiene un mal funcionamiento en grupos no convexos

Original Articles

Well-Separated Clusters and Optimal Fuzzy Partitions

J. C. Dunn†

Pages 95-104 | Received 01 Sep 1973, Published online: 30 Apr 2008

Cite this article https://doi.org/10.1080/01969727408546059

Medidas Internas: Calinski-Harabasz

Este índice para una partición P está definido como la razón entre la dispersión interior de los clústeres y la dispersión entre los clústeres.

$$CH(P) = \frac{WSS/(M-1)}{BSS/(N-M)}$$

donde

$WSS = \frac{1}{N}\sum_i \sum_{\vec{x}\in C_i}(\vec{x} - \vec{m}_i)^2$ y $BSS = \frac{1}{M(M-1)}\sum_i \sum_j (d(C_i, C_j))^2$

Siendo N el número de objetos de la base de datos y M el número de grupos

A DENDRITE METHOD FOR CLUSTER ANALYSIS

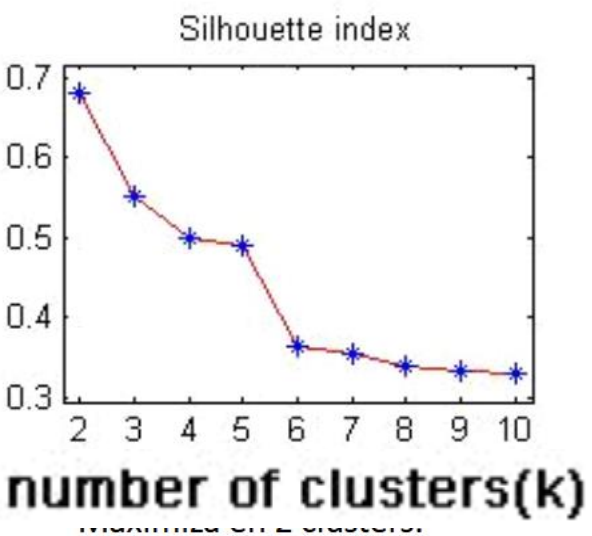
T. Caliński and J. Harabasz

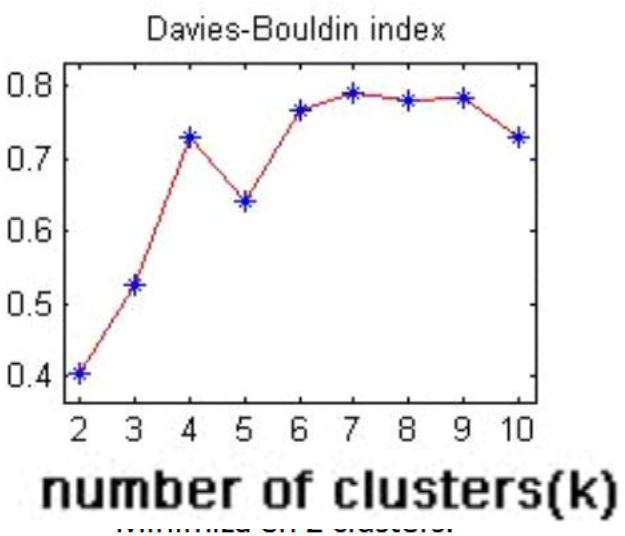
Academy of Agriculture, Poznań, Poland

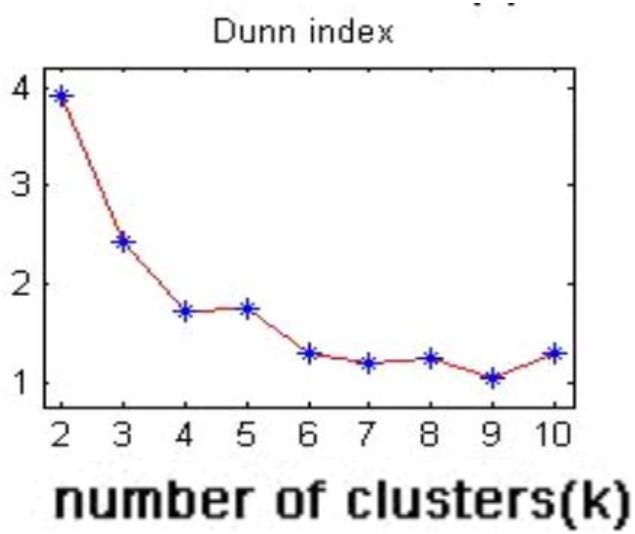
Key Words & Phrases: numerical taxonomy; cluster analysis; minimum variance (WGSS) criterion for optimal grouping; approximate grouping procedure; shortest dendrite = minimum spanning tree; variance ratio criterion for best number of groups.

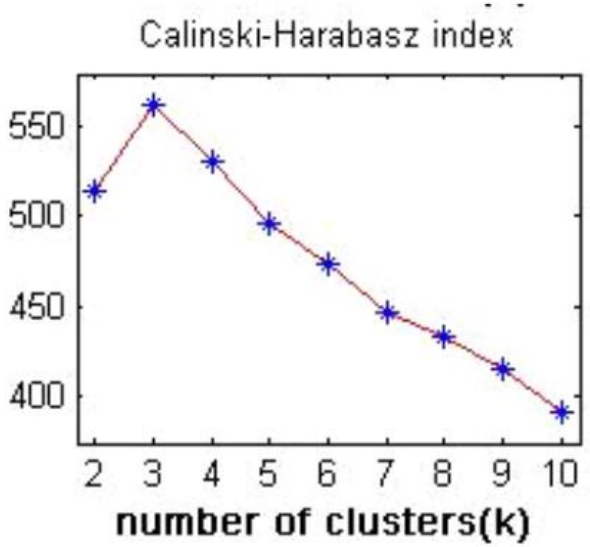
Ejemplo: Datos Iris

K-means:









- ✓ Índice silueta, DB, Dunn 2 clústeres
- ✓ El índice Calinski-Harabasz, 3 clústeres

Técnica del codo (Elbow Technique)

