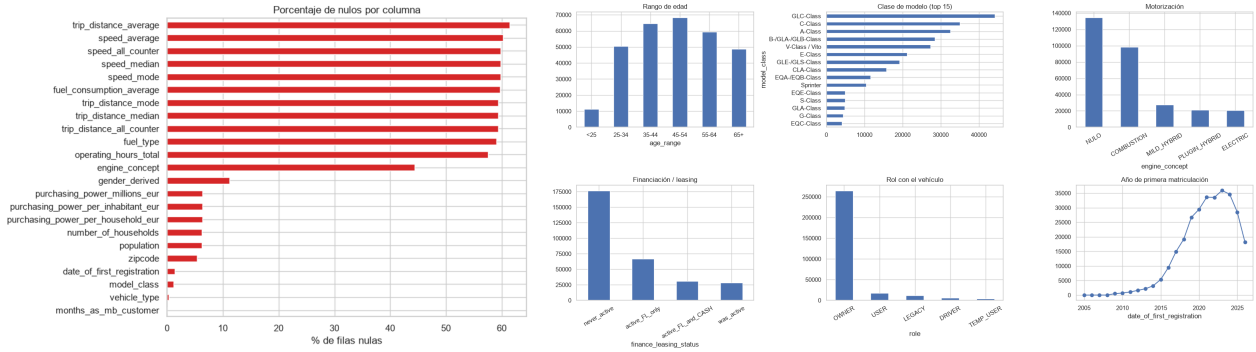
Resumen Bodo Git

Clustering the Star · Malackathon 2026 · Reto Mercedes-Benz — segmentación de clientes con K-Means

---

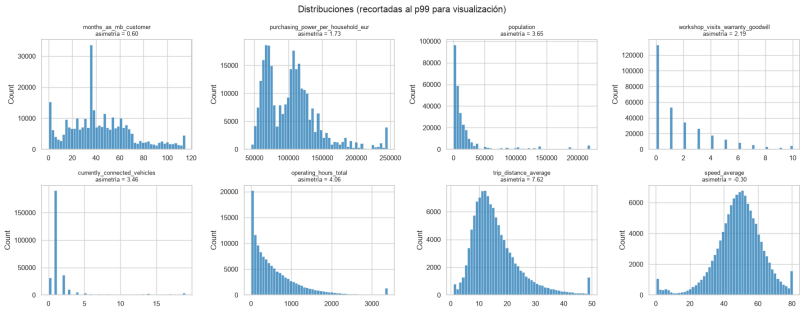
Qué muestran las gráficas de cada reto, qué decidimos y por qué. Todas las cifras salen de los notebooks ejecutados (*notebooks-básico/01–04* y *notebooks-avanzado/05–07*).

Reto 1 · Exploración y calidad de datos



Izquierda: % de nulos por columna. Derecha: perfil categórico (edad, modelo, motorización, financiación, rol y año de matriculación).

Nulos y perfil. La telemetría falta en ~60 % de las filas y la motorización en un 44 % (la barra mayor de motorización es **NULO**); el resto de columnas, menos de un 12 %. Los nulos de telemetría son más frecuentes en vehículos no actuales: **no son aleatorios**, así que imputarlos inventaría datos. Base madura (61 % con 45 años o más), predominio de GLC, C y A-Class, mayoría de propietarios y matriculaciones crecientes hasta 2023.



Distribuciones. Población, visitas y horas tienen una **asimetría fuerte** (→ log). El poder adquisitivo tiene **dos picos**: Austria ≈ 67.000 € y Suiza ≈ 116.000 € por hogar (→ imputar por país). La antigüedad tiene un pico en 36 meses (12 % de los clientes).

> *Conclusión: 302.850 filas son en realidad pares cliente–vehículo de 173.456 clientes. Decidimos agregar a una fila por cliente, no imputar la telemetría (solo un indicador has_telemetry), completar la motorización desde el modelo del vehículo y tratar los extremos con log y recorte en lugar de borrar filas.*

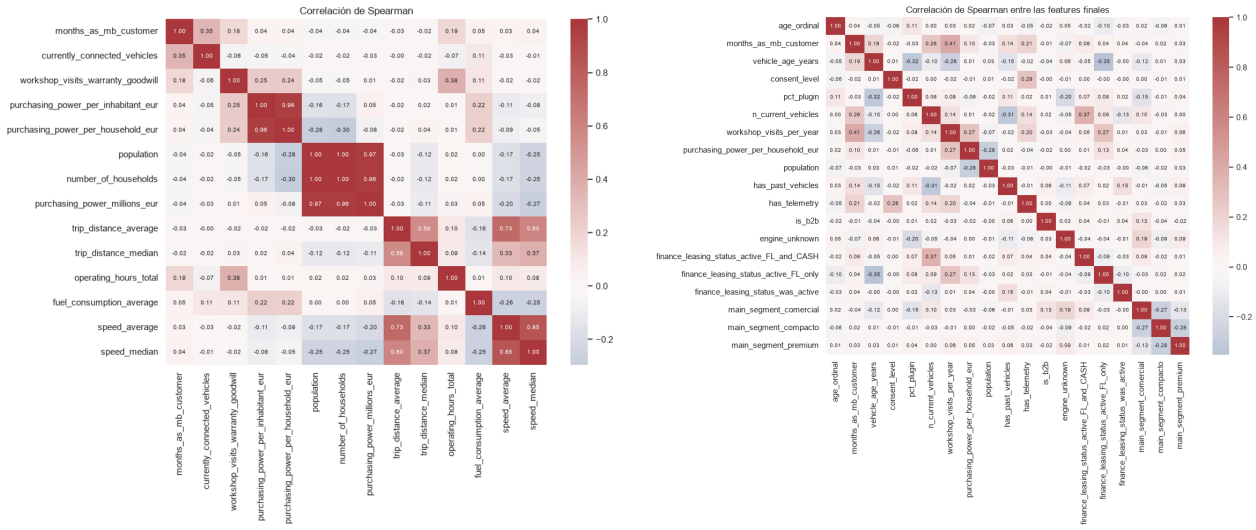
Reto 2 · Feature engineering y pipeline

Un único **pipeline de sklearn** va del CSV en bruto a la matriz de K-Means: features derivadas por vehículo (edad del vehículo, visitas de garantía al año, % enchufables, nivel de consentimiento, segmento principal…) → agregación por cliente → imputación por país → log → recorte p1–p99 → StandardScaler; one-hot para las categóricas. Resultado: **173.454 clientes × 19 features**, sin nulos.

¿Imputar o eliminar?

Media	Se quedan	Se eliminarían
Antigüedad como cliente (meses)	36,4	23,3
% con telemetría	63 %	47 %
% segmento comercial	8,9 %	20,1 %

Eliminar a los clientes con algún dato desconocido supondría perder el **19,1 %** (el umbral de los apuntes es el 5 %) y **no al azar**: más clientes recientes y comerciales. Por eso se imputa. La motorización completada desde el modelo del vehículo acierta un **95,5 %** en validación y baja los nulos del 44,4 % al 17,6 %.



Izquierda: correlación de las variables originales (EDA). Derecha: correlación de las 19 features finales.

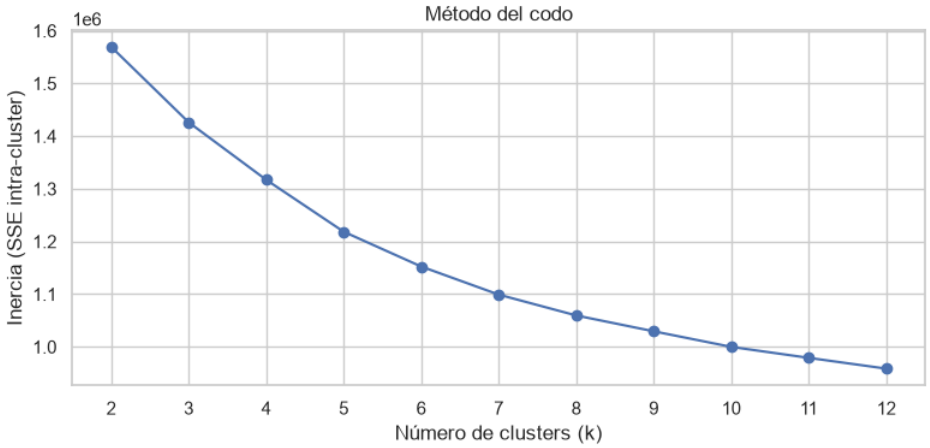
Antes (EDA). 5 pares con ρ ≥ 0,85: población–nº de hogares (1,00), población–poder adquisitivo total (0,97), nº de hogares–poder adquisitivo total (0,96), poder adquisitivo por habitante–por hogar (0,96) y velocidad media–mediana (0,85). Medían lo mismo, así que se conservó **una variable por grupo** (población y poder adquisitivo por hogar) y la telemetría quedó fuera del modelo.

Después (features finales). Además se eliminó *has_commercial_vehicle* (ρ = 0,92 con *segmento comercial*) y la categoría de referencia de cada one-hot (*never_active* y *medio*), que creaban correlaciones artificiales de –0,86 y –0,63.

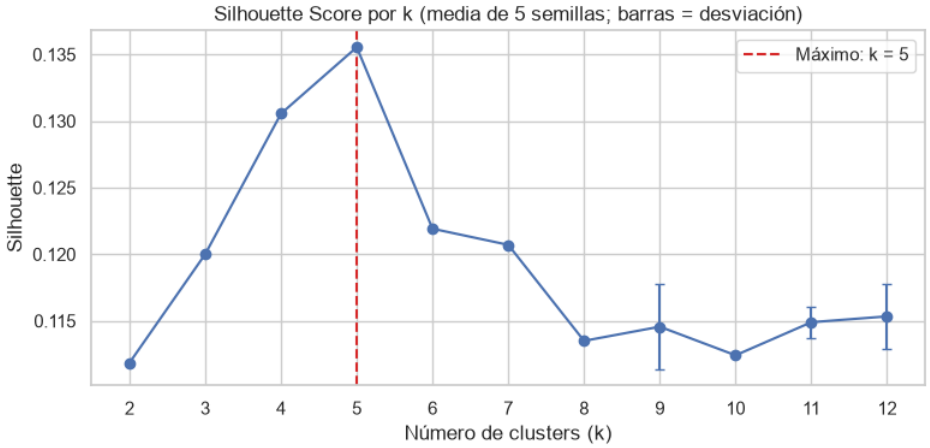
Conclusión: ninguna pareja de features supera |ρ| = 0,8 (máximo 0,41): cada variable aporta información distinta y todo el preprocesado es reproducible en un solo pipeline.

Reto 3 · K-Means: elección de k

K-Means para k = 2…12 con *k-means*++, 10 inicializaciones y **5 semillas por k** (55 modelos). Todos convergen antes del tope de iteraciones. El **Silhouette** (de –1 a 1) mide si cada cliente está más cerca de su cluster que del vecino: cuanto más alto, mejor separados.



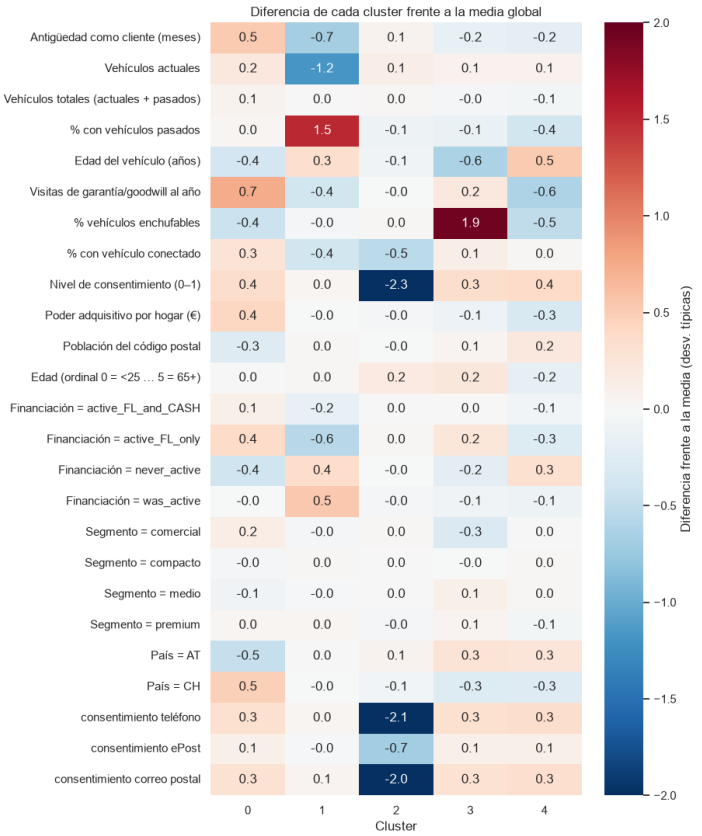
Método del codo. La inercia cae con fuerza hasta k = 5 (≥ 7,5 % por cada cluster nuevo) y a partir de k = 6 las caídas se reducen (≤ 5,4 %).



Silhouette por k. El máximo está en **k = 5 (0,136)**, igual con las 5 semillas. El valor es bajo en todos los k: los clientes forman un **continuo**, no grupos aislados, así que lo que decide es la comparación entre valores de k.

> *Conclusión: k = 5 es el único valor en el que coinciden el codo y el máximo del Silhouette. Con k = 5 las 5 semillas dan los mismos clusters (ARI ≥ 0,993; el **ARI** compara dos agrupaciones: 1 = idénticas, 0 = coincidencia al azar) y los tamaños están equilibrados (10,1–33,7 %).*

Reto 4 · Interpretación de los 5 segmentos



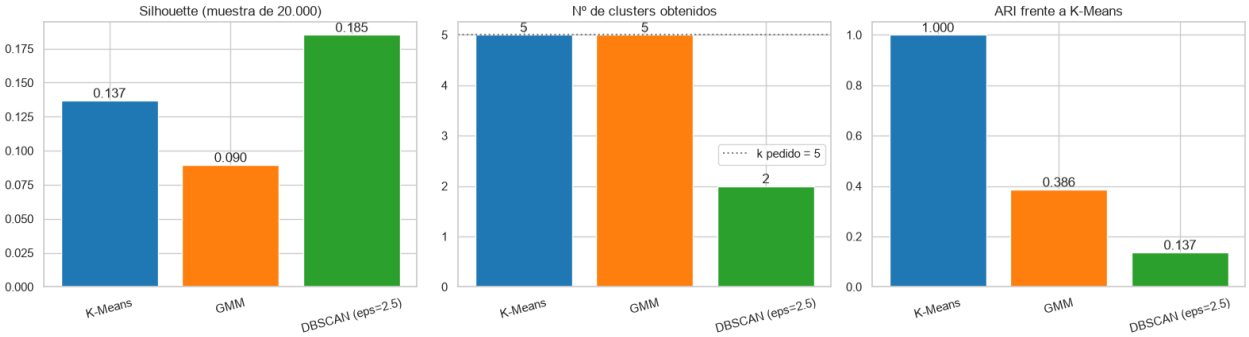
Diferencia frente a la media global (en desviaciones típicas; rojo = por encima, azul = por debajo). Cada segmento se nombra por sus rasgos más marcados, no a ojo:

Segmento	%	Por qué (rasgo que lo define)	Acción de marketing
Fieles Acomodados	28,6	Más visitas de garantía (+0,7), mayor antigüedad (+0,5) y poder adquisitivo; 89 % Suiza, 44 % leasing	Fidelización y renovación anticipada del leasing
Candidatos a Renovación	33,7	Coche más antiguo (+0,5), casi sin enchufables (–0,5), 85 % nunca financió, el más joven	Bono por entregar el usado + financiación
Pioneros Eléctricos	15,1	94 % enchufables (+1,9), coche más nuevo (–0,6)	Servicios de carga y renovación a nuevos EQ
Clientes Silenciosos	12,5	Consentimiento –2,3: solo aceptan ePost	Recuperar el consentimiento
Clientes Perdidos	10,1	Sin vehículo actual (–1,2), todos con vehículos pasados (+1,5)	Campaña de recuperación (win-back)

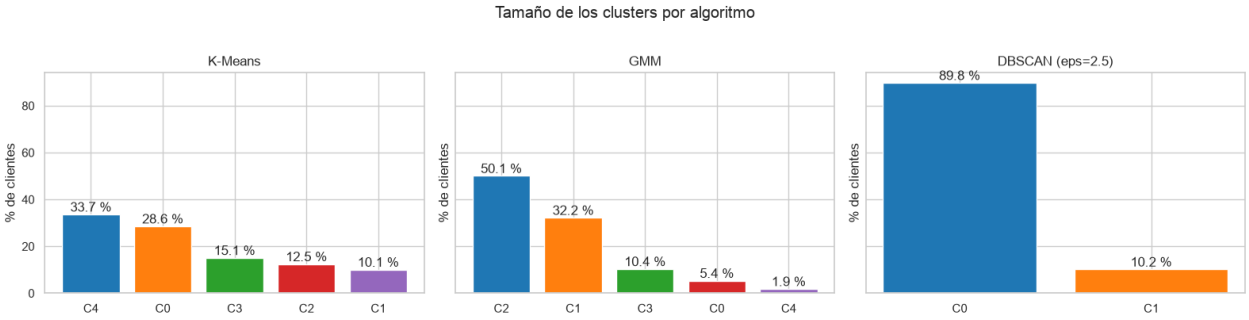
Conclusión: lo que separa a los clientes es su relación con la marca (antigüedad, vehículo actual, financiación, consentimiento) y la motorización, no la gama del coche ni la forma de conducir. Candidatos a Renovación es la mayor oportunidad de venta y electrificación.

Reto avanzado 1 · Comparativa de algoritmos

Mismos datos (*X_model.csv*) y mismo k = 5: K-Means frente a **GMM** (probabilístico) y **DBSCAN** (por densidad; no admite k). Métricas sobre la misma muestra de 20.000 clientes.



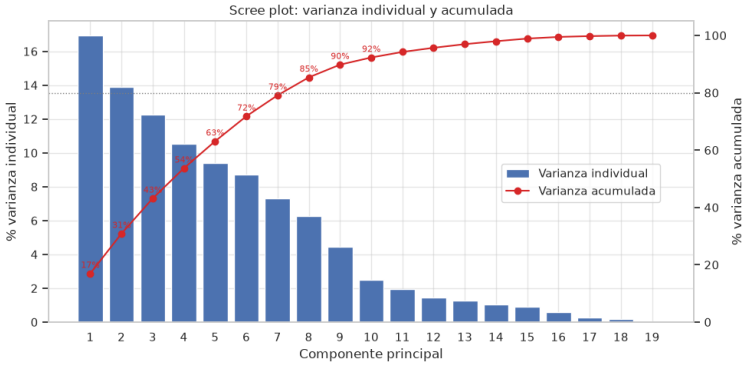
Métricas. K-Means tiene el mejor Silhouette con 5 clusters (0,137 frente a 0,090 de GMM). DBSCAN sale más alto (0,185) pero solo encuentra **2 clusters**, así que no es comparable. El ARI frente a K-Means (0,39 GMM, 0,14 DBSCAN) muestra que **los segmentos cambian**.



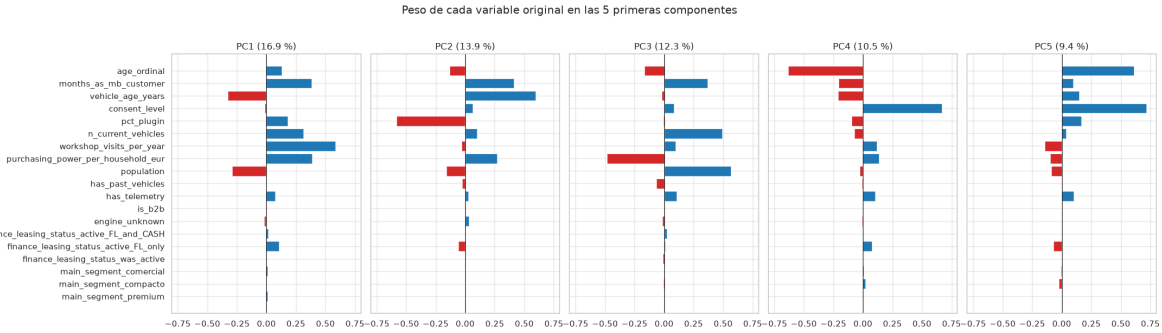
Tamaños. K-Means da segmentos equilibrados (10–34 %); GMM junta segmentos (un cluster con el 50 %) y crea uno residual del 2 %; DBSCAN separa solo a los Clientes Perdidos (10 %) del resto (90 %). Con ningún *eps* encuentra 5 grupos: no hay zonas vacías entre segmentos.

Conclusión: K-Means es el algoritmo más adecuado: mejor Silhouette con k = 5, segmentos equilibrados e interpretables, estable y capaz de asignar clientes nuevos. Clientes Perdidos es el único segmento que detectan los tres algoritmos.

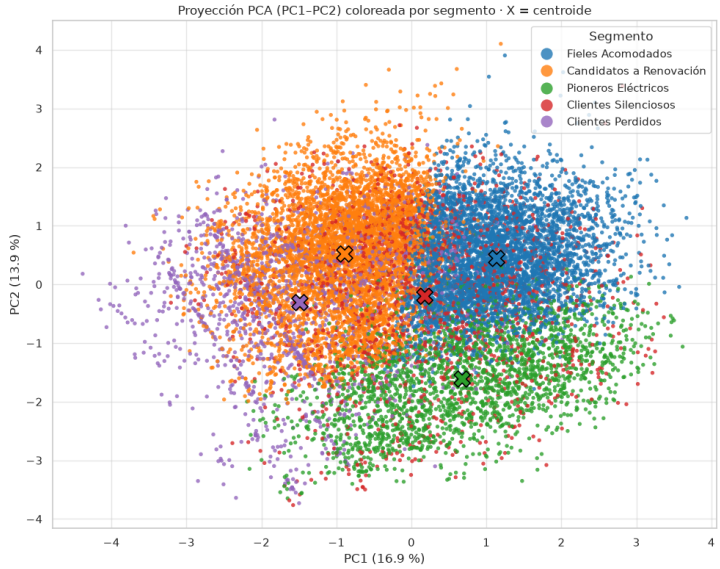
Reto avanzado 2 · PCA y visualización



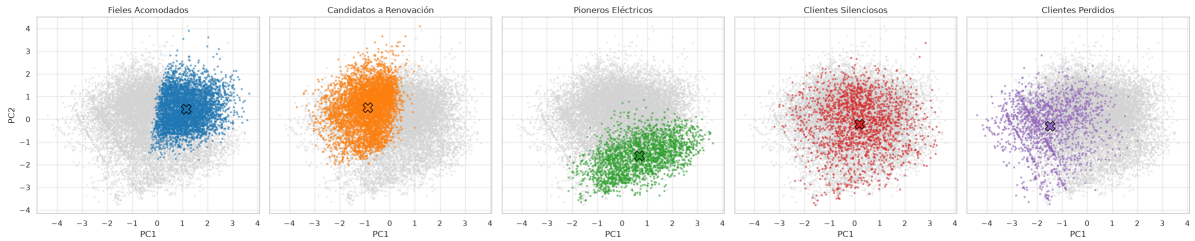
Cada **componente principal (PC)** es una combinación de las 19 variables que resume la mayor variación posible de los datos. **Varianza explicada:** muy repartida: PC1 16,9 %, PC2 13,9 %, PC3 12,3 %. El plano 2D recoge solo el **30,9 %** y hacen falta 8 componentes para llegar al 80 %: un scatter 2D enseña menos de un tercio de la estructura.



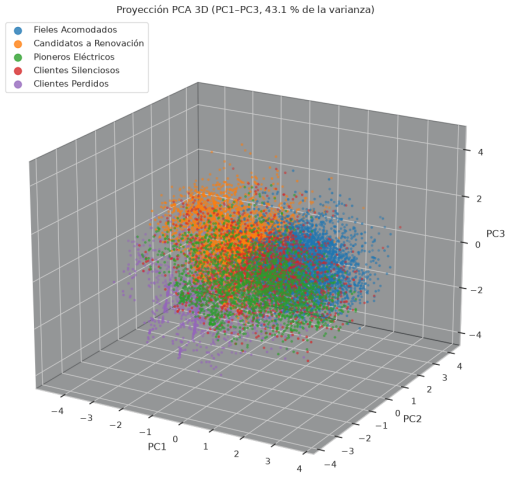
Cargas. PC1 = intensidad de la relación con la marca (visitas, antigüedad, poder adquisitivo); PC2 = coche veterano de combustión ↔ coche nuevo electrificado; PC3 = entorno urbano y nº de vehículos; PC4–PC5 = consentimiento.



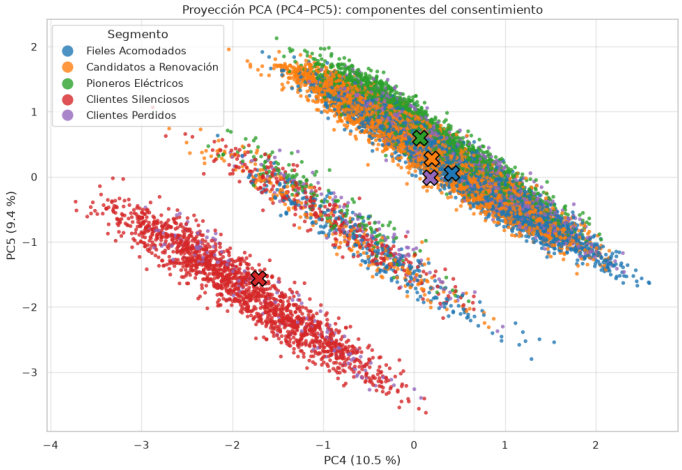
Scatter PC1–PC2. Pioneros Eléctricos abajo (PC2 bajo), Fieles Acomodados a la derecha (PC1 alto) y Candidatos a Renovación a la izquierda y arriba. Las nubes se tocan en los bordes: no hay fronteras limpias.



Cada segmento sobre la nube completa. Cada uno ocupa su zona; los Clientes Silenciosos quedan repartidos por el centro.



3D (PC1–PC3, 43,1 %). Los Clientes Perdidos se separan mejor por PC3 (sin vehículos actuales).

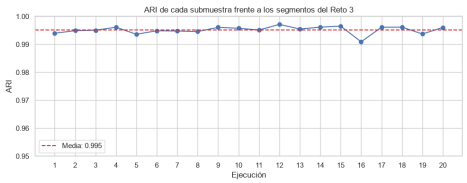


PC4–PC5. Las tres bandas son los niveles de consentimiento; la inferior es casi toda de **Clientes Silenciosos**, invisibles en 2D y 3D.

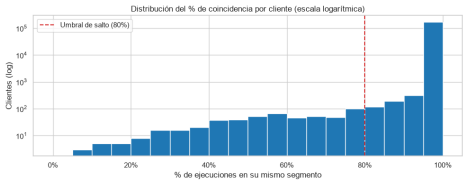
> *Conclusión: los clusters son parcialmente separables. Tres se distinguen en 2D, los Perdidos en 3D y los Silenciosos solo en PC4–PC5. PCA confirma la interpretación de negocio del Reto 4; un Silhouette más alto en el espacio PCA no indicaría mejores segmentos, solo otro espacio de medida.*

Reto avanzado 3 · Estabilidad (Jackknife)

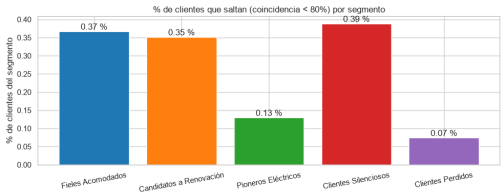
20 reentrenamientos de K-Means (k = 5), cada uno **sin un 20 % aleatorio** de los clientes (el extremo exigente del rango 10–20 %), emparejando los clusters con los segmentos del Reto 3 por centroide.



ARI por ejecución. Entre 0,991 y 0,997 (media 0,995): se reproducen los mismos 5 segmentos sea cual sea el 20 % excluido.



Coincidencia por cliente (escala logarítmica). El **99,3 %** cae siempre en su segmento; solo un 0,3 % (518 clientes) baja del 80 % y «salta».



Saltos por segmento. Ningún segmento es inestable (todos < 0,4 %); el más estable es Clientes Perdidos (0,07 %). El 62 % de los saltos son entre Fieles Acomodados y Candidatos a Renovación: clientes en la frontera entre ambos.

> *Conclusión: la segmentación es estable y fiable para decidir campañas. Los pocos clientes frontera pueden recibir la acción de cualquiera de sus dos segmentos posibles.*

Conclusiones del proyecto

1. **Datos:** 173.454 clientes y 19 features, imputando en lugar de eliminar (se perdería el 19,1 %, con sesgo).
2. **Modelo:** K-Means con k = 5 (codo y máximo del Silhouette coinciden; idéntico con 5 semillas).
3. **Segmentos:** 5 perfiles con una acción cada uno; los separa la relación con la marca y la motorización.
4. **Validación:** K-Means supera a GMM y DBSCAN, PCA confirma la interpretación y el jackknife, la estabilidad.
5. **Limitación:** Silhouette bajo (~0,14): los clientes forman un continuo; los segmentos son una partición útil y estable, no grupos aislados.

Recomendación: usar los 5 segmentos en las campañas, empezando por Candidatos a Renovación y recuperando antes el contacto con Clientes Silenciosos y Clientes Perdidos (22,6 % de la base).