Clustering the Star

Segmentación de clientes Mercedes-Benz con K-Means — resultados y decisiones de los 4 retos básicos

---

Este documento resume, en el orden en que trabajamos, **qué vimos en los datos, qué decidimos y por qué**. Cada decisión se apoya en un resultado o gráfico obtenido en los notebooks (*notebooks-básico/01–04*), de donde se han extraído todas las cifras.

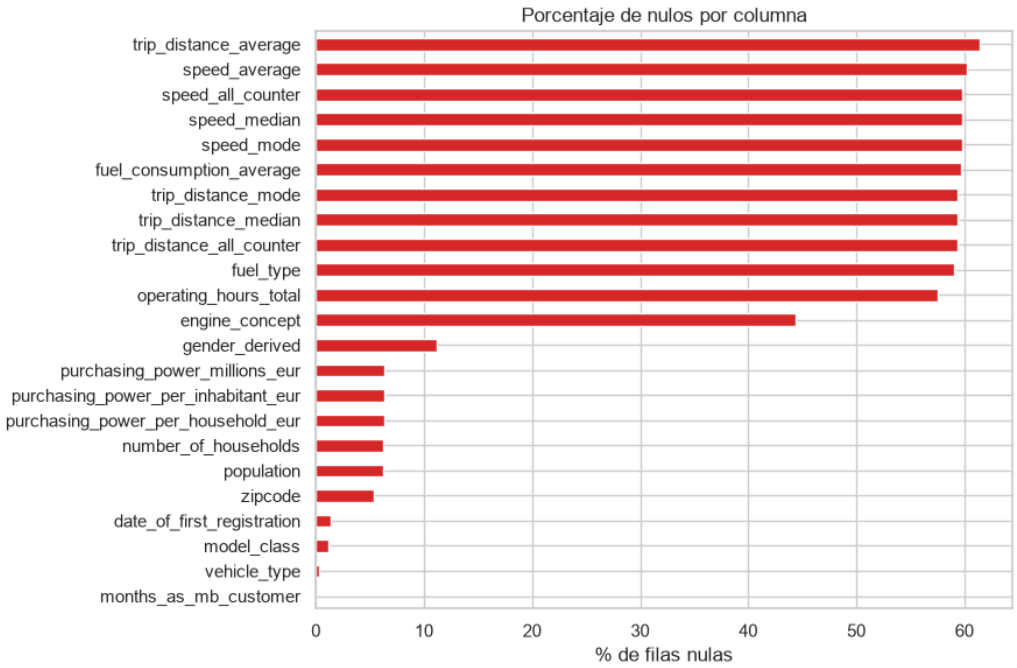
Resultado en tres líneas

1. Pasamos de 302.850 filas cliente–vehículo a **173.454 clientes** con 19 features, sin eliminar datos por nulos (imputando de forma justificada).
2. K-Means con **k = 5**: el codo y el máximo del Silhouette coinciden, y el resultado es idéntico con 5 semillas distintas (ARI ≥ 0,993).
3. Los 5 clusters son **5 segmentos de negocio** con una acción de marketing distinta: Fieles Acomodados, Candidatos a Renovación, Pioneros Eléctricos, Clientes Silenciosos y Clientes Perdidos.

Reto	Entregable
1 · EDA y calidad	notebooks-básico/01_eda.ipynb
2 · Feature engineering	notebooks-básico/02_feature_engineering.ipynb
3 · K-Means	notebooks-básico/03_kmeans.ipynb
4 · Segmentos	notebooks-básico/04_segmentos.ipynb

1. Los datos y sus problemas de calidad

Lo que vimos. El fichero tiene 302.850 filas × 38 columnas, pero **cada fila es un par cliente–vehículo**: hay 173.456 clientes y 244.519 vehículos. Además, la telemetría falta en ~60 % de las filas y la motorización en un 44 %.



Porcentaje de nulos por columna (EDA, sección 3).

Problema	Evidencia	Qué hicimos
Primera descarga truncada	Faltaban 17.925 filas	Re-descarga y verificación por SHA-256
Granularidad cliente–vehículo	302.850 filas / 173.456 clientes	Agregar a una fila por cliente
Telemetría ~60 % nula	Falta más en vehículos no actuales: no es aleatoria	No imputar; resumirla en *has_telemetry* y usarla solo para perfilar
Motorización 44 % nula	*fuel_type* es nulo en las mismas filas: no sirve para completar	Completar desde el modelo del vehículo (página 3)
Outliers	Velocidad > 150 km/h (26), consumo > 25 l (604)	Recorte p1–p99 y log, sin borrar filas
Redundancias	5 pares con $\rho \geq 0{,}85$	Conservar una variable por grupo

2. Decisión: imputar en lugar de eliminar

La pregunta. Tras agregar por cliente quedaban huecos en poder adquisitivo, población y segmento. Los apuntes dicen que eliminar filas solo es aceptable si afecta a **menos del 5 %** y los nulos son **aleatorios**. Comprobamos qué pasaría si eliminásemos a esos clientes:

Variable (media)	Se quedan	Se eliminarían
Antigüedad como cliente (meses)	36,4	23,3
Edad del vehículo (años)	4,7	5,1
% con telemetría	63 %	47 %
% segmento comercial	8,9 %	20,1 %
% segmento premium	11,1 %	15,6 %

Resultado. Se eliminarían **33.083 clientes (19,1 %)**, casi cuatro veces el umbral, y **no al azar**: serían sobre todo clientes recientes y del segmento comercial.

> *Decisión: imputar (poder adquisitivo y población con la mediana por país, porque su distribución es bimodal Suiza/Austria). Solo se eliminan 2 clientes sin antigüedad.*

Motorización: completar en vez de descartar

Completamos *engine_concept* con la motorización más frecuente de cada *vehicle_type*, más reglas por nombre de modelo (EQ*, «e», hybrid…). Para validarlo, ocultamos la mitad de los valores conocidos y los volvimos a predecir: **cobertura 99,9 % y acierto 95,5 %**. Los nulos bajan del **44,4 % al 17,6 %**; el resto se marca con *engine_unknown*.

3. Decisión: qué features entran en el modelo

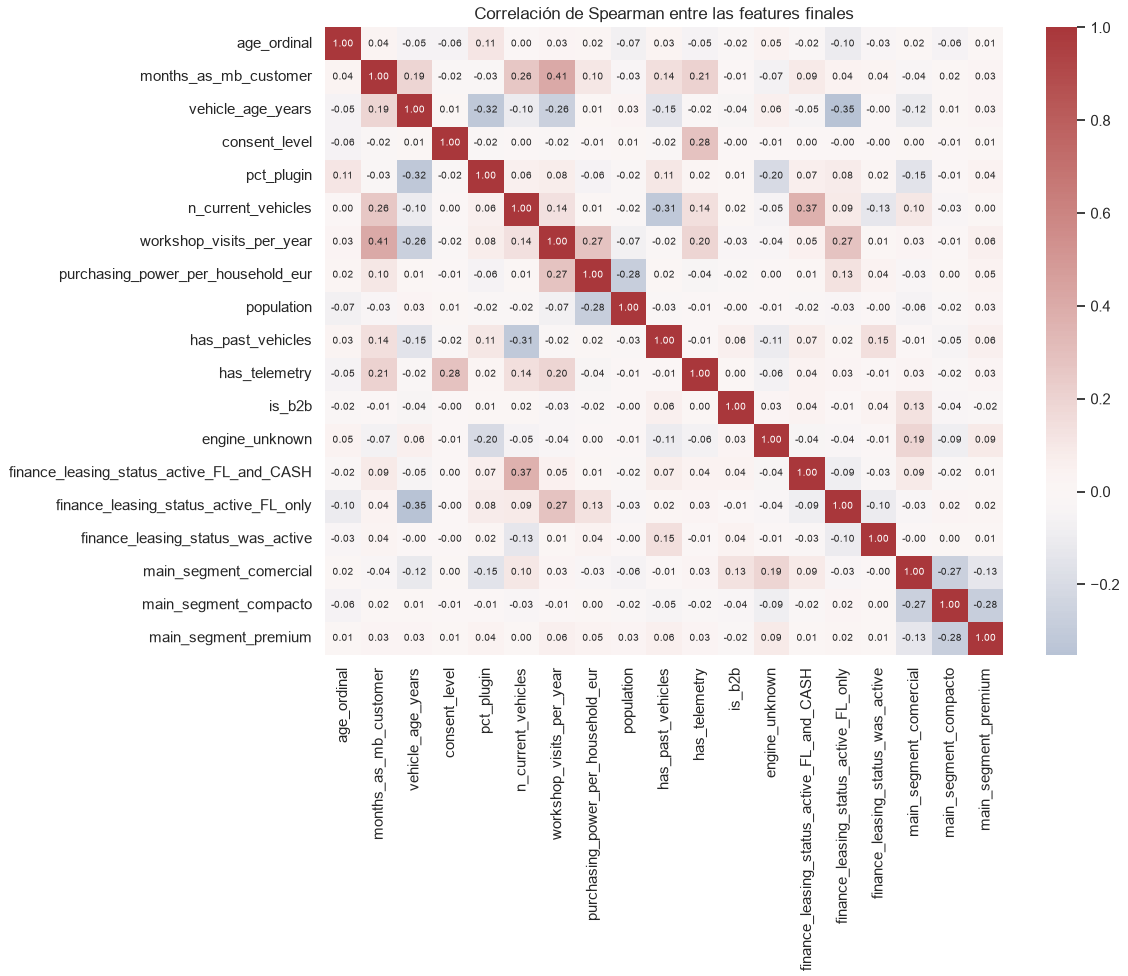
No usamos todas las columnas: elegimos las que responden a preguntas de marketing y creamos **features derivadas** a nivel vehículo antes de agregar por cliente.

Feature	Por qué (negocio)
vehicle_age_years (derivada)	Momento del ciclo de vida del coche: mantenimiento y renovación
workshop_visits_per_year (derivada)	Visitas de garantía/goodwill normalizadas por la edad del coche
pct_plugin + **engine_unknown** (derivadas)	Afinidad con la electrificación, sin confundir «desconocido» con «combustión»
consent_level (derivada)	Alcance de las comunicaciones (media de los 3 canales)
has_past_vehicles, **has_telemetry**, **is_b2b**	Renovación previa, vehículo conectado, empresa
months_as_mb_customer, n_current_vehicles	Antigüedad y tamaño de la relación con la marca
purchasing_power, population, age	Capacidad económica, entorno urbano/rural, edad
finance_leasing_status, main_segment (one-hot)	Relación con la financiación y posición en la gama

Descartadas: identificadores, telemetría detallada (~60 % nula, solo para perfilar), género (inferido, no declarado), país (partiría los clusters por mercado) y las variables redundantes.

Pipeline único (sklearn): agregación por cliente → imputación por país → log en variables asimétricas → recorte p1–p99 → StandardScaler; one-hot para las categóricas.

4. Decisión: eliminar redundancias



Correlación de Spearman entre las 19 features finales (Reto 2, sección 5).

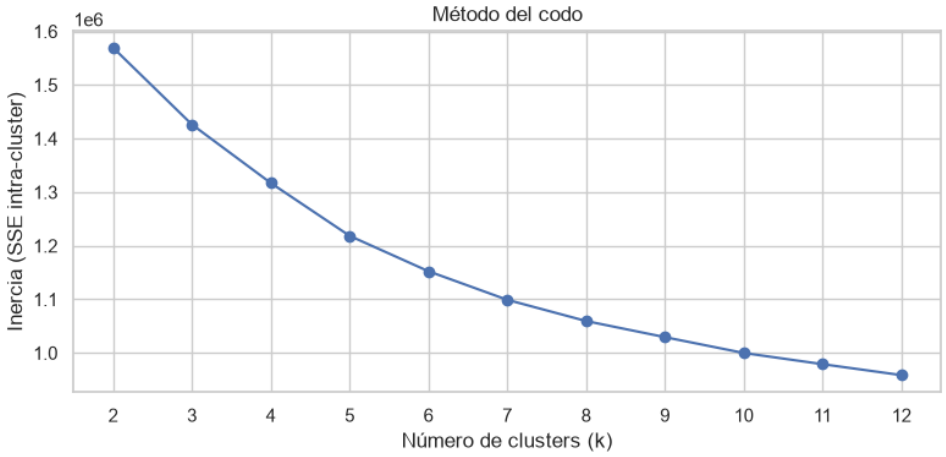
— **has_commercial_vehicle** tenía ρ = 0,92 con *main_segment = comercial*: contaba lo mismo dos veces → **eliminada**.

— Con el one-hot completo, *FL_only* y *never_active* tenían ρ = –0,86 y *compacto* y *medio*, –0,63. No es información de los clientes: las categorías de una misma variable son excluyentes. → **Se quita la categoría de referencia** (la mayoritaria: *never_active* y *medio*).

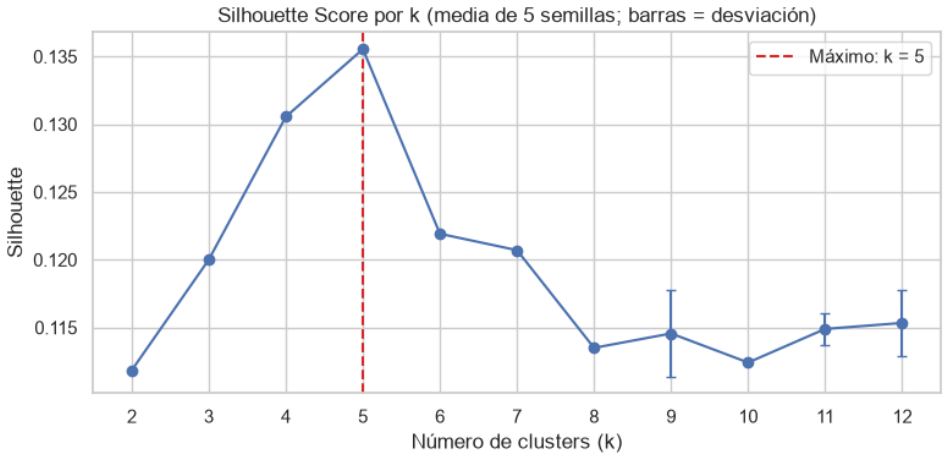
— **Resultado:** ningún par supera ya |ρ| = 0,8; el máximo es 0,41 (antigüedad – visitas al taller).

5. Elección del número de clusters: k = 5

Entrenamos K-Means para **k = 2…12** con *k-means*++, 10 inicializaciones y **5 semillas por k** (55 modelos). Criterio de finalización (apuntes T2-2): sin reasignaciones o desplazamiento de centroides < *tol*; todos convergen antes del tope de 300 iteraciones.



Método del codo: inercia por k.



Silhouette por k (media de 5 semillas; calculado sobre 5 muestras de 20.000 clientes).

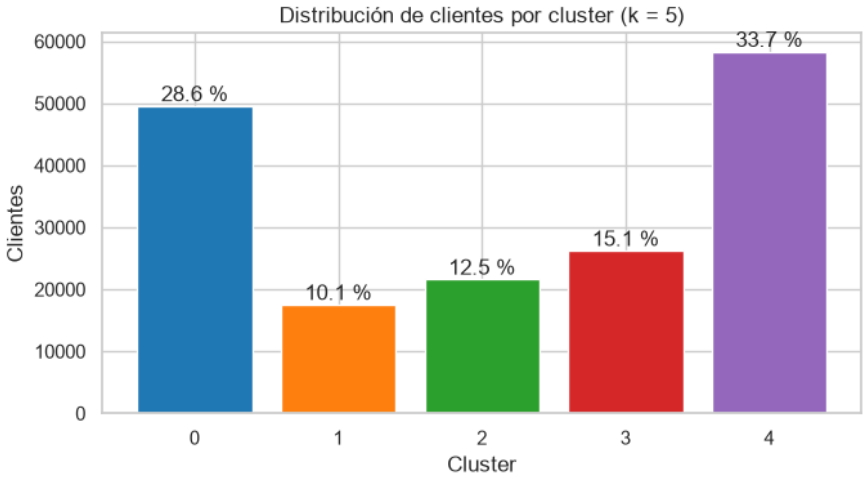
Criterio	Resultado
Codo	Caídas de inercia ≥ 7,5 % hasta k = 5; a partir de k = 6, ≤ 5,4 %
Silhouette	Máximo en k = 5 (0,136) con las 5 semillas
Robustez	Con k = 5 las 5 semillas dan los mismos clusters (ARI ≥ 0,993); a partir de k = 9 empiezan a diferir
Tamaños	Entre el 10,1 % y el 33,7 %: ningún cluster residual

6. ¿Por qué el Silhouette es bajo (0,14)?

El Silhouette va de –1 a 1; por debajo de ~0,25 indica que no hay grupos claramente separados: cada cliente está solo algo más cerca de su cluster que del vecino. Posibles motivos:

1. **Los clientes forman un continuo:** antigüedad, edad del coche o poder adquisitivo varían de forma gradual, y K-Means parte ese continuo dejando muchos clientes en la frontera.
2. **19 dimensiones:** con muchas dimensiones las distancias tienden a parecerse.
3. **Mezcla de variables continuas y binarias**, que encajan peor con la distancia euclídea.

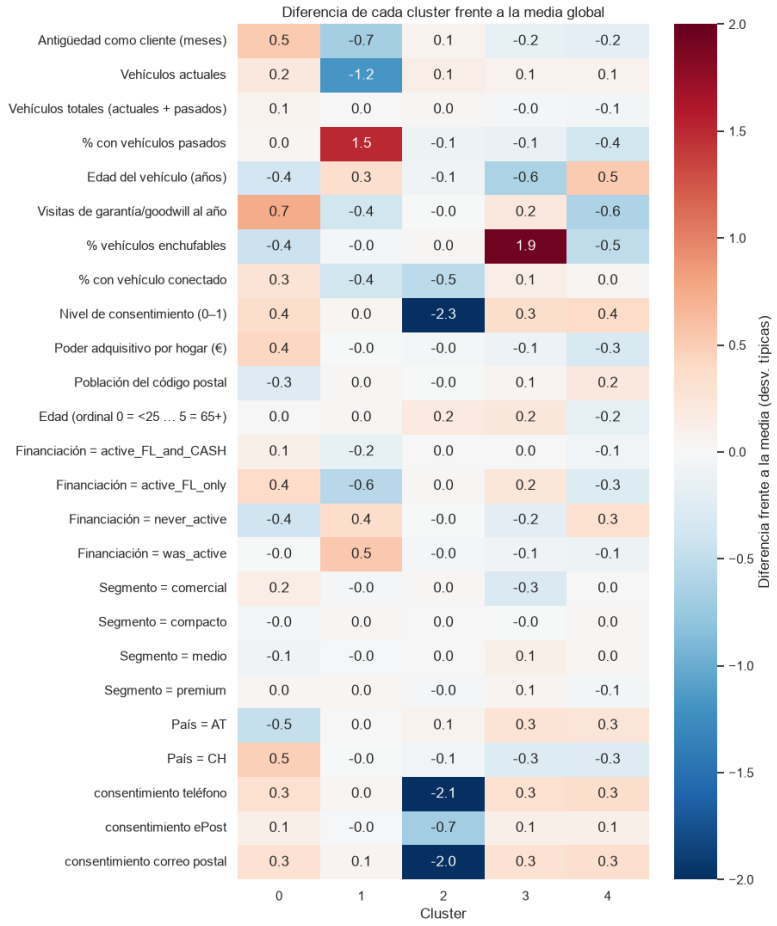
Conclusión: los 5 segmentos no son grupos naturales aislados, sino una partición útil y reproducible de un continuo de clientes. Para elegir k lo que importa es la comparación entre valores de k, y ahí k = 5 es el mejor.



Distribución de clientes por cluster (k = 5).

7. ¿Qué distingue a cada segmento?

Para no nombrar los segmentos a ojo, medimos la diferencia de cada variable frente a la media global en **desviaciones típicas** (|d| > 0,5 relevante; > 1 muy marcada). Los nombres se asignan con reglas sobre estos rasgos.

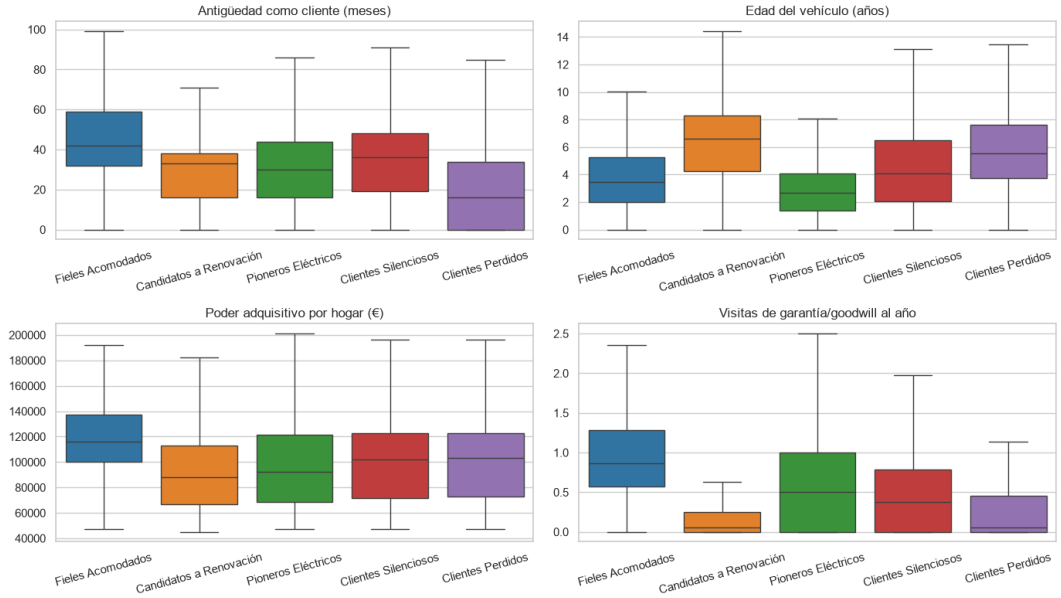


Diferencia de cada cluster frente a la media global (Reto 4, sección 2).

Cl.	Segmento	Rasgo que lo define (d)
0	Fieles Acomodados	Visitas de garantía +0,7, antigüedad +0,5, Suiza +0,5
1	Clientes Perdidos	Vehículos pasados +1,5, vehículos actuales –1,2
2	Clientes Silenciosos	Consentimiento –2,3 (teléfono –2,1, correo postal –2,0)
3	Pioneros Eléctricos	% enchufables +1,9, edad del vehículo –0,6
4	Candidatos a Renovación	Visitas de garantía –0,6, edad del vehículo +0,5, enchufables –0,5

8. Los 5 segmentos y qué hacer con cada uno

Segmento	%	Perfil (media del segmento)	Acción de marketing	Canal
Fieles Acomodados	28,6	45 meses de antigüedad, 124.500 €/hogar, 89 % Suiza, 44 % en leasing, coche de 3,7 años	Fidelización y renovación anticipada del leasing; prueba de modelos electrificados (solo 4 % enchufables)	Todos; concesionario
Candidatos a Renovación	33,7	Coche de 6,4 años, 1 % enchufables, 85 % nunca financió, el más joven (47 % < 45 años)	Bono por entregar el usado + financiación de entrada baja; plan de mantenimiento post-garantía	Todos; digital
Pioneros Eléctricos	15,1	94 % enchufables, coche de 2,9 años, 37 % en leasing	Wallbox, carga y servicios conectados; renovación a nuevos EQ; programa de recomendación	App / digital
Clientes Silenciosos	12,5	Solo aceptan ePost (89 %); teléfono 14 % y correo postal 13 %	Recuperar el consentimiento ofreciendo valor a cambio	Solo ePost; presencial
Clientes Perdidos	10,1	0 vehículos actuales, todos con vehículos pasados, 20 meses de antigüedad	Win-back: encuesta de salida y oferta de vuelta	Teléfono y correo postal



Variables clave por segmento (Reto 4, sección 5).

Conclusiones

— Lo que separa a los clientes es su **relación con la marca** (antigüedad, vehículo actual o no, financiación, consentimiento) y la **motorización**, no la gama del coche ni la forma de conducir.

— **Candidatos a Renovación** (33,7 %) es la mayor oportunidad de venta y de electrificación.

— **Clientes Silenciosos y Clientes Perdidos** (22,6 %) necesitan un paso previo — recuperar el contacto o el vínculo — antes de cualquier campaña.