MALACKATHON
INFORMATICA UMA

UNIVERSIDAD DE MÁLAGA | uma.es

III MALACKATHON 2026

MERCEDES-BENZ GROUP SERVICES MADRID

CLUSTERING THE STAR

¿Te interesa la ciencia de datos aplicada al mundo real del automóvil?

Te invitamos a participar en el III Malackathon, en el reto de la empresa Mercedes-Benz, reto diseñado para aplicar tus habilidades en un problema real de la industria.

En esta edición, proponemos **segmentar la base de clientes de Mercedes-Benz** mediante técnicas de aprendizaje no supervisado (clustering), con el objetivo de habilitar estrategias de marketing personalizadas:

- Ofertas de vehículos
- Planes de mantenimiento
- Campañas de fidelización
- Comunicaciones dirigidas

Trabajaremos con un dataset de datos reales de clientes proporcionado por Mercedes-Benz. El reto básico consiste en explorar los datos, preparar las features adecuadas e implementar un modelo de clustering **K-Means** que segmente a los clientes en grupos homogéneos, interpretando cada segmento con sentido de negocio. El resto de herramientas, lenguajes de programación y librerías de visualización es de libre elección, aunque se recomienda realizarlo con Python (pandas y scikit-learn) o R.

¿Qué aprenderás participando?

- **Procesamiento de datos a escala:** preparación, limpieza y transformación real
- **Ingeniería de características:** cómo seleccionar, crear y codificar variables relevantes para un modelo de machine learning no supervisado
- **Segmentación de clientes:** diseño, implementación y evaluación de modelos de clustering
- **Pensamiento analítico de negocio:** cómo traducir resultados técnicos en perfiles de cliente e insights accionables para un equipo
- **Visualización avanzada:** diseño de gráficos y dashboards que comunican los segmentos de forma clara y atractiva

El Malackathon tiene dos tipos de retos: retos básicos y retos avanzados. Estos últimos son los que darán acceso a la final del viernes. Cada uno de estos retos avanzados será evaluado por los mentores de los patrocinadores de cada premio. Para poder ser

evaluado en alguno de los retos avanzados, debes haber cubierto completamente todos los retos básicos.

RETOS BÁSICOS

1.- Reto de exploración y calidad de datos

Deberás acceder a los datos de cliente. Esta tabla integra información de múltiples dimensiones: perfil demográfico del cliente, características del vehículo, relación con la marca, consentimientos de comunicación y poder adquisitivo por zona geográfica.

Se pide realizar un **análisis exploratorio de datos (EDA) completo** que incluya:

- Estadísticas descriptivas de variables principales
- Análisis de valores nulos e inconsistencias, con una propuesta de tratamiento justificada
- Distribuciones de variables clave
- Identificación y exclusión justificada de columnas de metadatos e identificadores que no aportan valor analítico

Para evaluar el reto se debe proporcionar:

- Notebook con el EDA ejecutado y documentado
- Breve resumen de hallazgos y conclusiones:
    - ¿Cuáles son las principales características de los clientes?
    - ¿Qué problemas de calidad habéis encontrado y cómo habéis resuelto?

2.- Reto de feature engineering

El grupo deberá seleccionar y preparar las variables que alimentarán el modelo de clustering. No se trata de usar todas las columnas a ciegas, sino de **pensar como un analista de negocio.** ¿qué información es realmente útil para segmentar clientes?

Se pide:

- Selección justificada de features a incluir
- Creación de al menos **una feature derivada.** Como sugerencia:
    - Antigüedad del vehículo a partir de la fecha de registro
- Tratamiento adecuado de variables categóricas: codificación adecuada
- Tratamiento adecuado de variables numéricos: imputación de nulos o eliminación y escalado de las variables
- Construcción de un **pipeline** que encapsule todo el proceso de transformación

Para evaluar el reto se debe proporcionar:

- Notebook con el pipeline de preparación ejecutado y documentado
- Listado de features seleccionadas con justificación breve de cada una
- Descripción de las features derivadas creadas

3.- Reto Modelo de clustering (K-Means)

El grupo deberá implementar un modelo de clustering **K-Means** sobre los datos preparados en el reto anterior.

Se pide:

- Ejecución de K-Means para un rango de valores de ***k*** **(hace referencia al número de clúster seleccionados)**
- Cálculo del **método del codo** para seleccionar el *k* óptimo
- Cálculo del **Silhouette Score** para cada valor de *k*
- Entrenamiento del modelo final con el *k* elegido
- Distribución de clientes por cluster

Para evaluar el reto se debe proporcionar:

- Notebook con el modelo ejecutado, gráficos generados de codo y silhouette junto su documentación
- Selección y justificación del número óptimo de clusters

4.- Interpretación de los segmentos

El grupo deberá describir los clusters obtenidos **en lenguaje de negocio,** no solo en términos técnicos. Cada segmento debe tener un perfil claro que un equipo de marketing pueda entender y utilizar.

Se pide:

- Perfil del cliente de cada cluster
- Nombre descriptivo para cada segmento. Por ej. “Premium Tradicional”, “Joven Digital”...

Para evaluar el reto se debe proporcionar:

- Notebook con las tablas y gráficos de perfilado por cluster

RETOS AVANZADOS

1.- Comparativa de algoritmos de clustering

Comparad los resultados de K-Means con al menos **otro algoritmo de clustering** que esté disponible (DBSCAN, Gaussian Mixture Models, Agglomerative Clustering...)

Se pide:

- Entrenar el/los algoritmo(s) alternativos con el mismo *k* y los mismos datos preparados
- Compararlos Silhouette Scores de todos los algoritmos

- Analizar si los segmentos cambian significativamente entre algoritmos
- Gráfico comparativo de rendimiento

Para evaluar el reto se debe proporcionar:

- Notebook con la comparativa ejecutada
- Tabla y gráfico comparativo de métricas
- Conclusión razonada sobre el algoritmo más adecuado

2.- Reducción de dimensionalidad y visualización

Aplicad técnicas de **reducción de dimensionalidad (PCA)** para visualizar los clusters en un espacio 2D o 3D

Se pide:

- Aplicar PCA sobre las features
- Indicar la varianza explicada por cada componente principal y la acumulada
- Gráfico scatter 2D (y opcionalmente 3D) coloreado por cluster
- Análisis de qué variables originales pesan más en cada componente principal

Para evaluar el reto se debe proporcionar:

- Notebook con PCA ejecutado y gráficos generados
- Interpretación de las componentes principales
- Valoración: ¿los clusters son visualmente separables?

3.- Estabilidad de Clusters: Jackknife Clustering

Un modelo de clustering puede ofrecer buenos valores de Silhouette y sin embargo producir segmentos inestables: pequeñas variaciones en los datos de entrada provocan que los clusters cambien drásticamente.

Para validar que la segmentación de clientes es robusta y fiable antes de basar decisiones de marketing en ella, se pide aplicar la técnica de Jackknife Clustering.
La idea es la siguiente: si eliminamos un subconjunto aleatorio de clientes y re-entrenamos el modelo, ¿se mantienen los mismos segmentos? Si los clusters son estables, las asignaciones deberían ser consistentes independientemente de qué clientes se excluyan.

Se pide:

- **Implementar Jackknife Clustering**: generar *N* submuestras del dataset (por ejemplo 20) cada una excluyendo un porcentaje de los datos (por ejemplo, 10-20%). Entrenar el K-Means con el mismo *k* óptimo sobre cada submuestra

- **Medir la estabilidad de las asignaciones**: para los clientes presentes en múltiples submuestras, comparar sus asignaciones de cluster entre ejecuciones. Utilizar métricas como el **porcentaje de coincidencia de asignación**
- **Análisis por cluster:** ¿hay algún segmento que sea especialmente inestable? ¿algún grupo de clientes que "salta" entre clusters en distintas ejecuciones?

Para evaluar el reto se debe proporcionar:

- Notebook con la implementación anterior
- Gráficos que muestren las conclusiones anteriores
- Análisis de los clusters más/menos estables y por qué
- Recomendación final

DICCIONARIO DE DATOS

Columna	Descripción	Tipo de dato	Ejemplo
client_id	Identificador del cliente	string	12345
vehicle_id	Identificador de vehículo	string	12345
age_range	Rango de edad	string	20-30
gender_derived	Género del cliente derivado (inferido) a partir de otra información del cliente; no es un dato declarado directamente.	string	female
model_series	Número de la serie del modelo del vehículo.	string	205
vehicle_type	Denominación comercial específica del tipo o acabado del vehículo (C 200, GLE 450 4MATIC).	string	C 200 d
model_class	Clase o categoría del vehículo (p. ej., Clase A – Clase S, Clase GLE/GLS).	string	C-Class
product_group	Grupo de producto para identificar si es un Passenger car (P), Vans (V), etc.	string	P
engine_concept	Concepto de motorización del	string	ICE

	vehículo (p. ej., combustión, híbrido o eléctrico).		
country_code	Código de país ISO. En los datos de cliente, país de mercado del cliente; en la relación cliente-vehículo, país en el que se establece la conexión con el vehículo; en los datos sociodemográficos, país al que corresponde el código postal.	string	DE
fuel_type	Tipo de combustible del vehículo (p. ej., diésel, gasolina, eléctrico).	string	Diesel
date_of_first_registration	Día del primer registro de matriculación del vehículo en cuestión.	date	2021-02-01
is_current_vehicle	Indicador que señala si la relación con este vehículo está actualmente activa.	boolean	false
role	Rol del cliente en relación con el vehículo (p. ej., Driver, Owner).	string	Owner
role_type	Clasificación de la relación con el vehículo, si forma parte de una empresa (B2B: flota/empresa) o consumidor (B2C: particular).	string	B2C
months_as_mb_customer	Meses desde que inició su relación con la marca (meses desde su primera conexión a un coche).	integer	76
currently_connected_vehicles	Número de vehículos actualmente vinculados al cliente.	integer	1

finance_leasing_status	Situación del cliente en relación con operaciones de financiación mediante leasing financiero (FL) y compras al contado (Cash).	string	was_active
workshop_visits_warranty_goodwill	Número de visitas al taller durante el periodo de garantía.	int	3
consent_phone_communication_channel	Indica si el cliente ha dado su consentimiento para ser contactado por teléfono con fines de comunicación comercial.	boolean	true
consent_epost_communication_channel	Indica si el cliente ha dado su consentimiento para ser contactado por canal electrónico (ePost / correo electrónico) con fines de comunicación comercial.	boolean	true
consent_post_communication_channel	Indica si el cliente ha dado su consentimiento para ser contactado por correo postal con fines de comunicación comercial.	boolean	false
purchasing_power_per_inhabitant_eur	Poder adquisitivo medio estimado por habitante del código postal, expresado en euros.	double	7425.96
purchasing_power_per_household_eur	Poder adquisitivo medio estimado por hogar del código postal, expresado en euros.	double	20601.05
population	Población total de la zona geográfica	integer	688

	correspondiente al código postal.		
zipcode	Código postal asociado al cliente / correspondiente a la zona geográfica de los datos sociodemográficos.	string	81925
trip_distance_average	Distancia media recorrida por trayecto (km).	double	—
trip_distance_mode	Distancia recorrida por trayecto que aparece con mayor frecuencia (moda).	string	—
trip_distance_median	Distancia mediana recorrida por trayecto.	double	—
trip_distance_all_counter	Número total de trayectos utilizados para calcular las métricas de distancia.	double	—
operating_hours_total	Número total de horas de funcionamiento del vehículo.	double	—
fuel_consumption_average	Consumo medio de combustible del vehículo.	double	—
speed_average	Velocidad media del vehículo.	double	—
speed_mode	Velocidad que aparece con mayor frecuencia (moda).	string	—
speed_median	Velocidad mediana.	double	—
speed_all_counter	Número total de mediciones utilizadas para calcular las métricas de velocidad.	double	—
number_of_households	Número total de hogares de la zona geográfica correspondiente al código postal.	integer	248

purchasing_power_millions_eur	Poder adquisitivo total estimado de la población correspondiente al código postal, expresado en millones de euros.	double	5.109

NOMBRE DEL PREMIO: AIRPODS
Los equipos serán de 4

EMPRESA: Mercedes-Benz Group Services Madrid

Premio: Premio a los ganadores del grupo con unos Airpods
Título: Premiar a los alumnos que mejor interpreten el problema de clustering y mejor perfilen al tipo de cliente de Mercedes-Benz con sentido de negocio y utilidad comercial.

https://u.uma.es/ita/